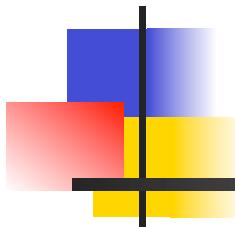
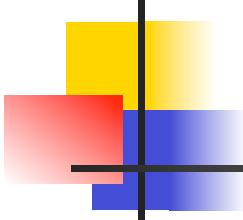


# Aprendizado de Máquina

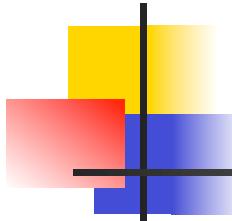
André C. P. L. F. de Carvalho  
Centro de Pesquisa AMDA  
ICMC-USP





# Tópicos

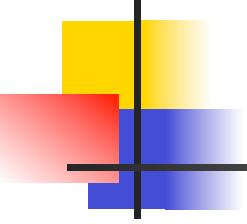
- Introdução
- Aprendizado de Máquina
- Métodos Preditivos
  - Algoritmos de treinamento
  - Avaliação de desempenho
- Métodos Descritivos
  - Algoritmos de treinamento
  - Avaliação de desempenho
- Conclusão



# Introdução

---

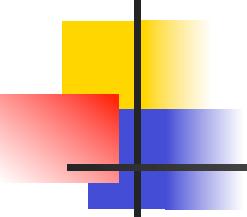
- Sem perceber, as pessoas geram dados a todo momento
  - Aplica para um cartão de fidelidade
    - Empresa aérea, supermercado, ...
  - Faz uma compra com cartão de débito ou crédito
  - Navega pela internet
  - Vai ao médico
- Esses dados são armazenados em computadores



# Explosão de dados

- Máquinas estão continuamente coletando dados
  - E consumidos
  - Por pessoas e máquinas



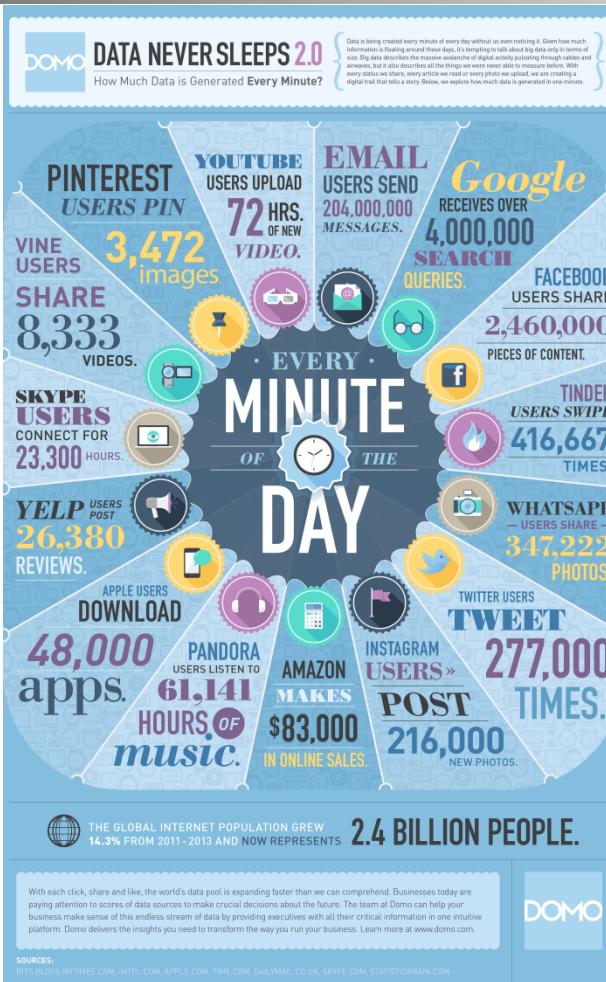


# Explosão de dados

- Todo mundo é um cineasta
  - E quer uma grande audiência
- Todo mundo tem um ótimo gosto para vídeos e músicas
  - E quer que todos possam se beneficiar de seu bom gosto
- Todo mundo está sendo visto e ouvido
  - A toda hora e em todo lugar



# Dados nunca dormem

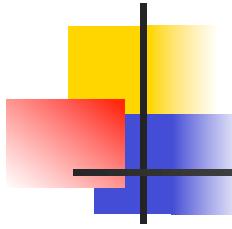


Quantos dados são gerados a cada minuto

Origem: *Domo business management platform*

<https://www.domo.com>

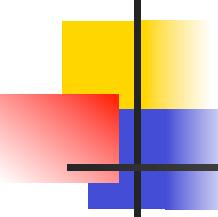
07/2013 e  
05/2014



# Análise de dados

---

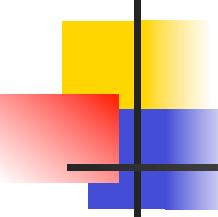
- Análise dos dados por seres humanos
  - Falta de especialistas
  - Custo elevado
  - Subjetividade
  - Grande volume
- Técnicas tradicionais para análise
  - Planilhas
  - Sistemas de gerenciamento de bancos de dados



# Análise de dados

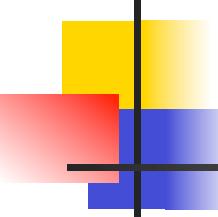
---

- Técnicas tradicionais de análise de dados permitem apenas consultas simples
  - Quantos itens de um produto em particular foram vendidos em um dado dia?
  - Não conseguem responder consultas do tipo:
    - Que novo filme eu gostaria de assistir?
    - Um tecido pode apresentar um tumor?
    - Qual a estrutura terciária de uma nova proteína
  - Técnicas mais sofisticadas, capazes de extrair conhecimento de grandes conjuntos de dados



# Aprendizado de Máquina

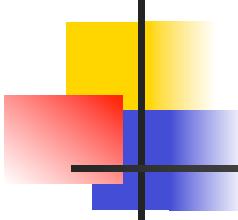
- Investiga técnicas computacionais capazes de adquirir automaticamente
  - Novas habilidades, conhecimentos e formas de organizar o conhecimento existente
- Definições
  - Área de pesquisa que dá aos computadores a habilidade de aprender sem ser explicitamente programado (Arthur Samuel, 1959)
  - Técnicas capazes de melhorar seu desempenho em uma dada tarefa utilizando experiências prévias (Mitchell, 1997)



# Aplicações de AM

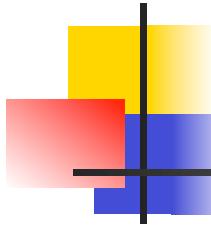
---

- Programas baseados em AM têm sido bem sucedidos para:
  - Análise de redes sociais
  - Análise de dados biológicos
  - Detecção de fraudes
  - Diagnóstico médico
  - Biometria
  - Recomendação de filmes e séries



# Aplicações clássicas de AM

- Aprender a reconhecer palavras faladas
  - SPHINX (Lee 1989)
- Aprender a conduzir um automóvel
  - ALVINN (Pomerleau 1989)
- Aprender a classificar objetos celestiais
  - (Fayyad et al 1995)
- Aprender a jogar gamão
  - TD-GAMMON (Tesauro 1992)



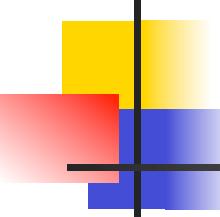
# ALVINN



Dean Pomerleau  
CMU



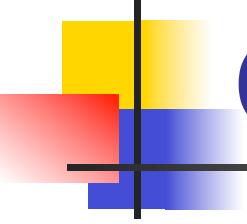
- Autonomous Land Vehicle In a Neural Network
  - Sistema automático de navegação para automóveis baseado em redes neurais
    - Tese de doutorado da CMU
  - Comunicação por uma câmera montada no veículo
  - Dirigiu a 70 M/h (110 Km/h) em uma rodovia pública americana em 1989
    - De costa a costa por 2850 milhas (com exceção de 50 milhas)



# Carros da Google

---

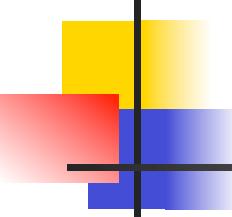
- Stanford Artificial Intelligence Laboratory
- Vários algoritmos de AM
- Comunicação por sensores no topo do carro
  - Lasers, câmeras e informação do Google street view
- Atua no volante de direção e nos pneus
- Mais de 2 milhões de milhas percorridos
  - Metade da rede de estradas americana
  - Acidentes provocados por terceiros (distração)
- Várias cidades permitem carros autônomos



# Carros da Google



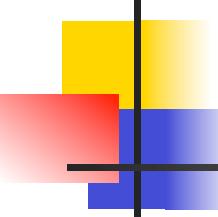
<http://www.citylab.com/tech/2014/05/the-trick-that-makes-googles-self-driving-cars-work/371060/>



# Carros da Google



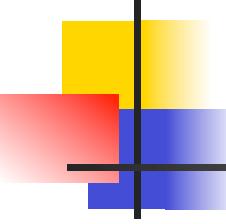
<http://www.theguardian.com/technology/2015/jun/28/google-self-driving-cars-accidents>



# Aprendizado de Máquina

---

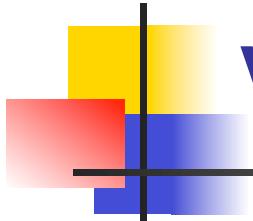
- Algoritmos de AM aprendem a partir de um conjunto de exemplos
  - Indução de hipóteses ou modelos
    - Aplicados depois a novos dados
- Todo algoritmo de AM indutivo possui um viés
  - Tendência a privilegiar uma dada hipótese ou conjunto de hipóteses



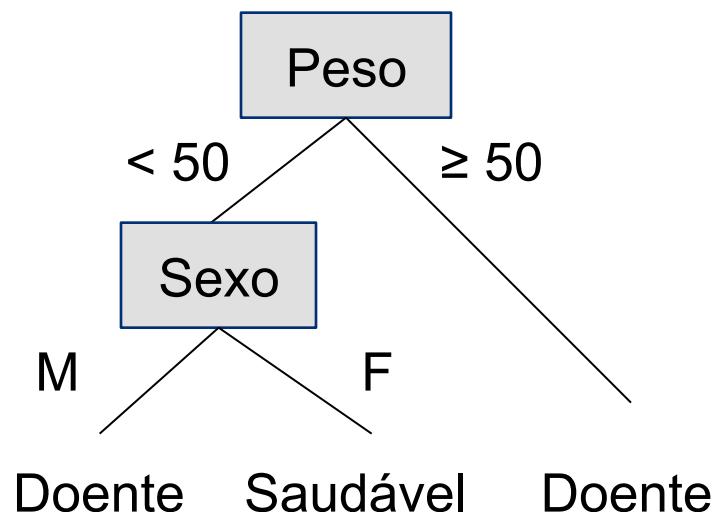
# Viés indutivo

---

- Viés de preferência ou busca
  - Como as hipóteses são pesquisadas no espaço de hipóteses
  - Preferência de algumas hipóteses sobre outras
  - Ex.: preferência por hipóteses simples (curtas)
- Viés de representação ou linguagem
  - Define o espaço de busca ou de hipóteses
  - Restrição das hipóteses que podem ser geradas
  - Ex.: hipóteses no formato de ADs



# Viés de representação



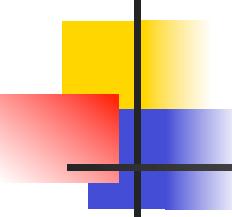
Árvore de decisão

0.45	-0.40	0.54	0.12	0.98	0.37
-0.45	0.11	0.91	0.34	-0.20	0.83
-0.29	0.32	-0.25	-0.51	0.41	0.70

Redes neurais

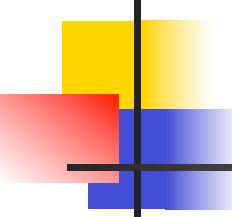
Se Peso  $\geq 50$  então Doente  
Se Peso  $< 50$  e Sexo = M então Doente  
Se Peso  $< 50$  e Sexo = F então Saudável

Conjunto de regras



# Viés indutivo

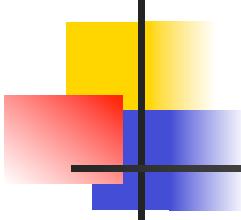
- Algoritmos de AM precisam ter um viés indutivo
  - Necessário para restringir o espaço de busca
  - Se não houvesse viés, não haveria generalização
    - Regras / equações seriam especializados para os exemplos específicos



# Algoritmos de AM

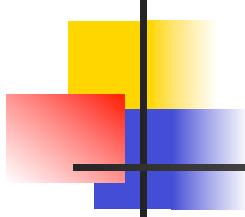
---

- Extraem conhecimento de um conjunto de dados
  - Novo, útil e relevante
  - Precisam ser tratados
    - Entra lixo, sai lixo
  - Precisam ser representativos
    - Cobrir situações que possam ocorrer
  - Podem ser estruturados ou não



# Conjuntos de dados

- Estruturados
  - Mais facilmente analisados por técnicas de AM
  - Ex.: Planilhas e tabelas atributo-valor
- Não estruturados
  - Mais facilmente analisados por seres humanos
    - Para AM, são geralmente convertidos em dados estruturados
  - Ex.: Sequência de DNA, textos, conteúdo de página na web, emails



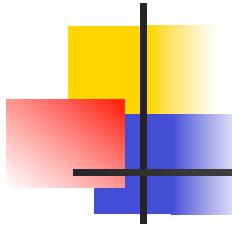
# Conjuntos de dados

Atributos de entrada (preditivos)

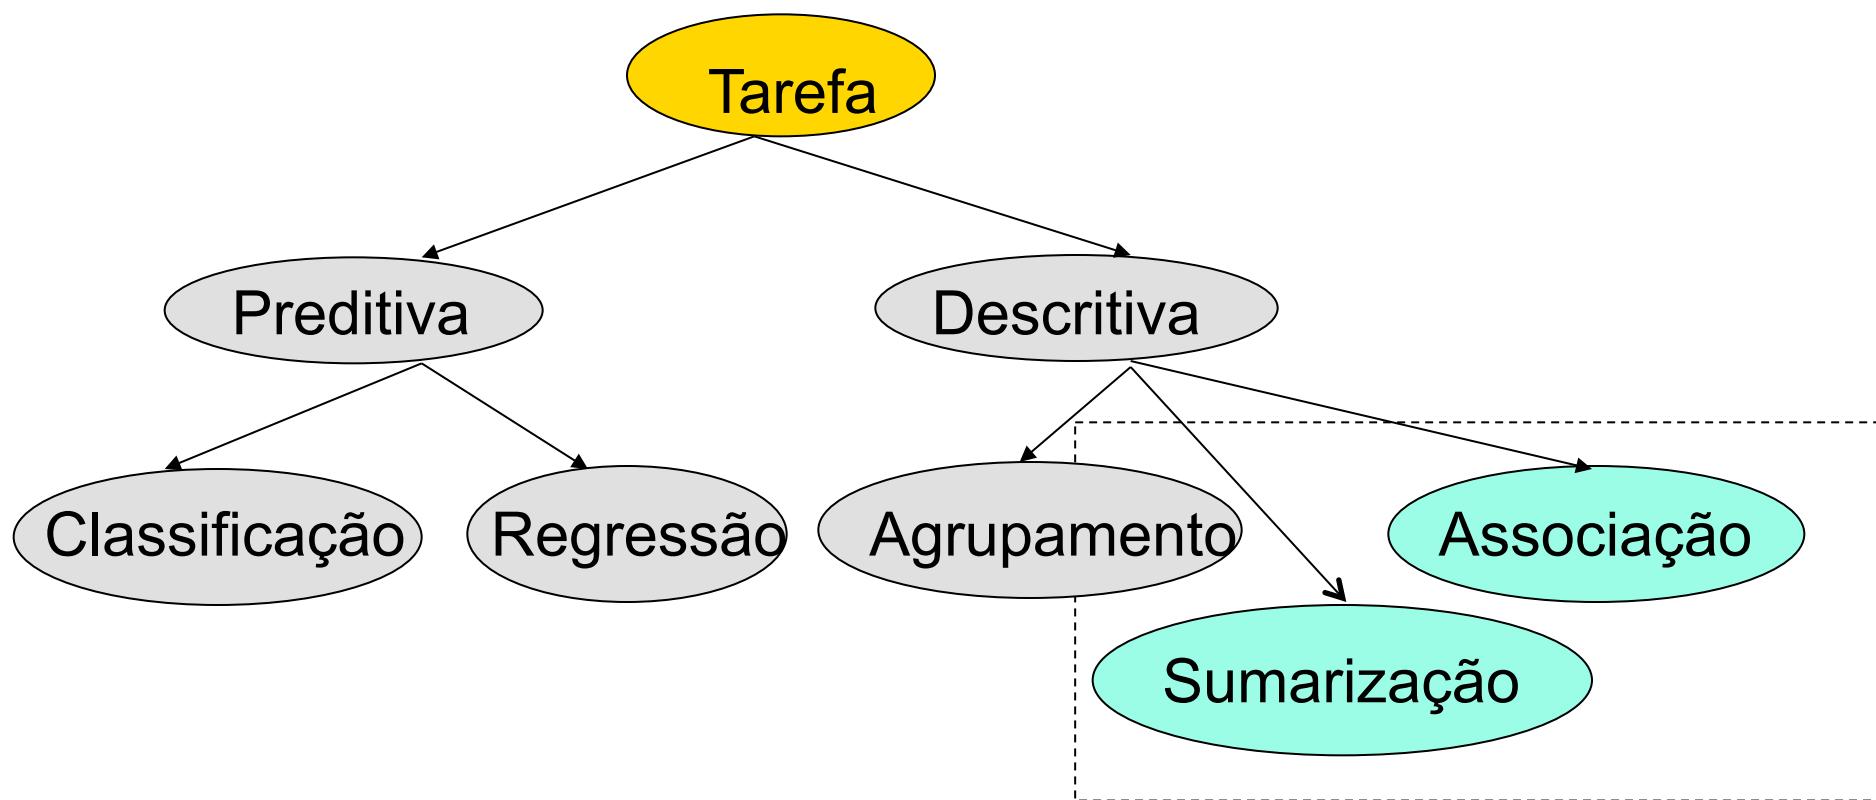
Exemplos  
(objetos,  
instâncias)

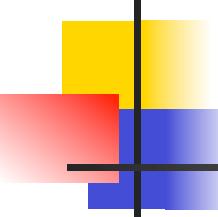
	Nome	Batim.	Temp.	Idade	Peso	Pressão	Diagn.
	João	70	37	70	94	12	Saudável
	Maria	38	39	30	40	14	Doente
	José	39	38.5	70	85	18	Doente
	Sílvia	38	37.5	15	60	13	Saudável
	Pedro	37	40	90	78	14	Doente

Atributo alvo



# Tarefas de aprendizado

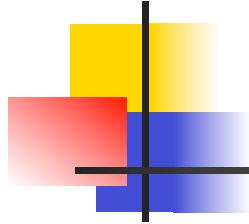




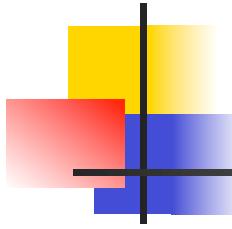
# Aprendizado pode ser

---

- Supervisionado
  - Tarefa preditiva (mais comum) ou descritiva
  - Ensina ao modelo o que ele deve fazer
    - Fornece, para cada entrada, a saída desejada (correta)
- Não supervisionado
  - Tarefa descritiva (mais comum) ou preditiva
  - Algoritmo aprende por si só
- Semi-supervisionado (aprendizado ativo)
- Reforço



# Tarefas Preditivas

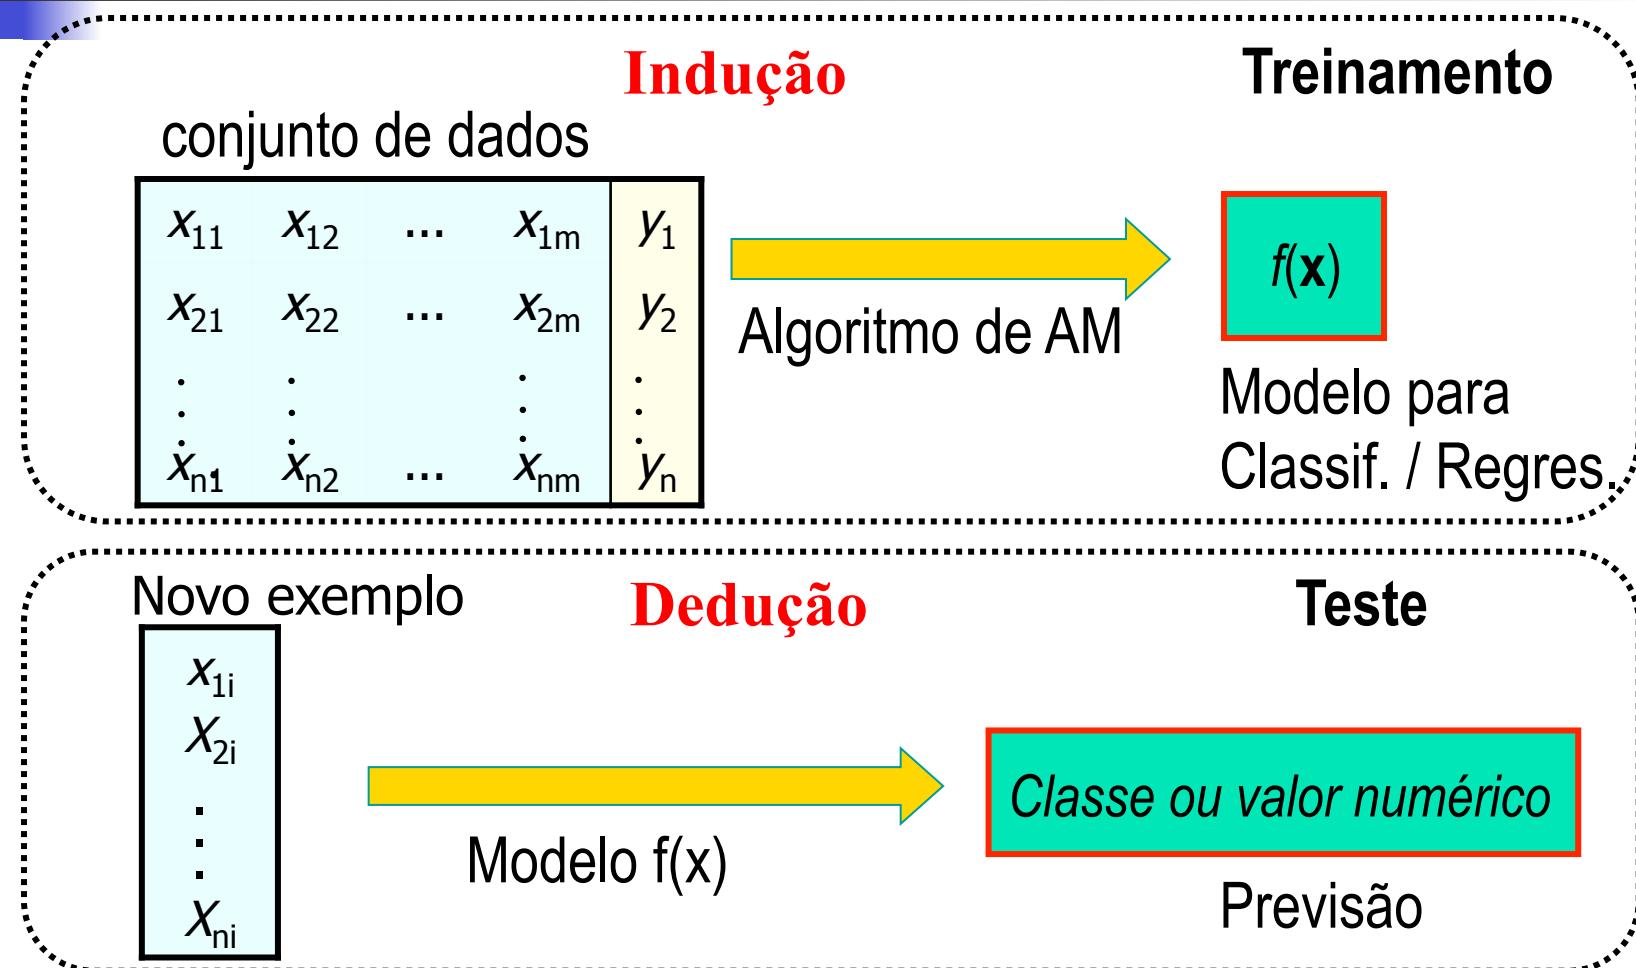


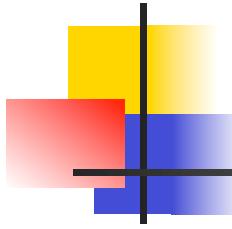
# Algoritmos de AM preditivos

---

- Induzem modelos (funções) preditivas
  - Dados de treinamento
- Modelo pode ser aplicado a novos dados
  - Dados de teste
  - Predição
- Classificação e regressão

# Algoritmos de AM preditivos

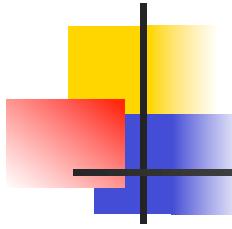




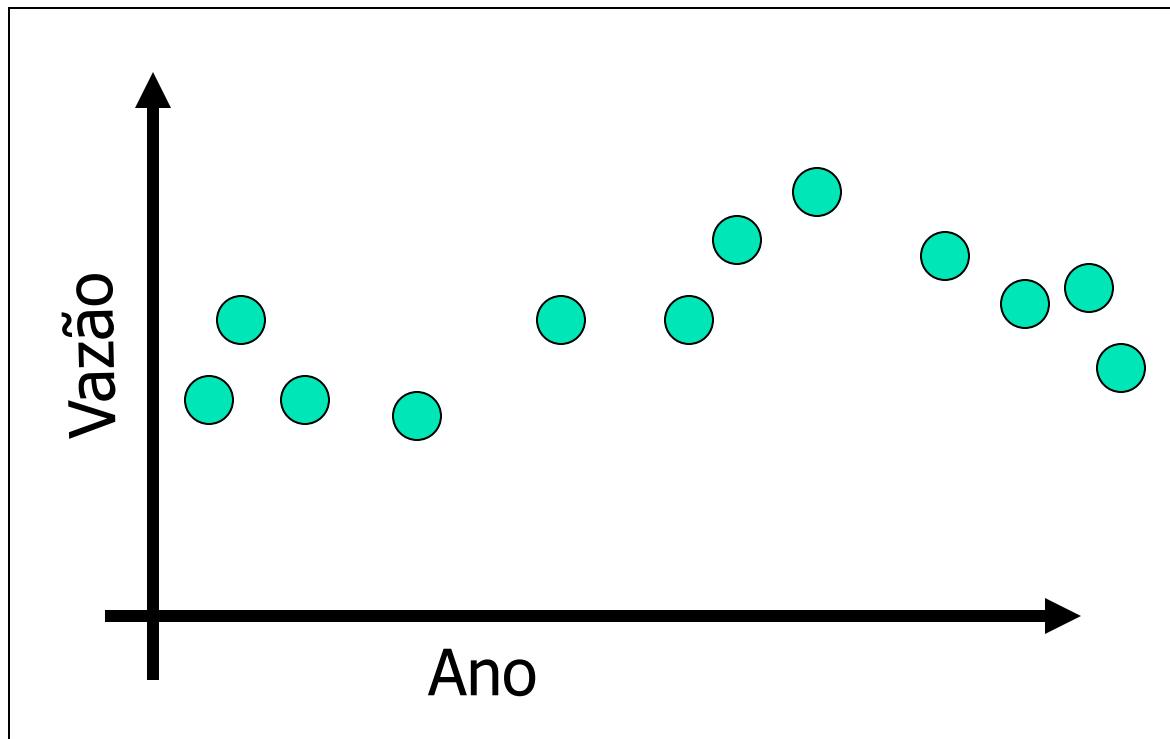
# Regressão

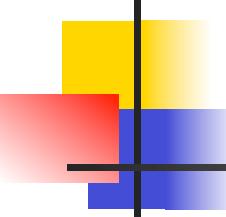
---

- Objetivo: aprender uma função que mapeia um exemplo em um valor real
  - Caso especial: análise de séries temporais
- Exemplos:
  - Prever valor de mercado de um imóvel
  - Prever o lucro de um empréstimo bancário
  - Prever tempo de internação de um paciente

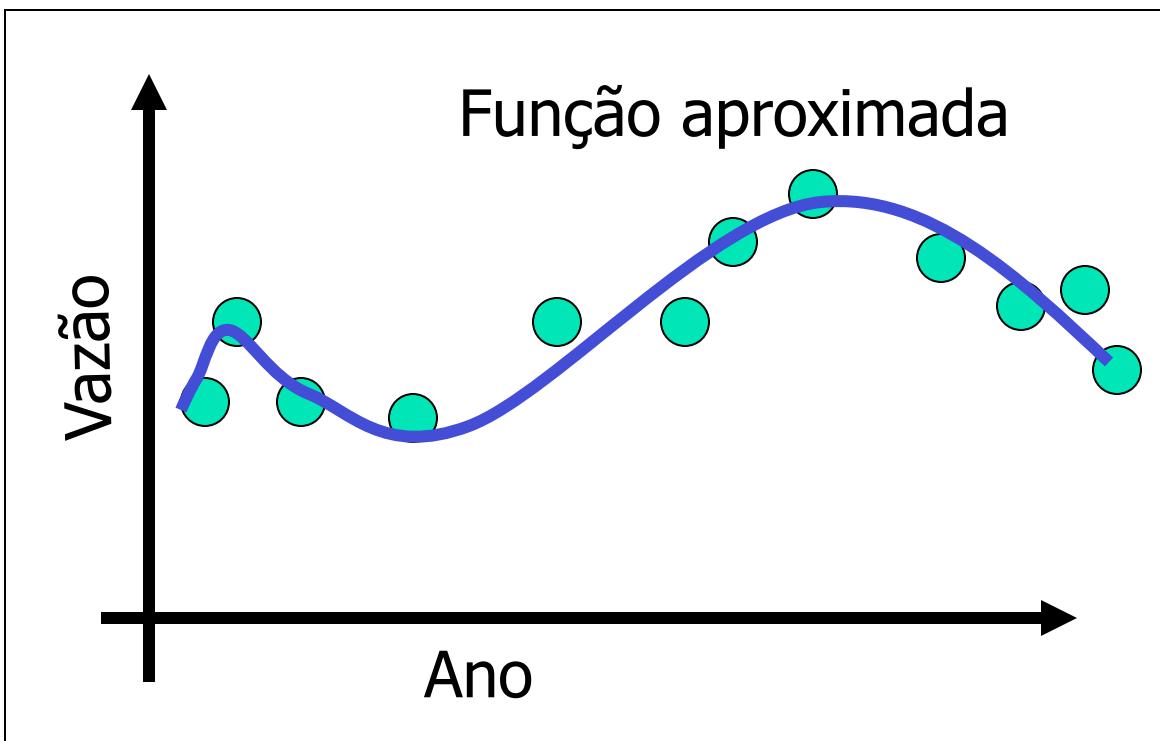


# Regressão





# Regressão

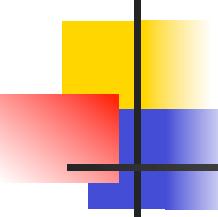




# Regressão

## ■ Técnicas

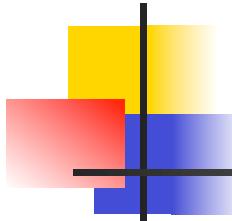
- Árvores de Regressão
- Redes Neurais Artificiais
- Máquinas de Vetores de Suporte
- Regressão Linear



# Classificação

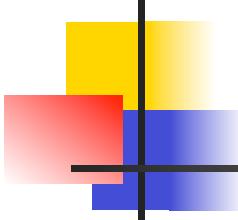
---

- Objetivo: aprender uma função que associa descrição de um exemplo a uma classe
- Exemplos:
  - Definir a função de uma proteína
  - Distinguir emails entre spam ou ham
  - Definir se um paciente tem ou não uma doença



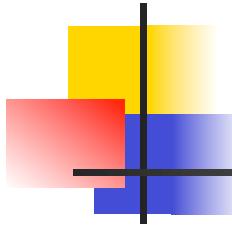
# Classificação

- Posto médico A
  - Tem um histórico de vários atendimentos e diagnósticos
  - João, ao sentir alguns sintomas, vai ao posto para uma consulta médica
  - O único médico, faltou
    - Mas uma enfermeira pode anotar os sintomas
  - É possível fazer um pré-diagnóstico?



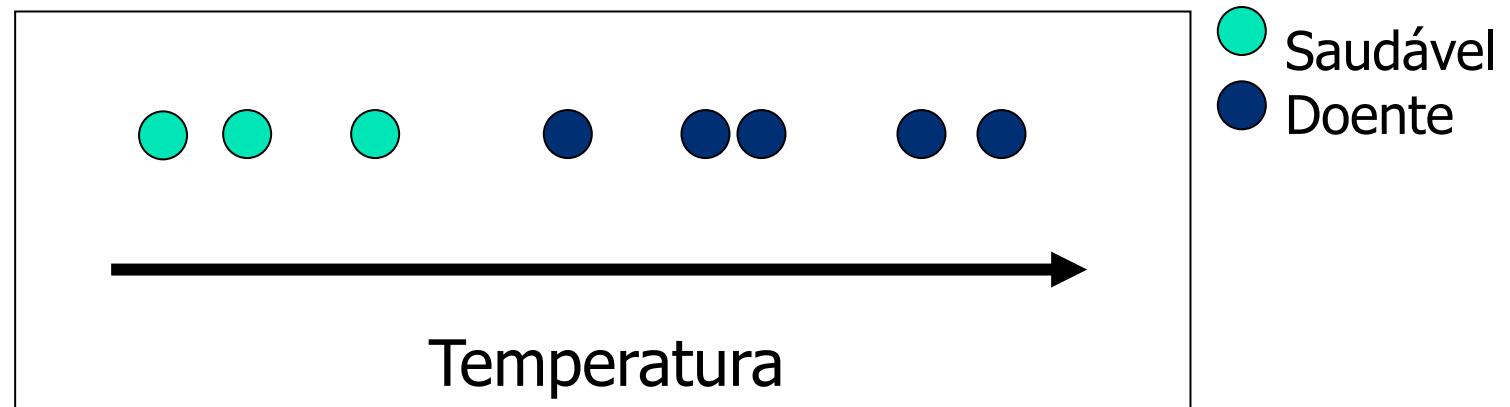
# Classificação

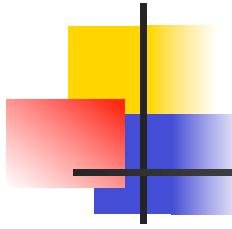
- Sintomas coletados pela enfermeira:
  - Temperatura



# Classificação

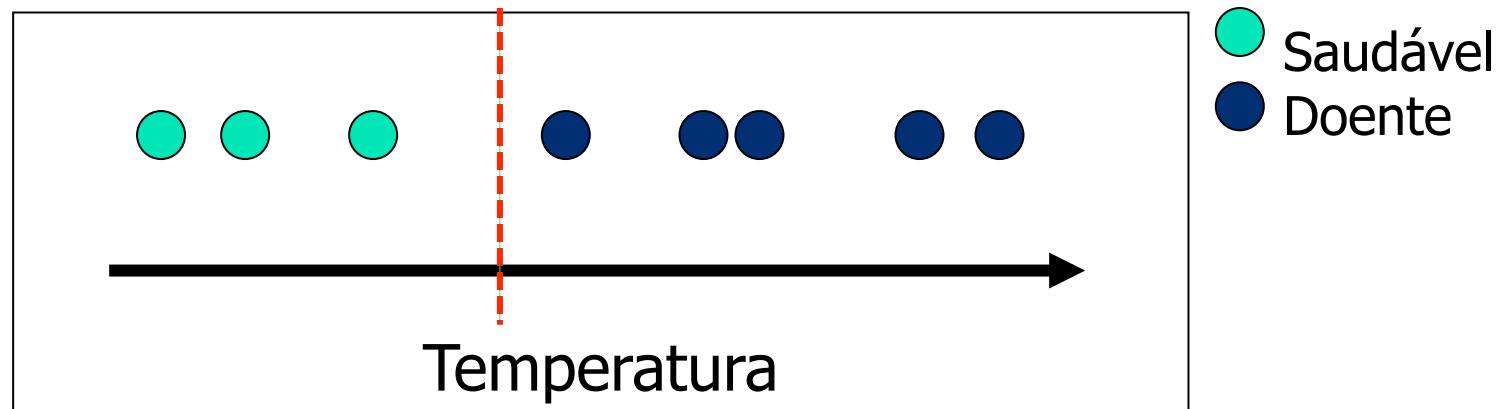
- Forma mais simples





# Classificação

- Forma mais simples

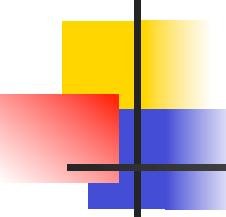


Função estimada: diagnóstico =  $f(\text{temperatura})$

Se temperatura >  $c$

Então doente

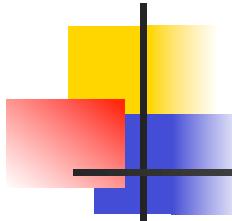
Senão saudável



# Classificação

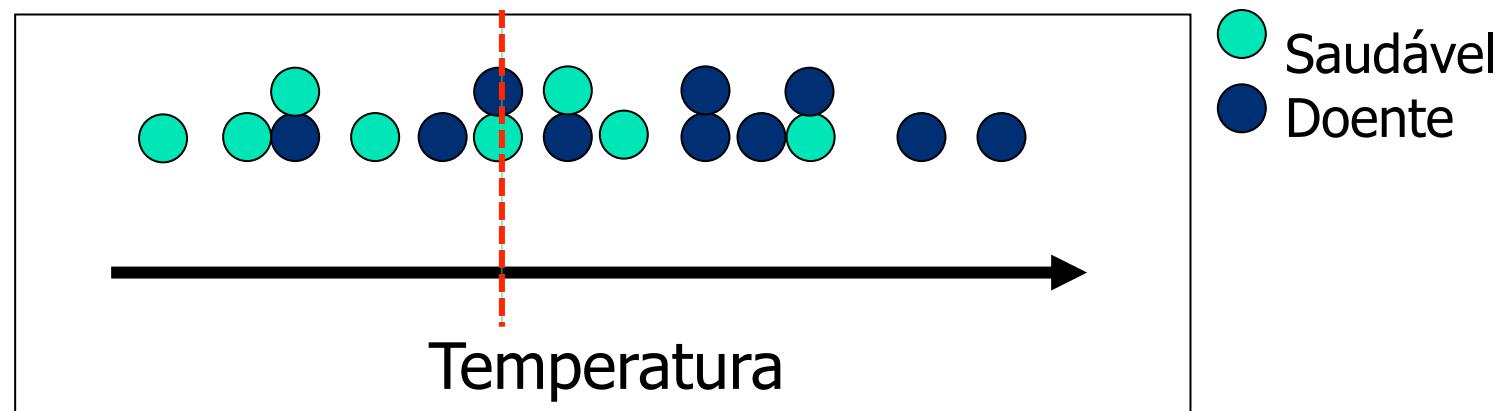
---

- Basta encontrar um valor de temperatura que separa
  - Doentes
  - Saudáveis
- Mas todo problema de classificação é simples assim?

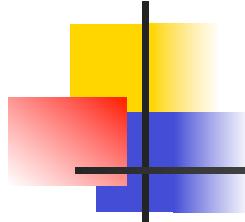


# Classificação

- Problema pode não ser tão simples



- Alternativa: considerar outros sintomas para o diagnóstico

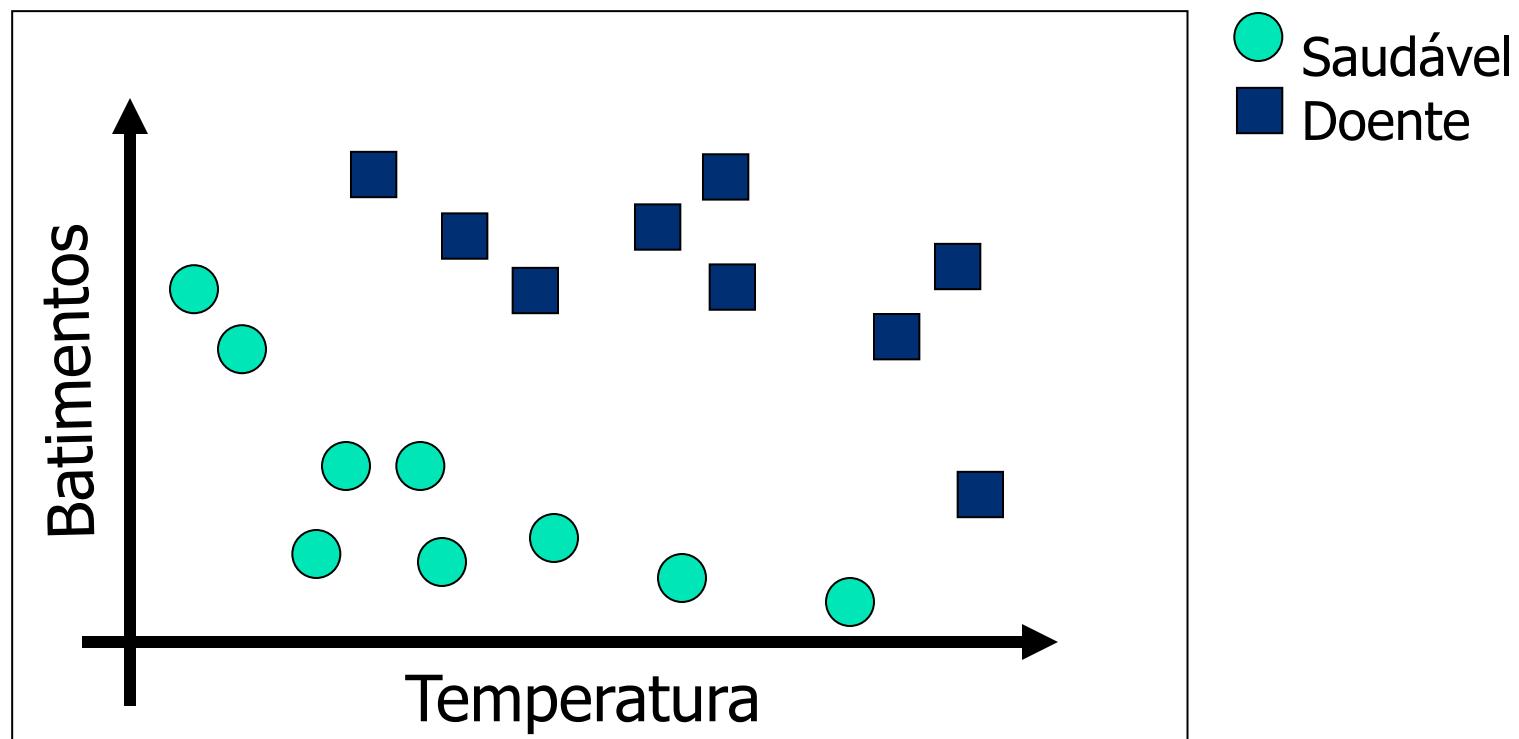


# Classificação

- Sintomas coletados pela enfermeira:
  - Batimentos cardíacos
  - Temperatura

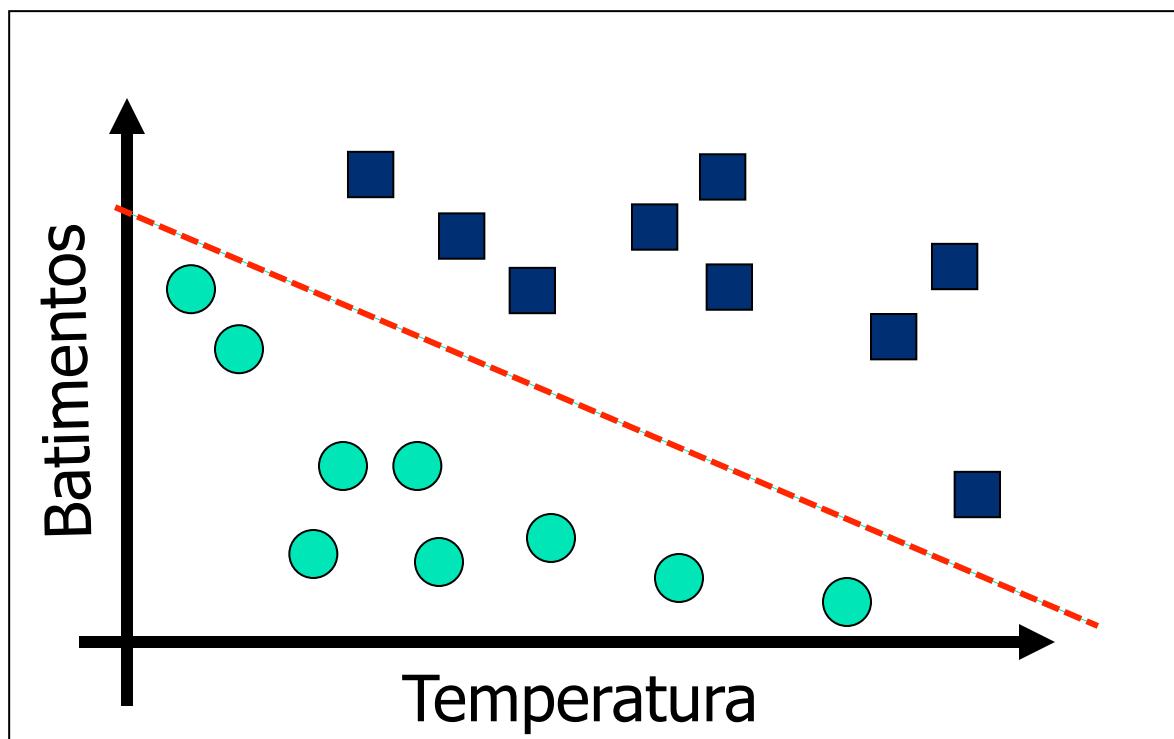
# Classificação

- Incluir número de batimentos

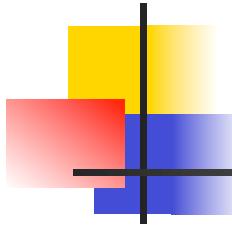


# Classificação

- Função linear permite diagnóstico



Saudável  
Doente  
Nova função:  
Se  $a \cdot t + b > 0$   
Então doente  
Senão saudável



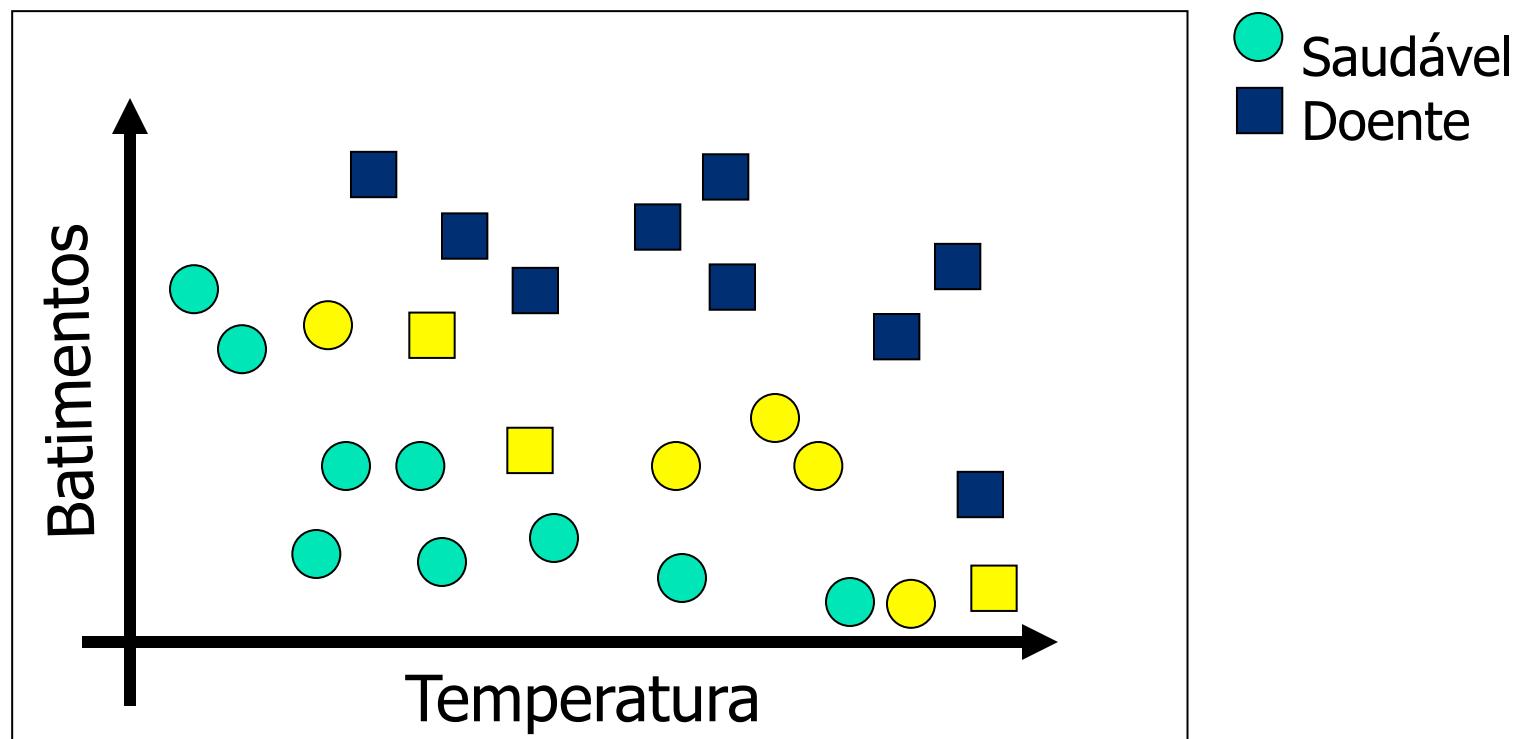
# Classificação

---

- Basta encontrar uma função linear que separa doentes de saudáveis
  - Inclinação da reta e ponto onde cruza o eixo da ordenada
- Espaço de pacientes
  - Ordenada: número de batimentos
  - Abscissa: temperatura
- Mas toda tarefa de classificação é simples assim?

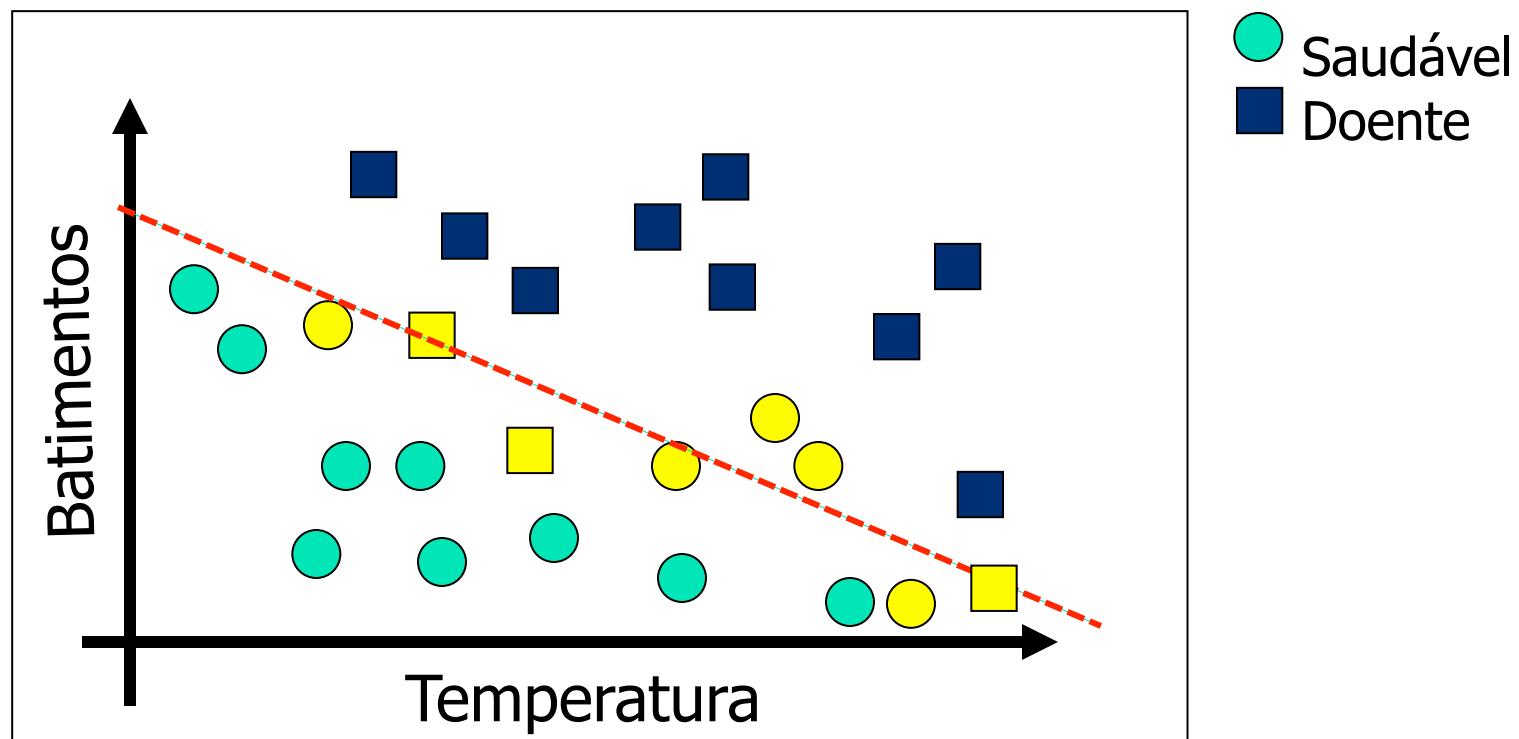
# Classificação

- Supor inclusão de outros pacientes



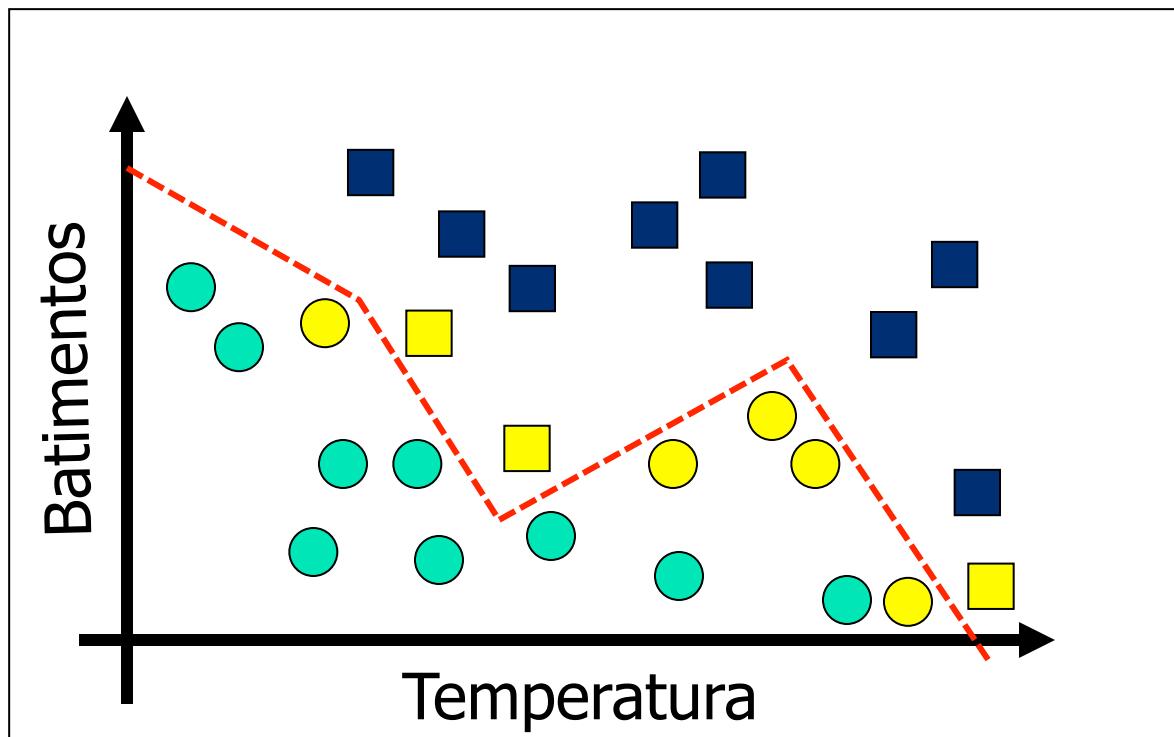
# Classificação

- Supor inclusão de outros pacientes



# Classificação

- ## ■ Supor inclusão de outros pacientes

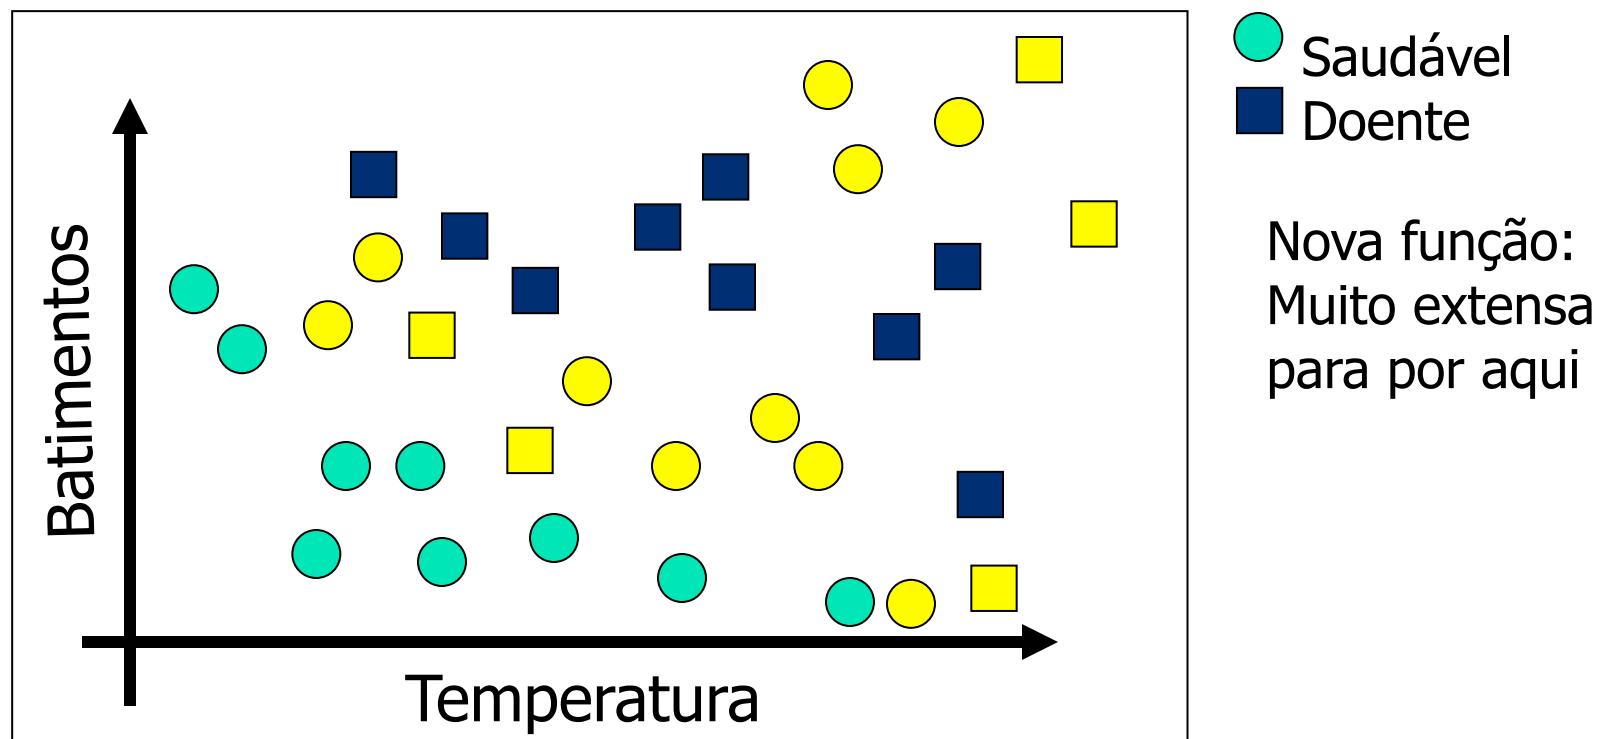


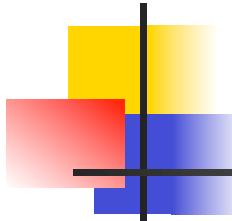
# Saudável Doente

Nova função:  
Muito complexa  
Para por aqui

# Classificação

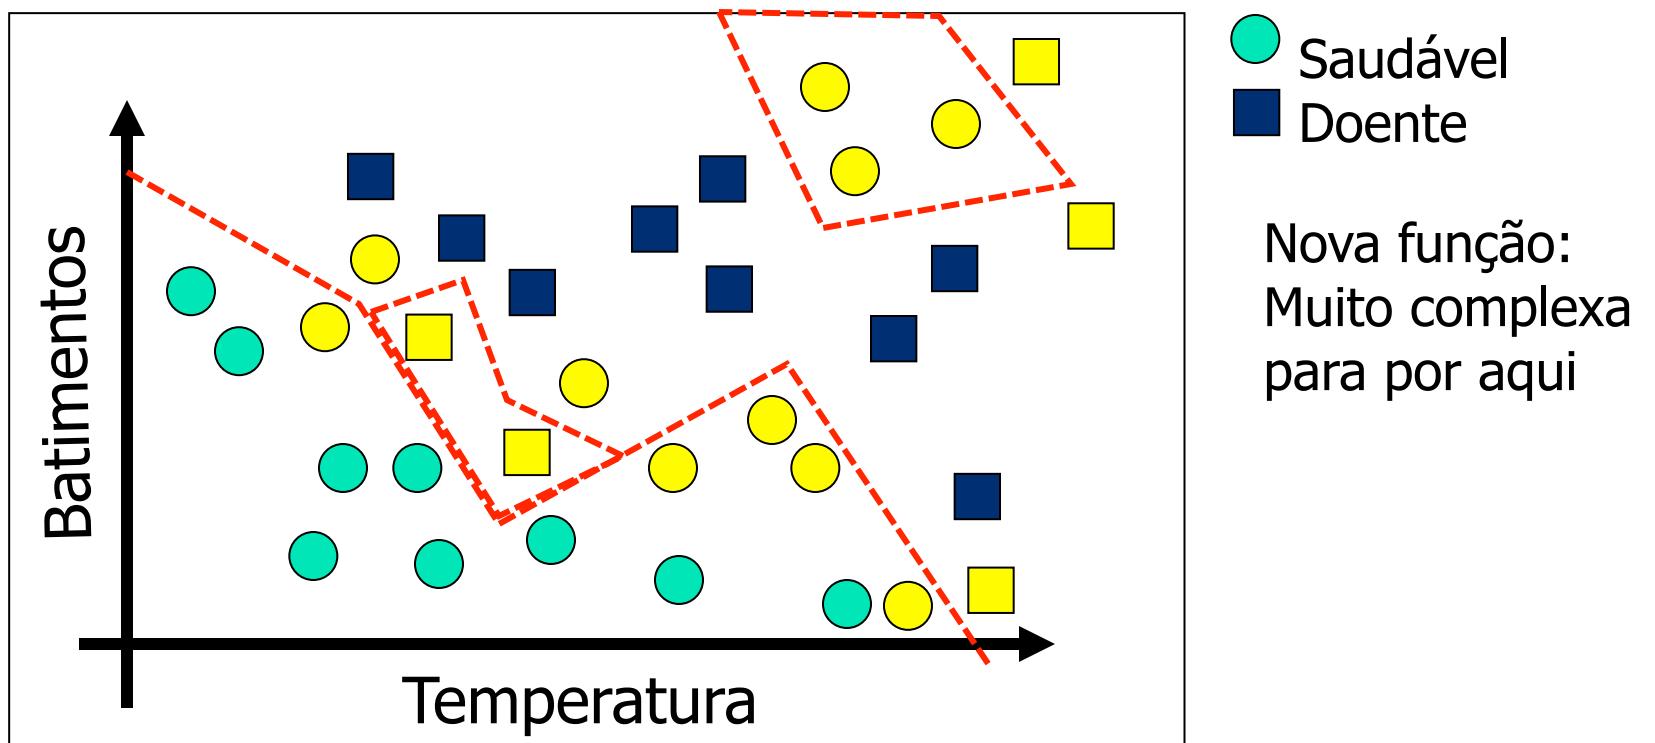
- Supor inclusão de mais pacientes

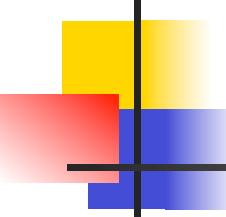




# Classificação

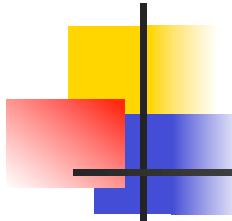
- Supor inclusão de outros pacientes





# Classificação

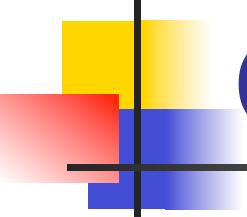
- Função para definir fronteira de decisão se torna mais complexa
  - Difícil de obter por técnicas tradicionais
- Algoritmos de AM utilizam heurísticas para procurar essas funções
- Conjunto de atributos utilizados podem não representar bem a tarefa
  - Dificultando a indução de bons modelos



# Classificação

---

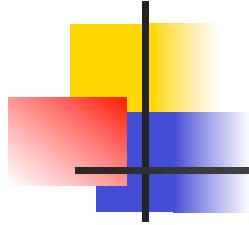
- Sintomas que poderiam permitir um melhor modelo para diagnóstico:
  - Batimentos cardíacos
  - Idade
  - Peso
  - Pressão
  - Temperatura
  - Taxas em uma amostra de sangue



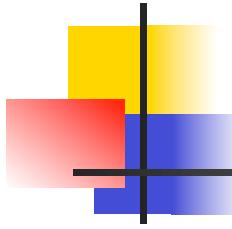
# Classificação

---

- Atributos preditivos procuram descrever a tarefa a ser resolvida
  - Em geral, quanto mais atributos são extraídos, melhor
    - Facilitam indução de bons modelos
  - No entanto
    - Dificultam visualizar distribuição dos dados
    - Podem incluir atributos irrelevantes, redundantes. ...
    - Maldição da dimensionalidade



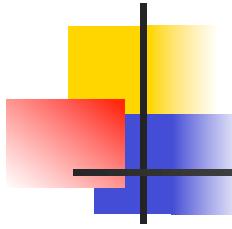
# Algoritmos de Classificação



# Algoritmos de classificação

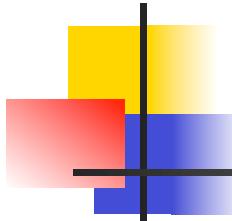
---

- Indução de Árvores de Decisão
- Indução de conjuntos de regras
- Redes Neurais
- Máquinas de Vetores de Suporte
- K-NN
- Regressão Logística
- Redes Bayesianas



# Algoritmos de classificação

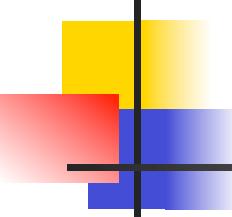
- Podem ser agrupados por diferentes critérios
  - Baseados em distâncias
    - K-NN
  - Baseados em otimização
    - RNs
  - Baseados em probabilidade
    - NB
  - Baseados em procura (lógicos)
    - Indução de ADs



# Algoritmos de classificação

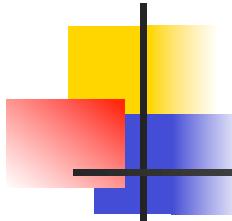
- Podem ser agrupados por diferentes critérios
  - Baseados em distâncias
    - K-NN
  - Baseados em otimização
    - RNs
  - Baseados em probabilidade
    - NB
  - Baseados em procura (lógicos)
    - Indução de ADs

} Geométricos



# Algoritmos baseados em distância

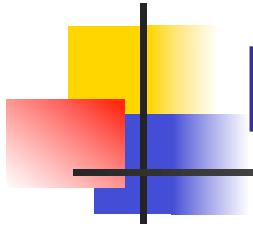
- Usam medidas de distância para classificar novos exemplos
  - Medem (dis)similaridade entre dados
  - Diversas medidas podem ser usadas
- Vários algoritmos são baseados em distância
  - Algoritmo k-NN



# Algoritmo K-NN

---

- Algoritmo *lazy* (preguiçoso)
  - Consulta os dados de treinamento apenas quando vai classificar um novo objeto
- Não constrói um modelo explicitamente
- Diferente de algoritmos *eager*
  - Induzem um modelo
    - Ex.: ADs, RNs e SVMs



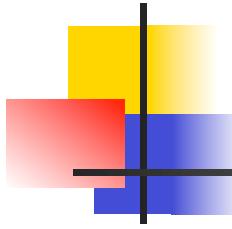
# K-Vizinhos mais próximos

Seja  $k$  o número de vizinhos mais próximos  
Para cada novo exemplo  $x$

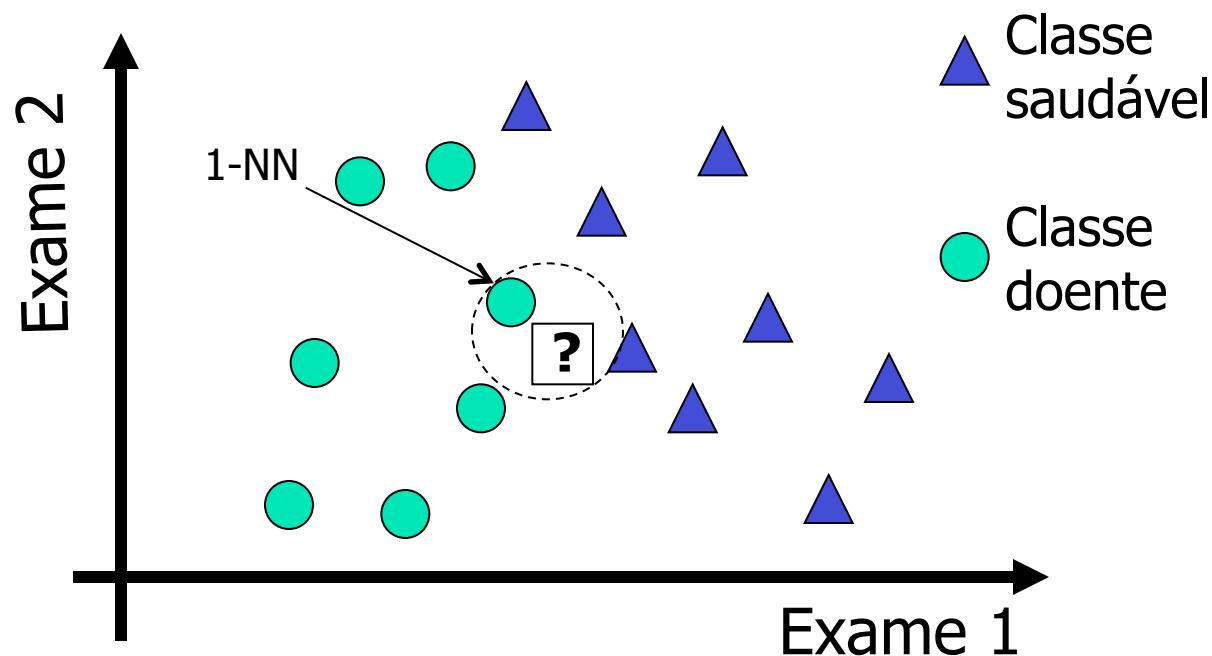
Definir a classe dos  $k$  exemplos

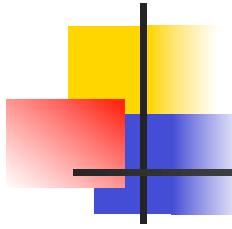
(vizinhos) mais próximos

Classificar  $x$  na classe majoritária  
entre seus  $k$  vizinhos

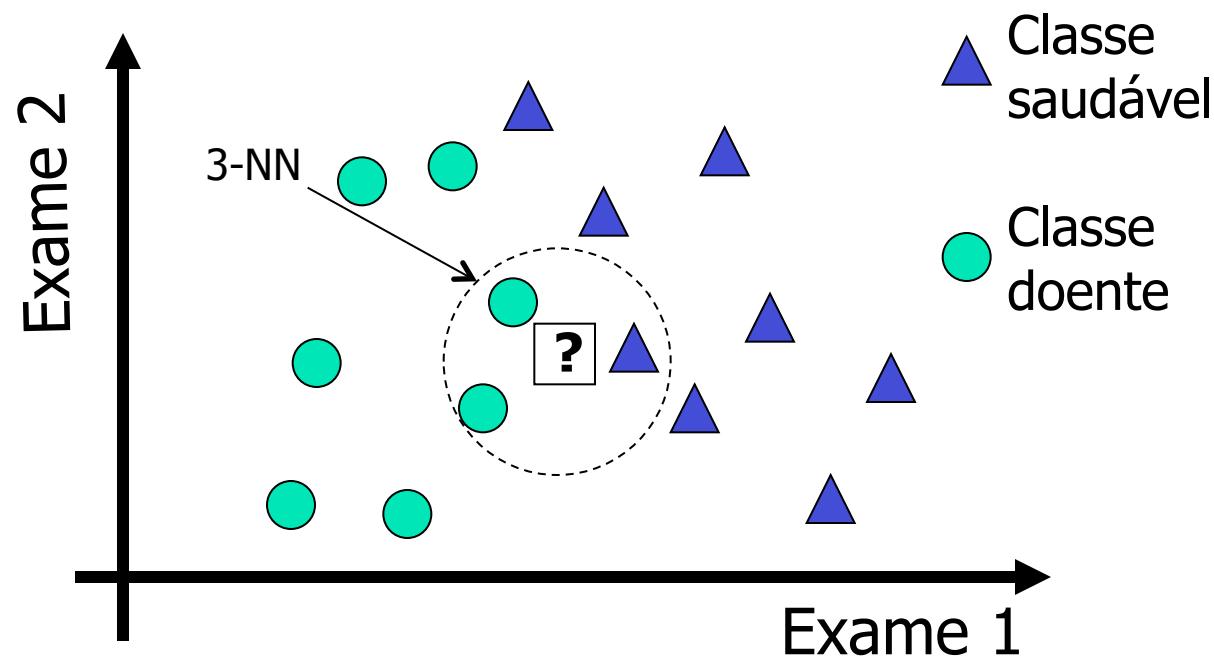


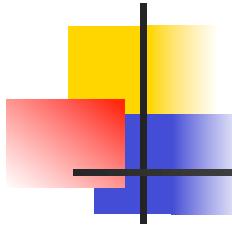
# 1-vizinho mais próximo



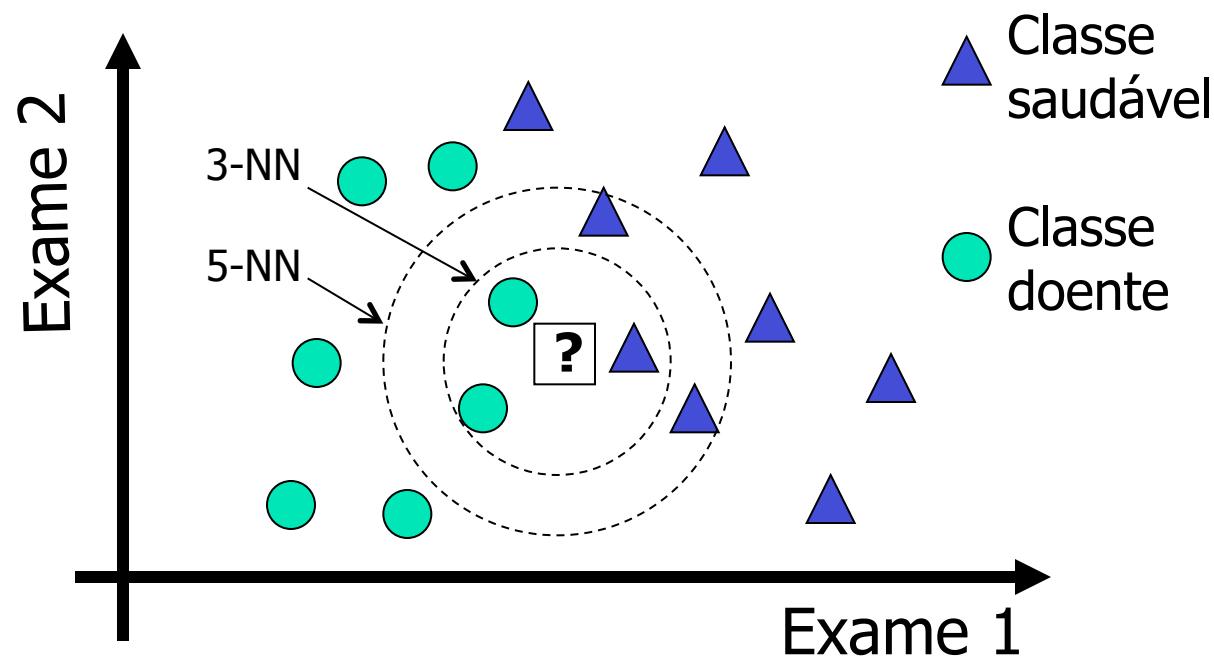


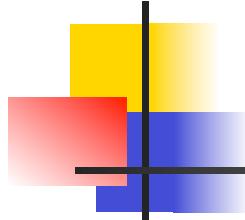
# Quantos vizinhos?





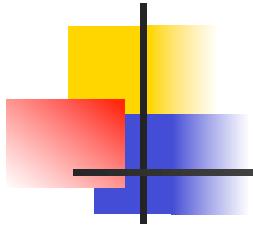
# Quantos vizinhos?





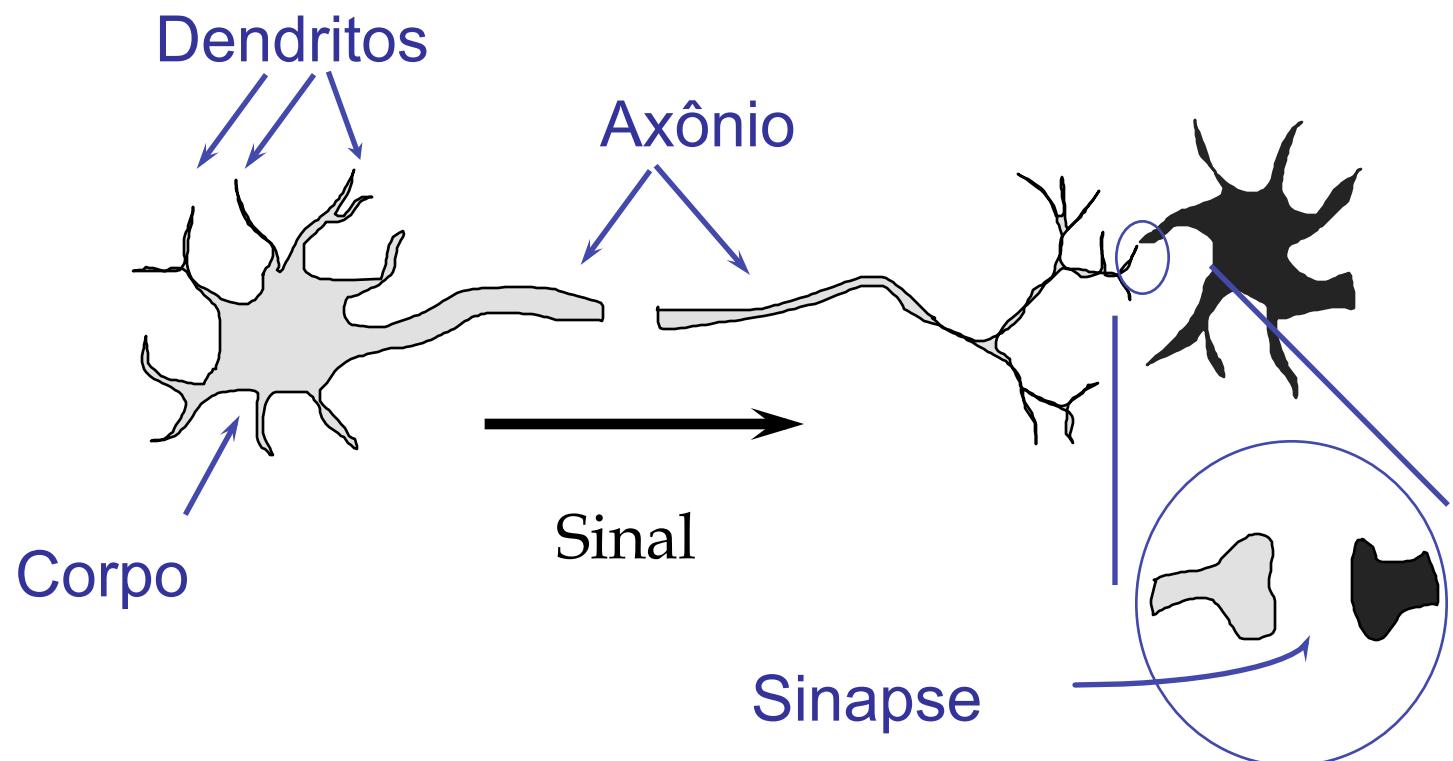
# Redes Neurais Artificiais

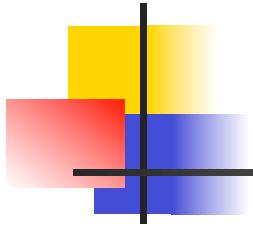
- Sistemas distribuídos inspirados no cérebro humano
  - Compostas por várias unidades de processamento (“neurônios”)
  - Interligadas por um grande número de conexões (“sinapses”)
- Arquitetura e aprendizado



# Neurônio natural

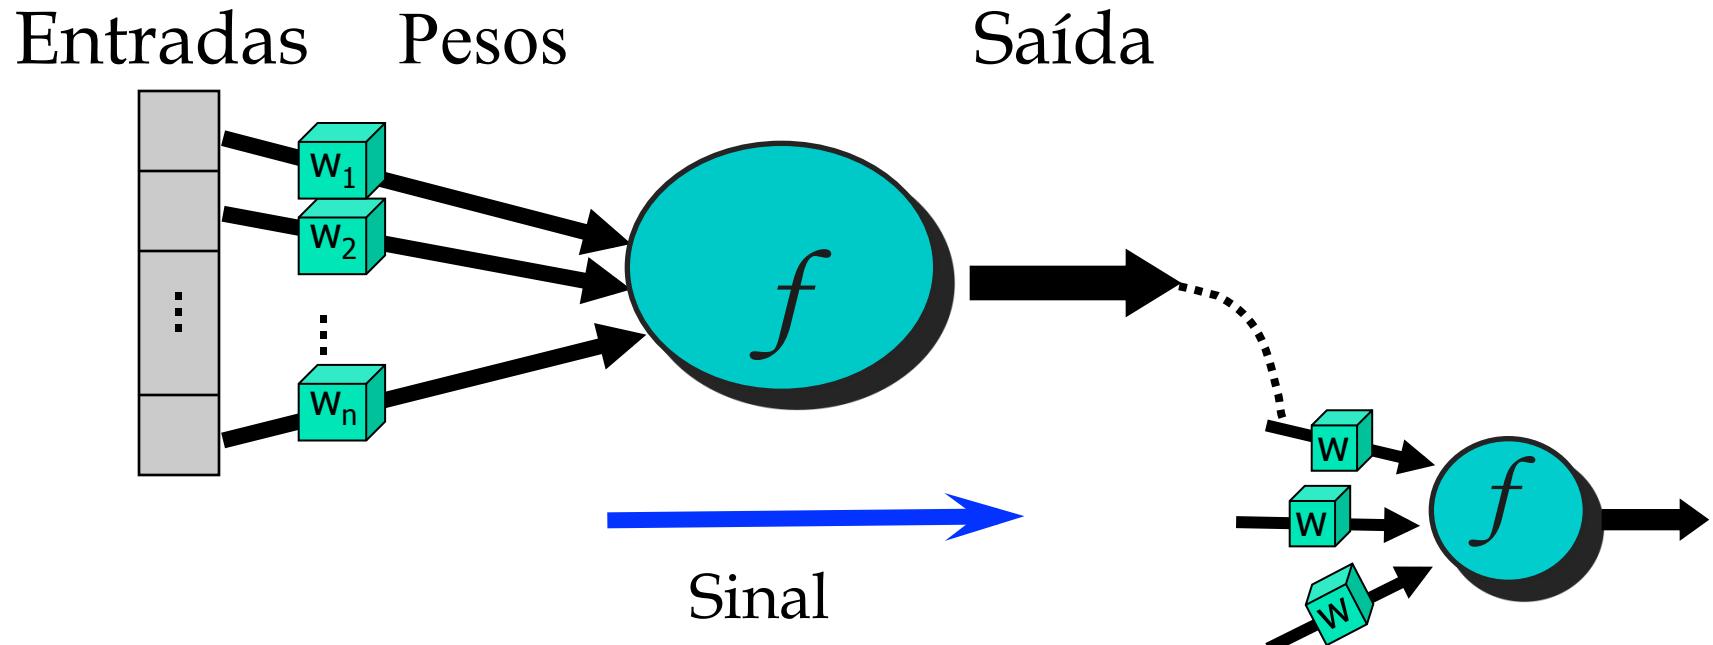
- Um neurônio simplificado:

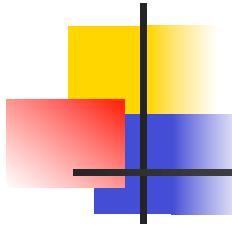




# Neurônio artificial

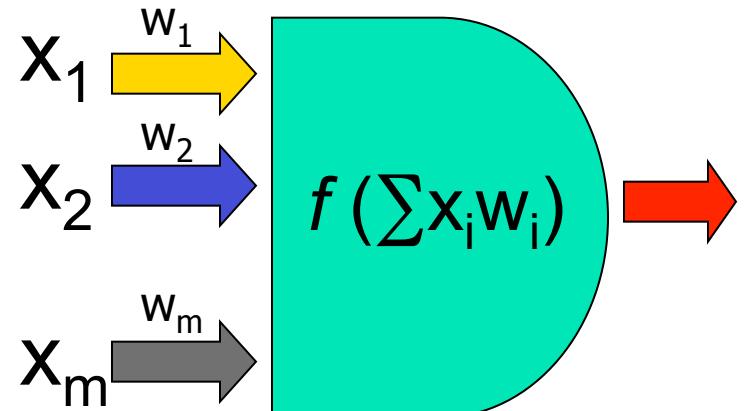
- Modelo de um neurônio abstrato:

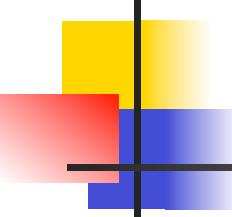




# Perceptron

- Primeira rede - Rosemblat, 1958
  - Modelo de neurônio de McCulloch-Pitts
- Treinamento
  - Supervisionado
  - Correção de erro
    - $w_i(t) = w_i(t-1) + \Delta w_i$
    - $\Delta w_i = \eta x_i \delta$
    - $\Delta w_i = \eta x_i (y - f(x))$
- Teorema de convergência





# Algoritmo de treinamento

1 Iniciar todas as conexões com  $w_i = 0$

2 Repita

    Para cada par de treinamento  $(X, y)$

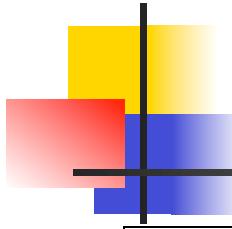
        Calcular a saída  $f(X)$

        Se  $(y \neq f(X))$

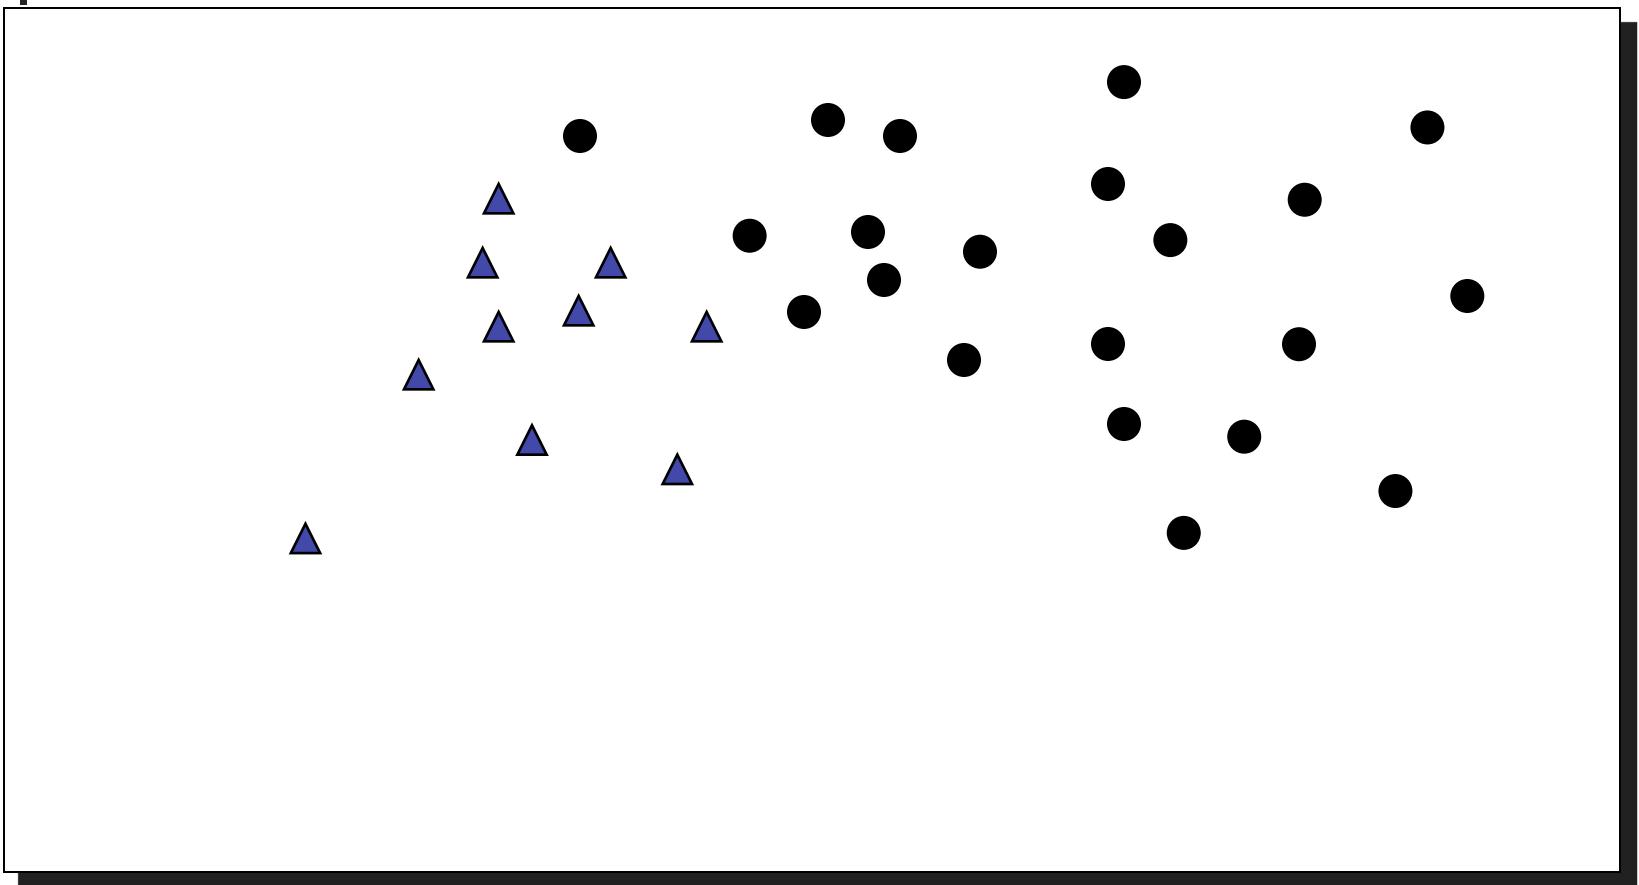
            Então

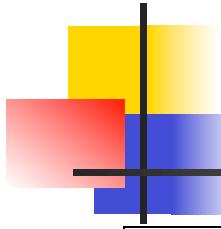
                Atualizar pesos do neurônio

    Até valor erro aceitável

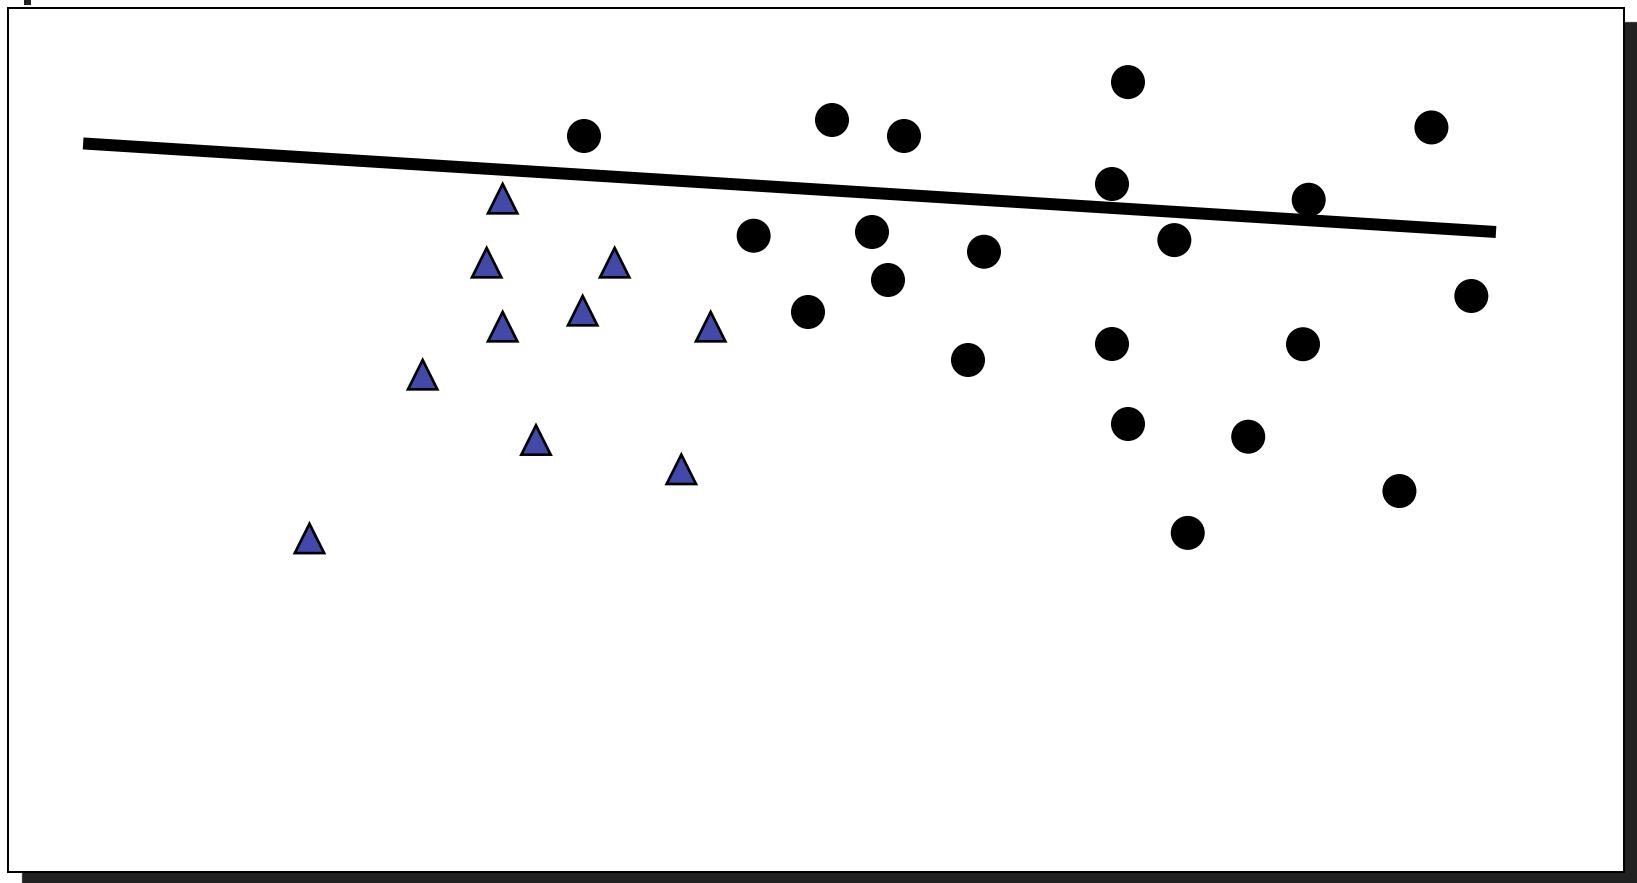


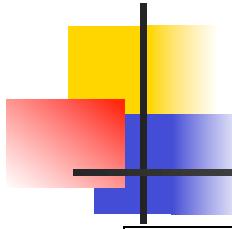
# Treinamento modificando fronteiras



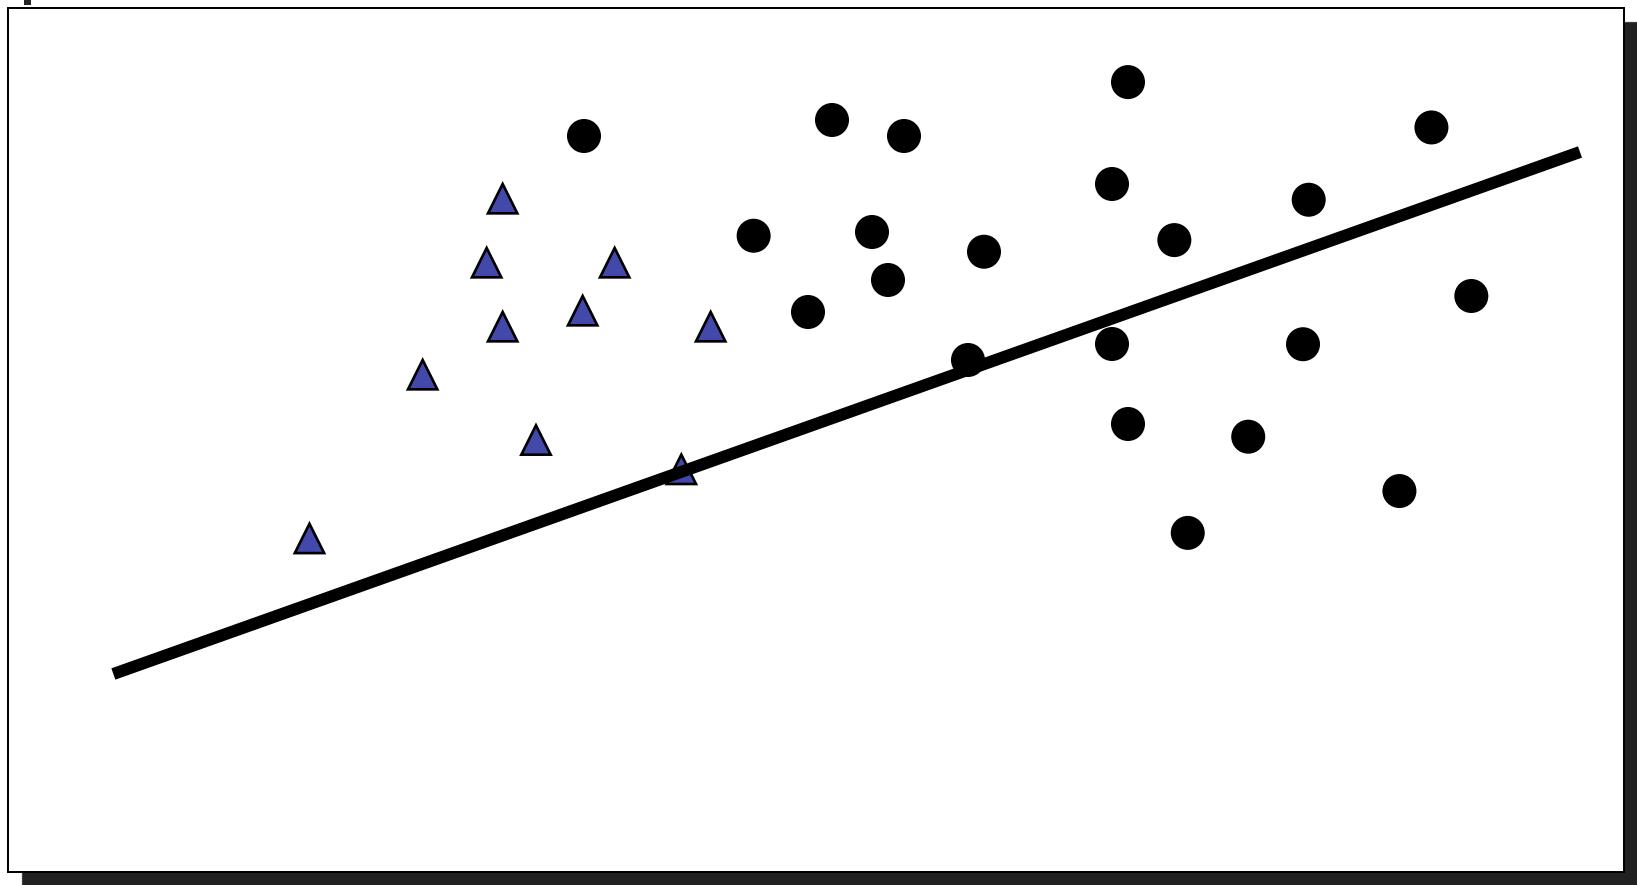


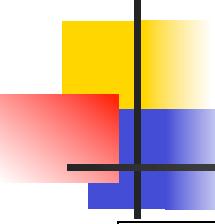
# Treinamento modificando fronteiras



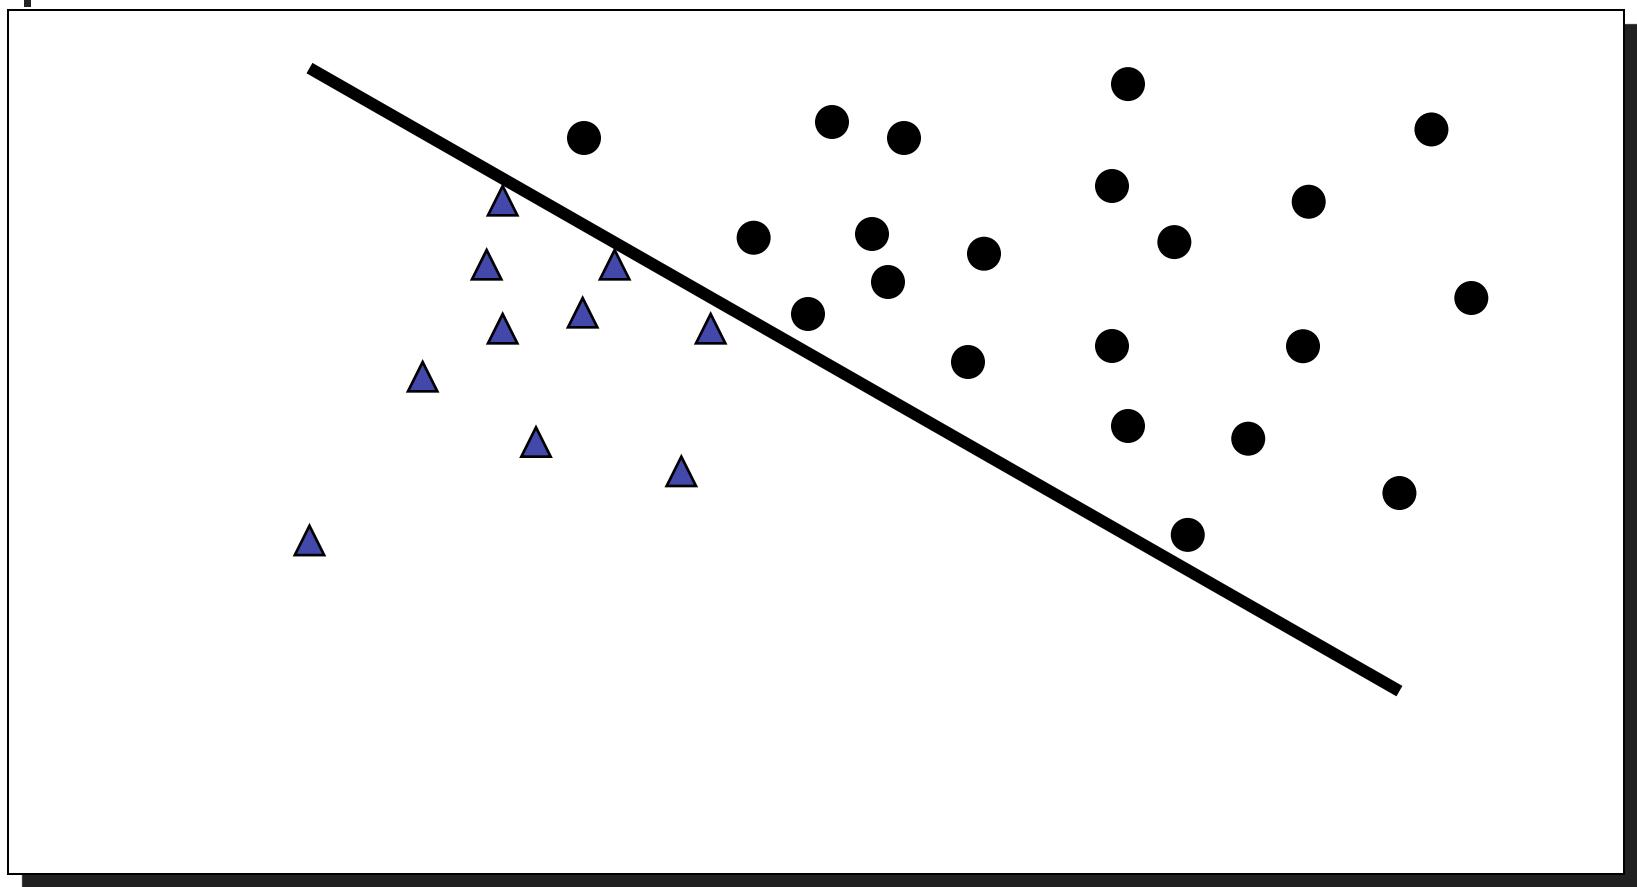


# Treinamento modificando fronteiras



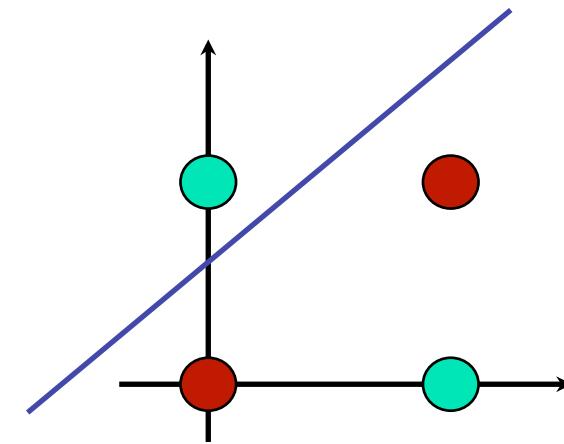
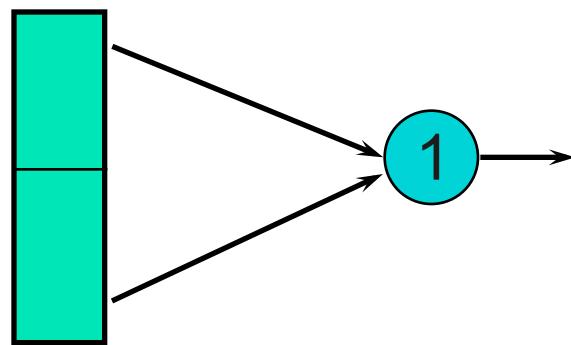


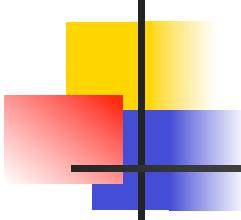
# Treinamento modificando fronteiras



# Problemas com Perceptron

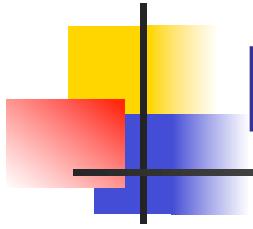
$0, 0 \rightarrow 0$
$0, 1 \rightarrow 1$
$1, 0 \rightarrow 1$
$1, 1 \rightarrow 0$



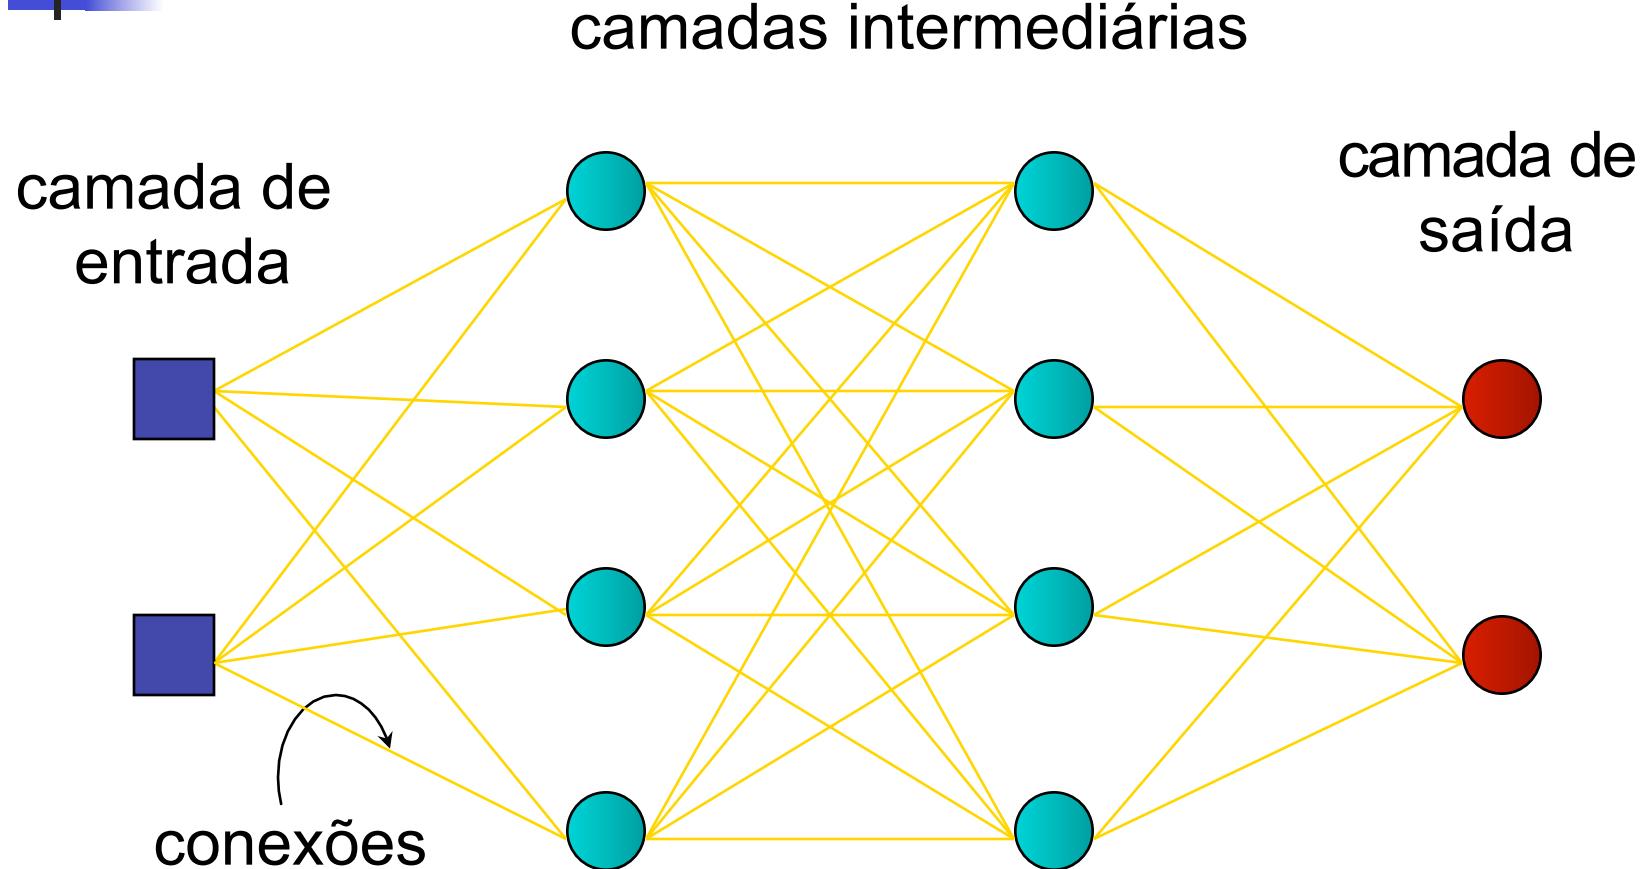


# Rede Multi-Layer Perceptron

- Arquitetura de RNA mais utilizada
  - Uma ou mais camadas intermediárias de neurônios
- Funcionalidade (teórica)
  - Uma camada intermediária: qualquer função contínua ou Booleana
  - Duas camadas intermediárias: qualquer função
- Originalmente treinada com o algoritmo  
*Backpropagation*

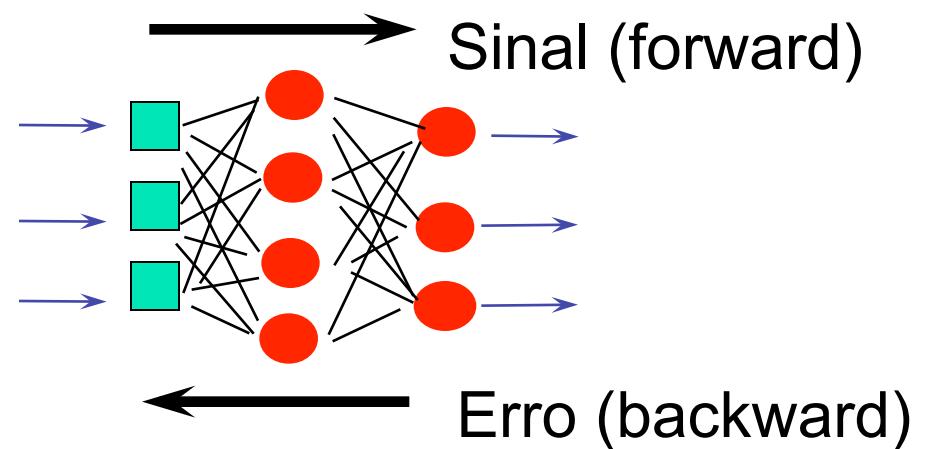


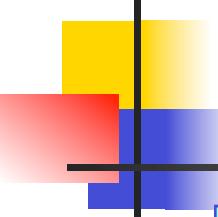
# MLP e Backpropagation



# Backpropagation

- Treina a rede com pares entrada-saída
  - Cada vetor de entrada é associado a uma saída desejada
- Treinamento em duas fases, cada uma percorrendo a rede em um sentido
  - Fase forward
  - Fase backward





# Treinamento

*Iniciar todas as conexões com valores aleatórios  $\in [a,b]$*

*Repita*

*erro = 0;*

*Para cada par de treinamento ( $X, y$ )*

*Para cada camada  $k := 1$  a  $N$*

*Para cada neurônio  $j := 1$  a  $M_k$*

*Calcular a saída  $f_{kj}(\text{net})$*

*Se  $k = N$*

*Calcular soma dos erros de seus neurônios;*

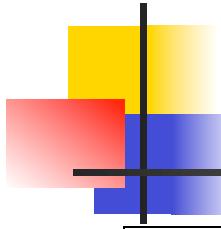
*Se  $\text{erro} > \varepsilon$*

*Para cada camada  $k := N$  a 1*

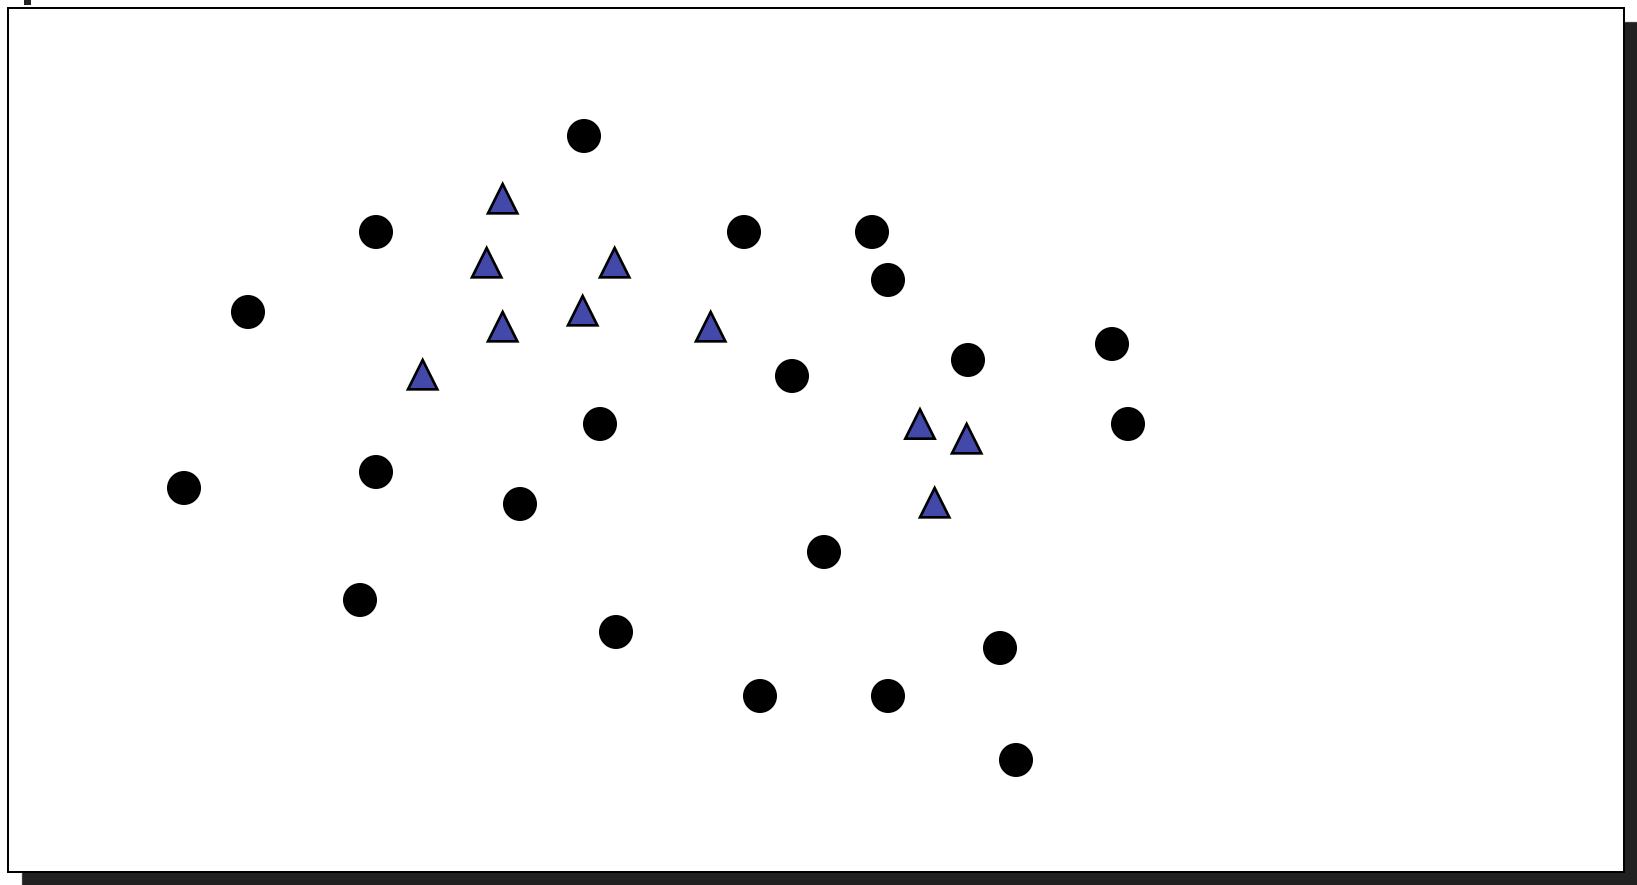
*Para cada neurônio  $j := 1$  a  $M_k$*

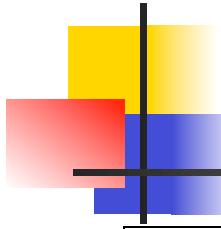
*Atualizar pesos;*

*Até  $\text{erro} < \varepsilon$  (ou número máximo de ciclos)*

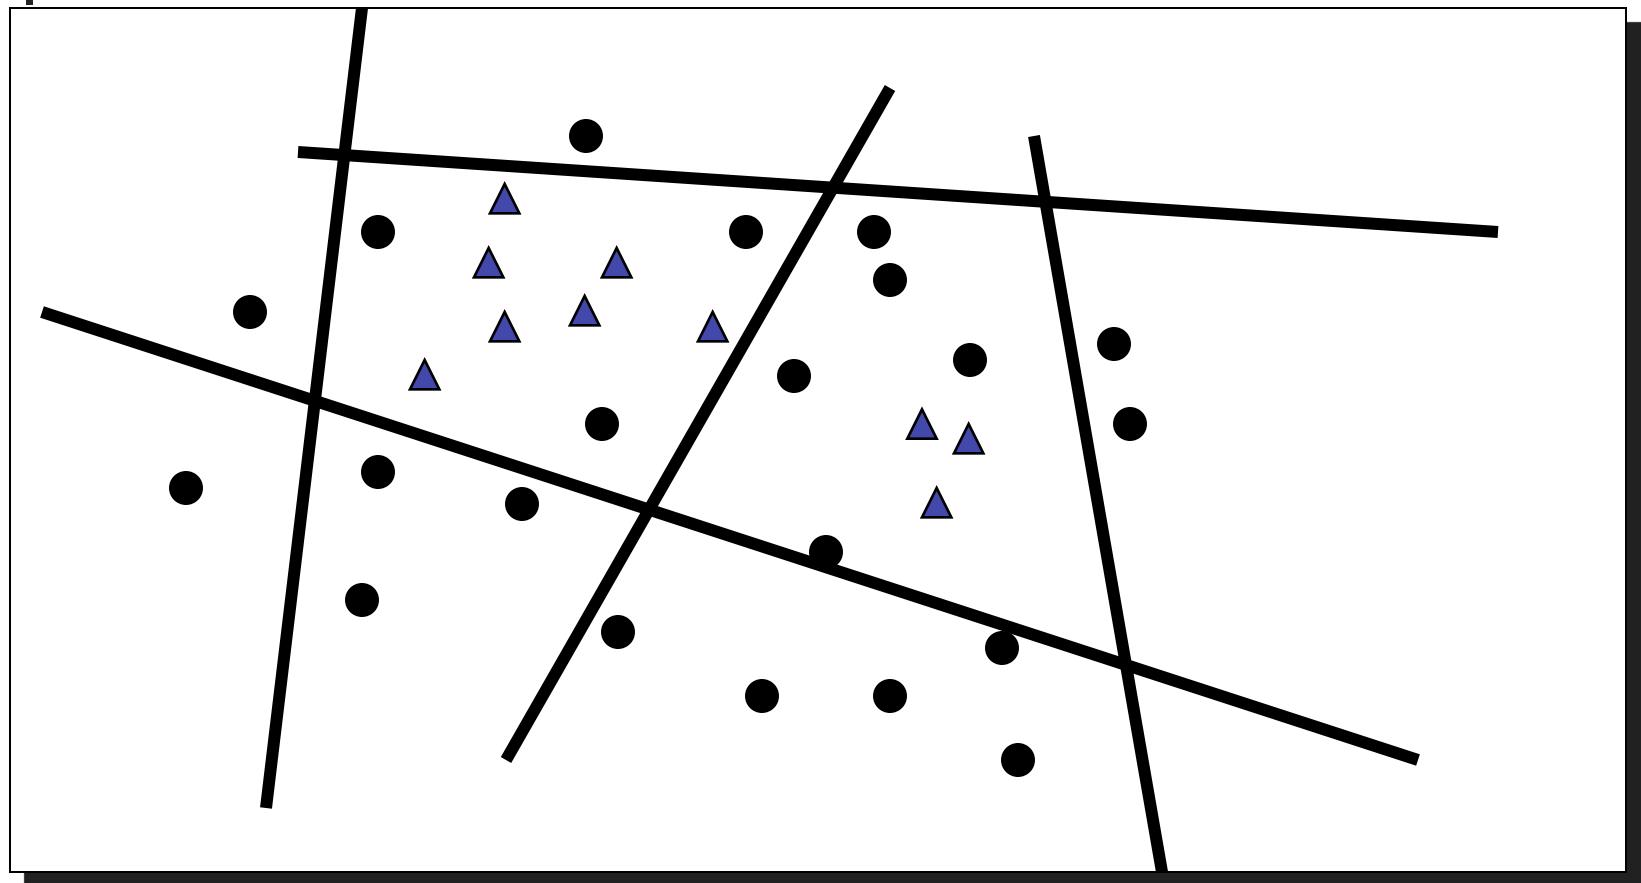


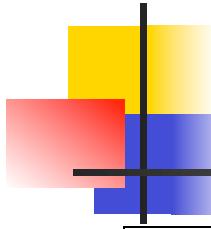
# Treinamento modificando fronteiras



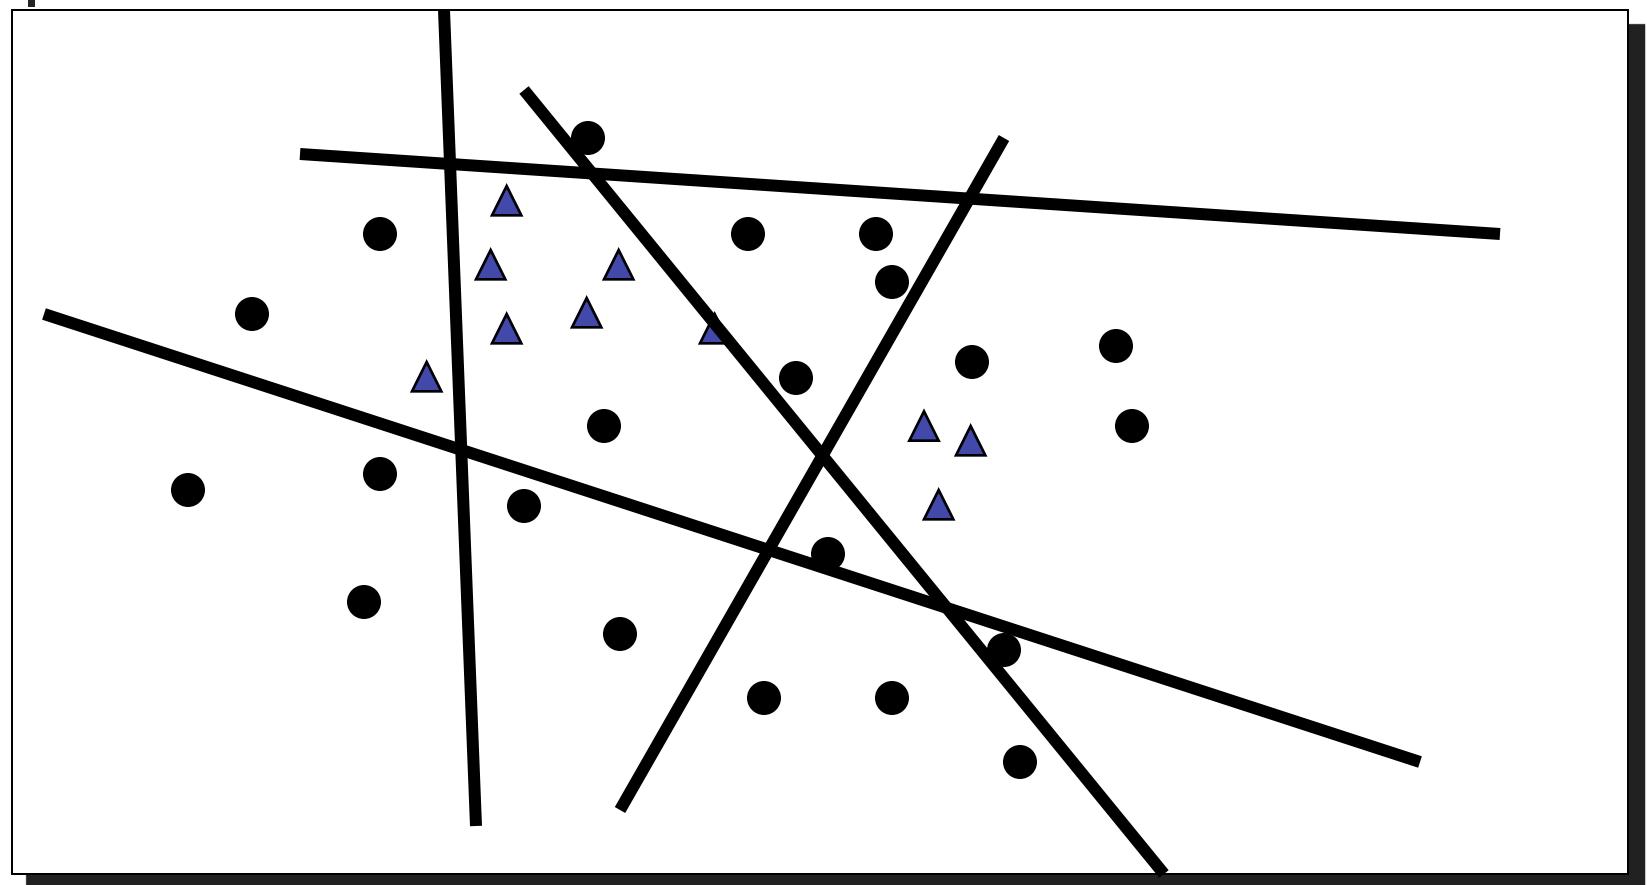


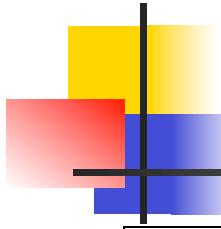
# Treinamento modificando fronteiras



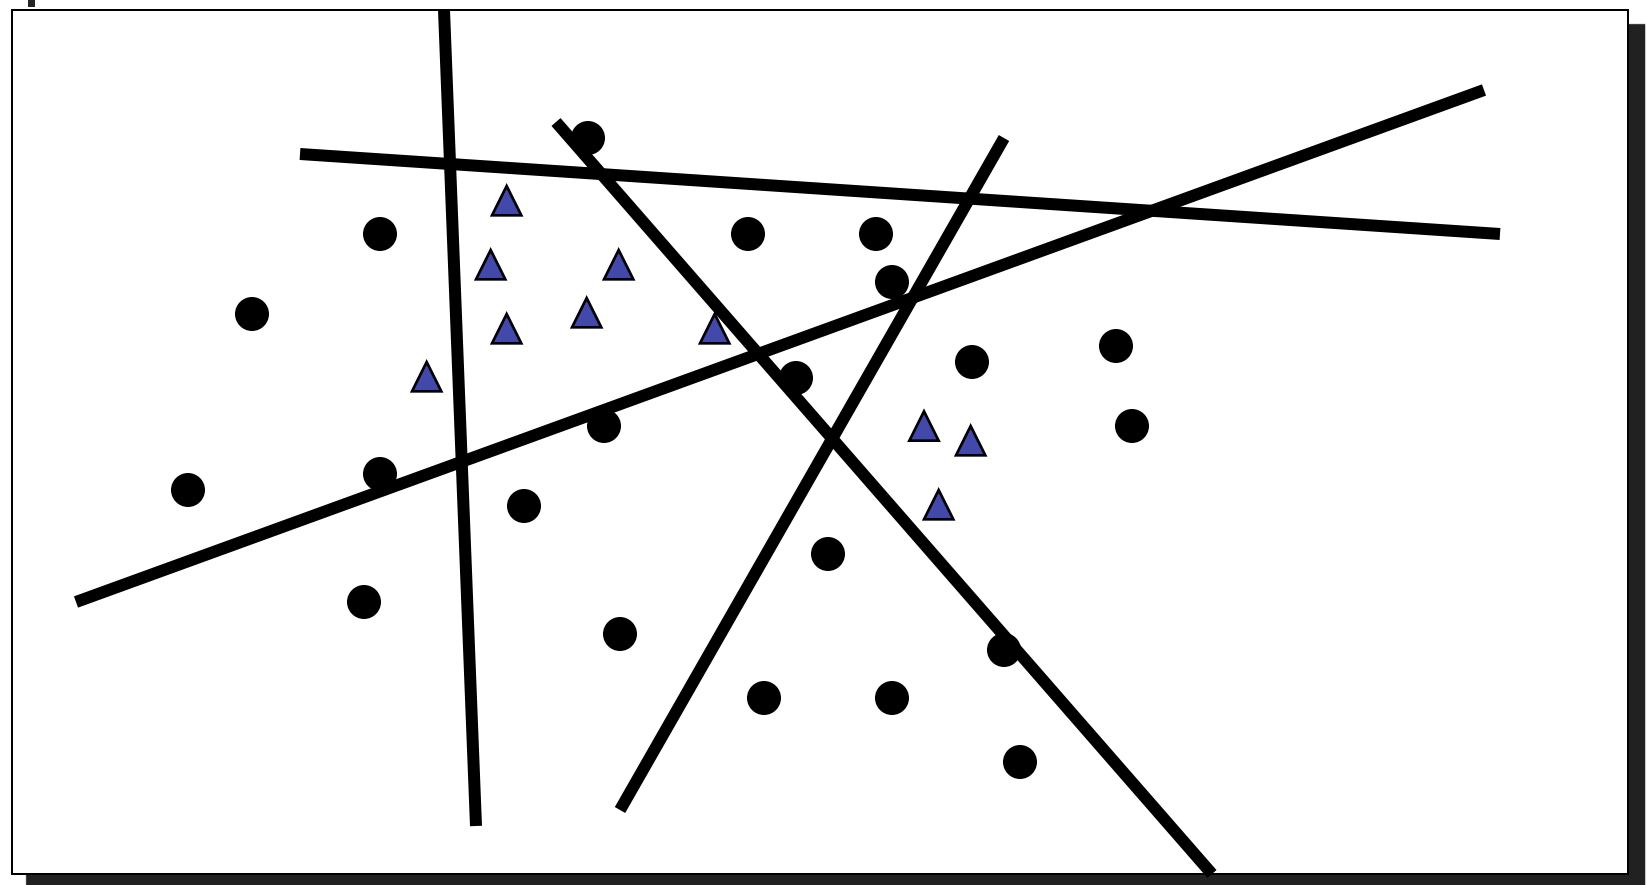


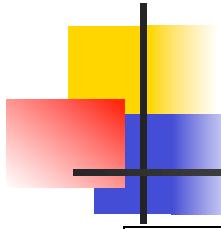
# Treinamento modificando fronteiras



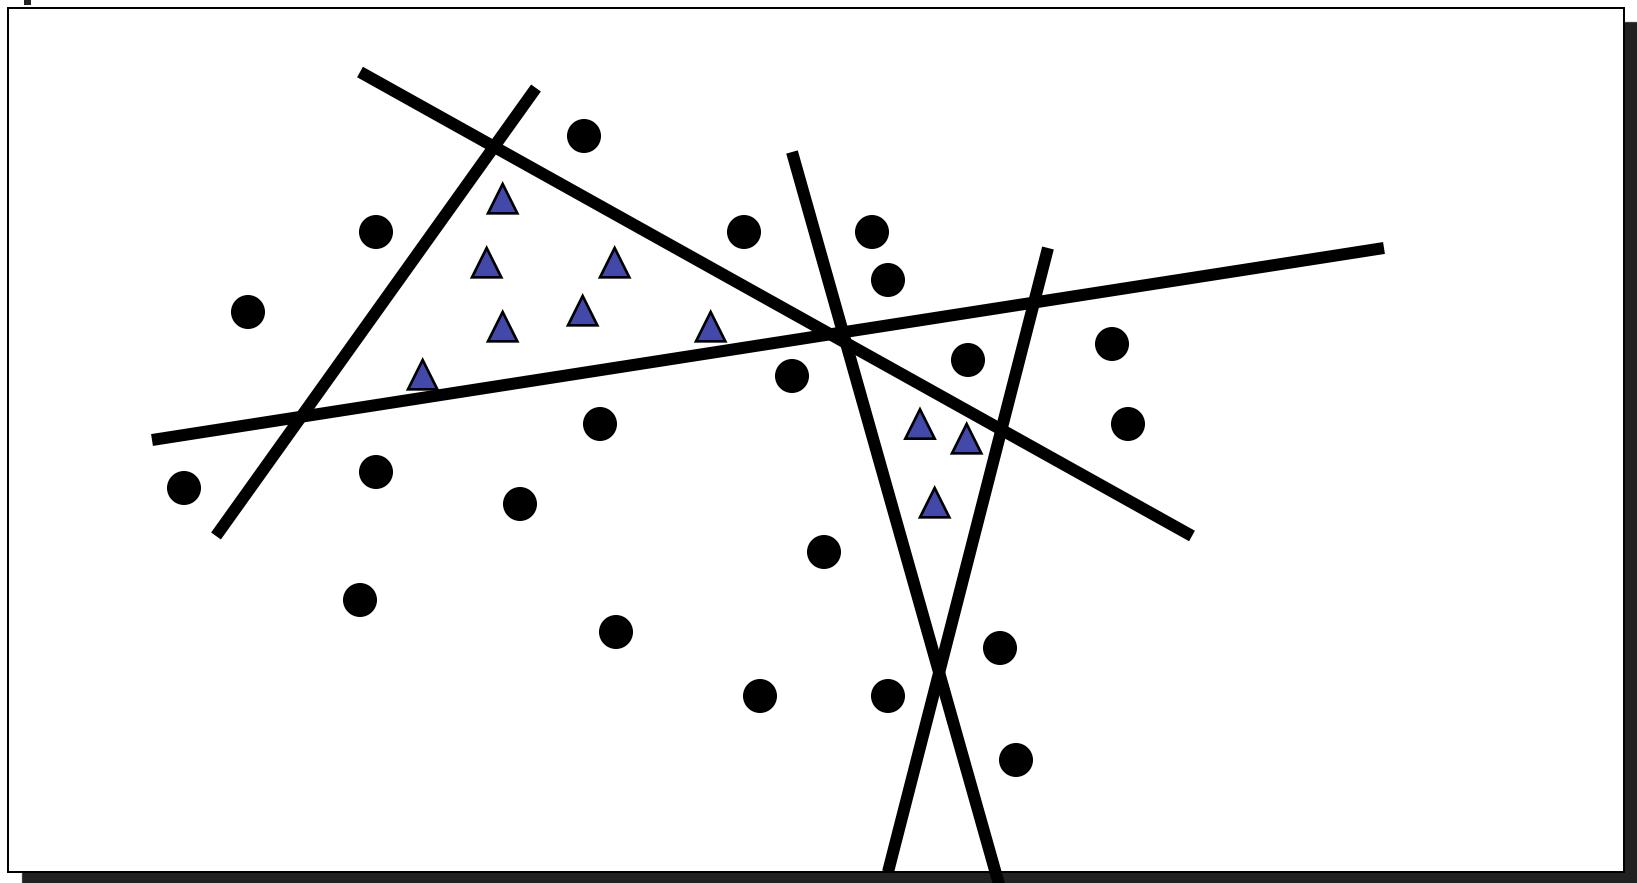


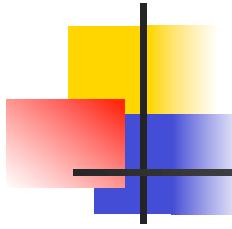
# Treinamento modificando fronteiras



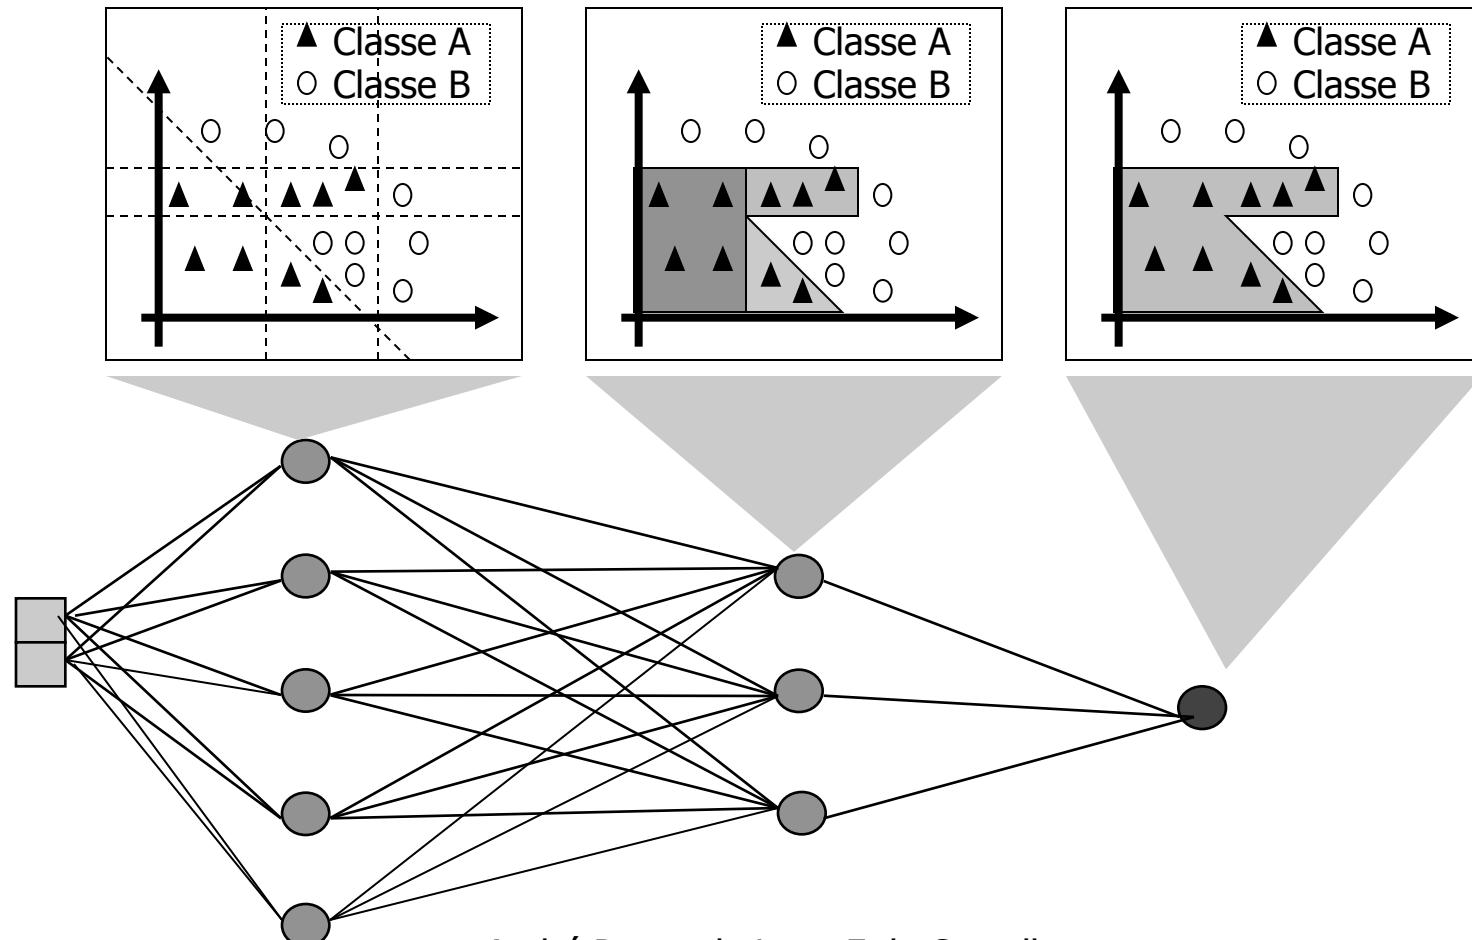


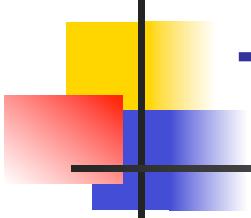
# Treinamento modificando fronteiras





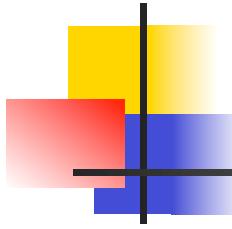
# MLPs como classificadores





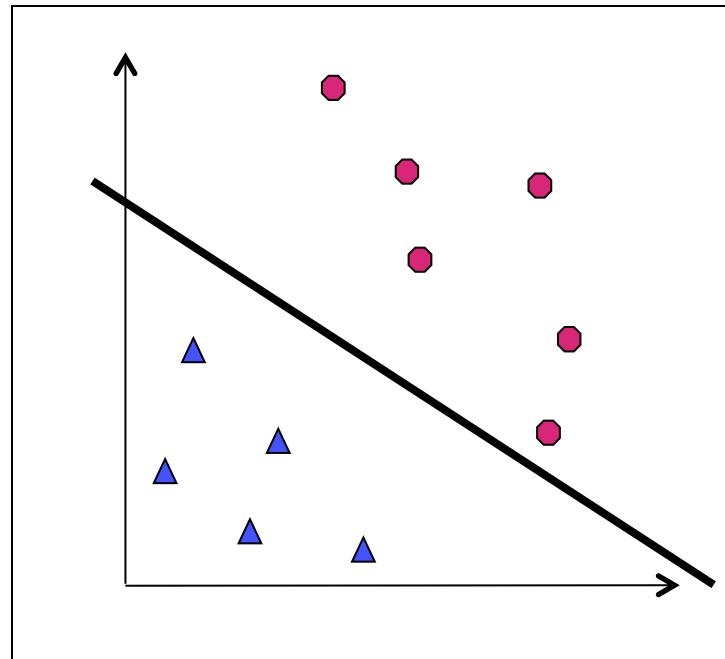
# Teoria de Aprendizado Estatístico

- Difícil garantir que função induzida representa função verdadeira
  - Modelo apresenta boa generalização
- TAE estabelece princípios para obter modelo com boa generalização
  - Vapnik e Chervonenkis em 1968
  - Busca função com menor erro e complexidade
  - Máquinas de Vetores de Suporte (SVMs)

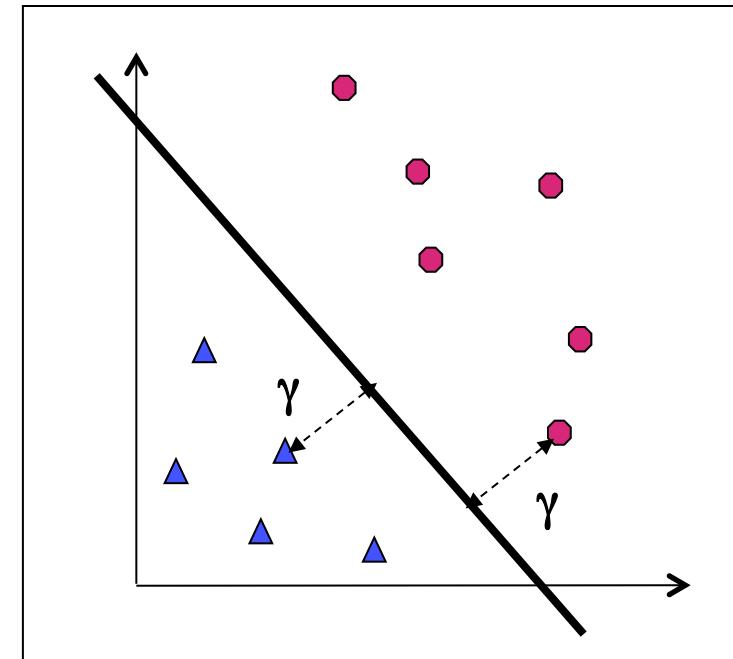


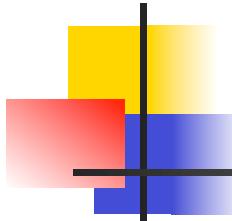
# Máquinas de Vetores de Suporte (SVMs)

Rede Neural

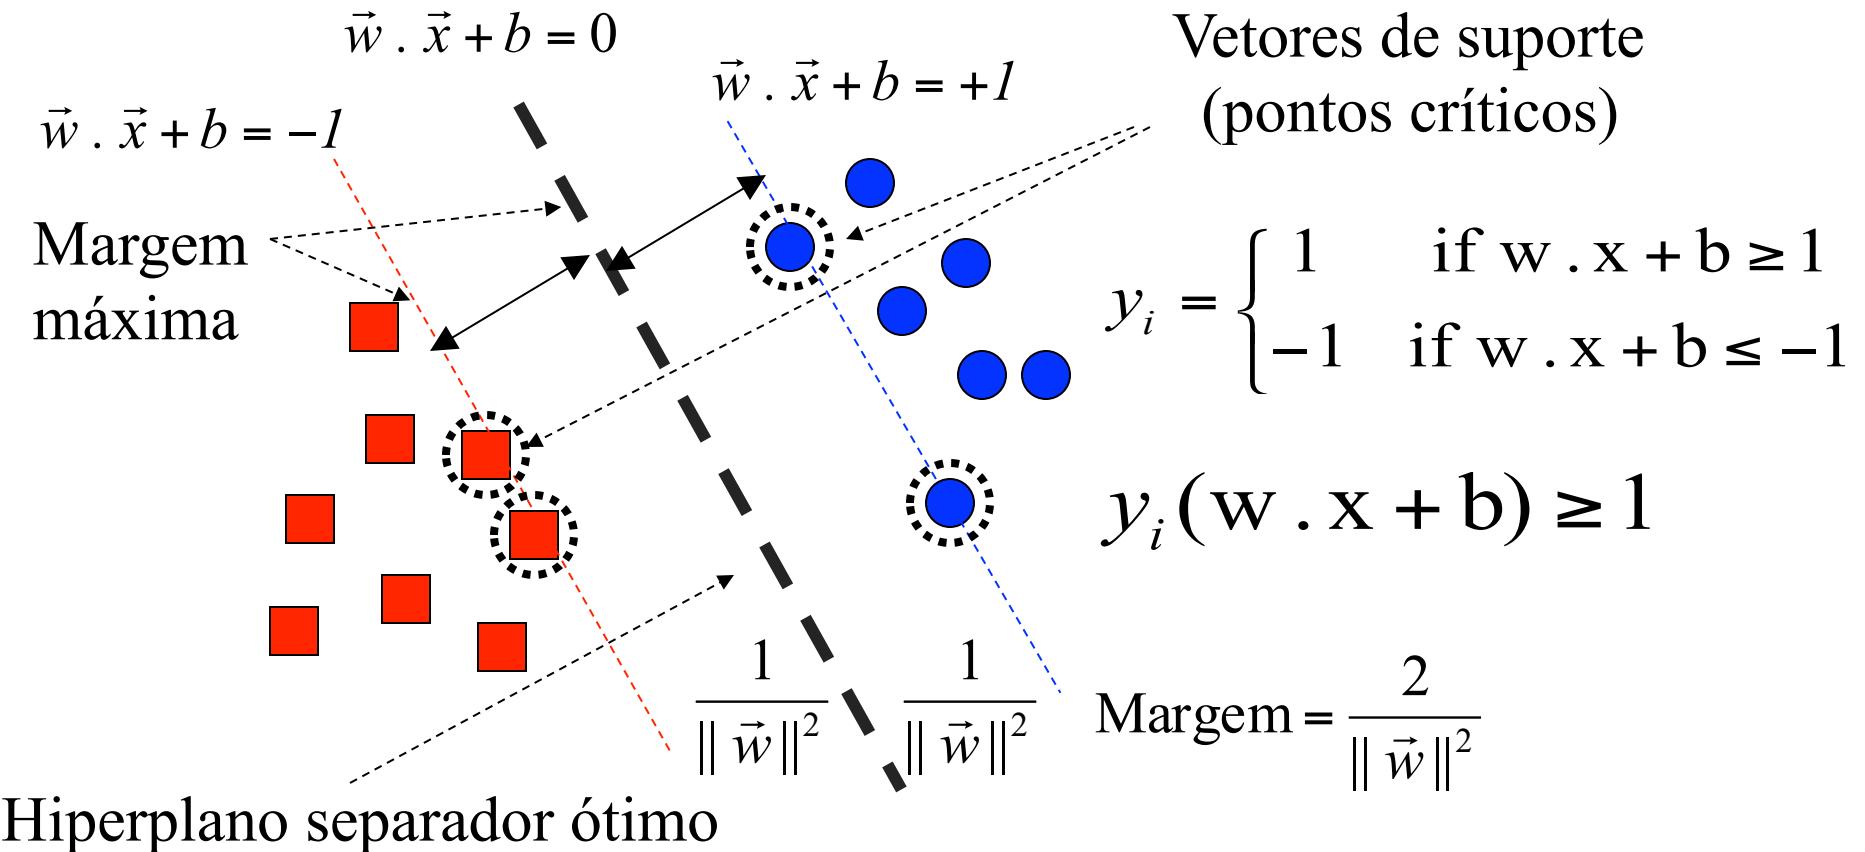


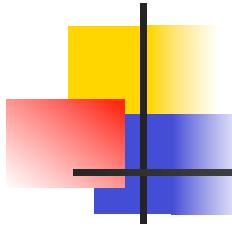
SVMs



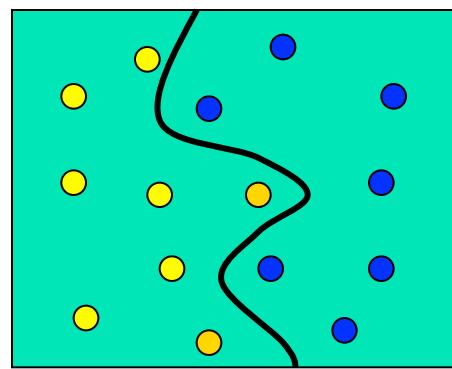


# SVMs



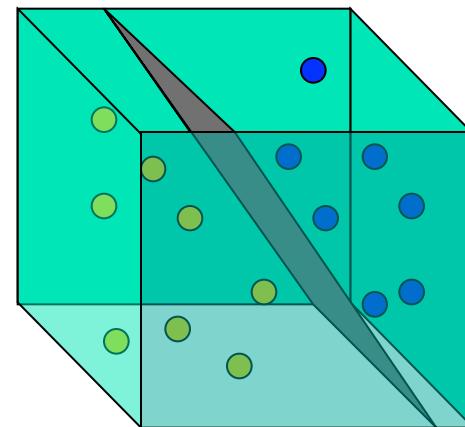


# Fronteiras mais complexas



Espaço de entradas

$$\Phi$$



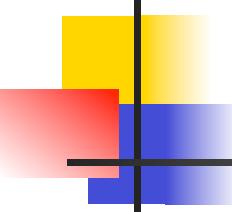
Espaço de características

$$f(x) = w \cdot \Phi(x) + b$$



# Redes neurais profundas (RNP)

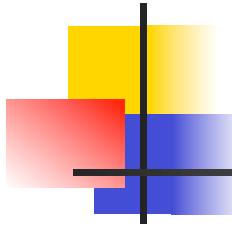
- Redes neurais MLP em geral têm 1 ou 2 camadas intermediárias
  - Redes neurais rasas
- Poucas camadas tornam difícil extrair função que represente os dados
- Uso de backpropagation em redes com muitas camadas leva a soluções pobres
  - Problema de atribuição de erro



# RNs profundas

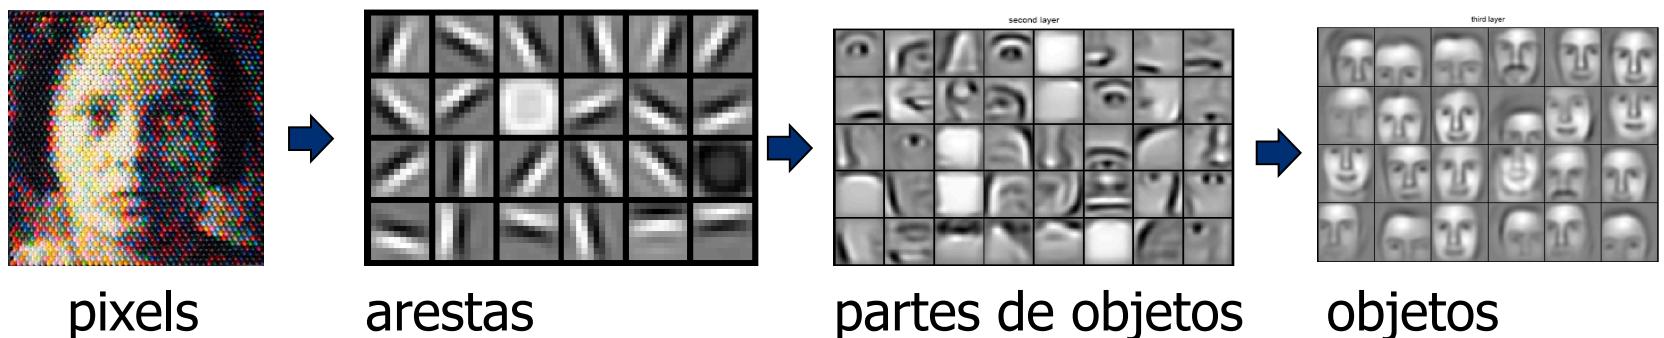
---

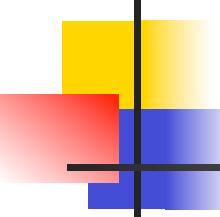
- RNs rasas
  - Características extraídas manualmente (por especialistas) ou por técnicas de extração
- RN profundas
  - Características extraídas hierarquicamente por algoritmos de aprendizado
    - Não supervisionado
      - Pode usar dados não rotulados
    - Semi-supervisionado



# RNs profundas

- Extração de características
  - Inicialmente características simples
  - Nível crescente de abstração
    - Cada camada aplica transformação não linear àa características recebidas da camada anterior

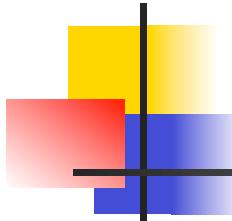




# Principais RNs profundas

---

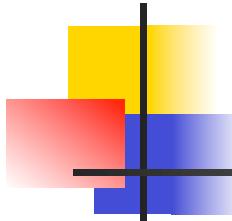
- Redes neurais profundas (RNP)
- Redes credais profundas (RCP)
- Redes autocodificadoras profundas (RAP)
- Redes neurais convolucionais profundas (RNCP)



# Compreensibilidade

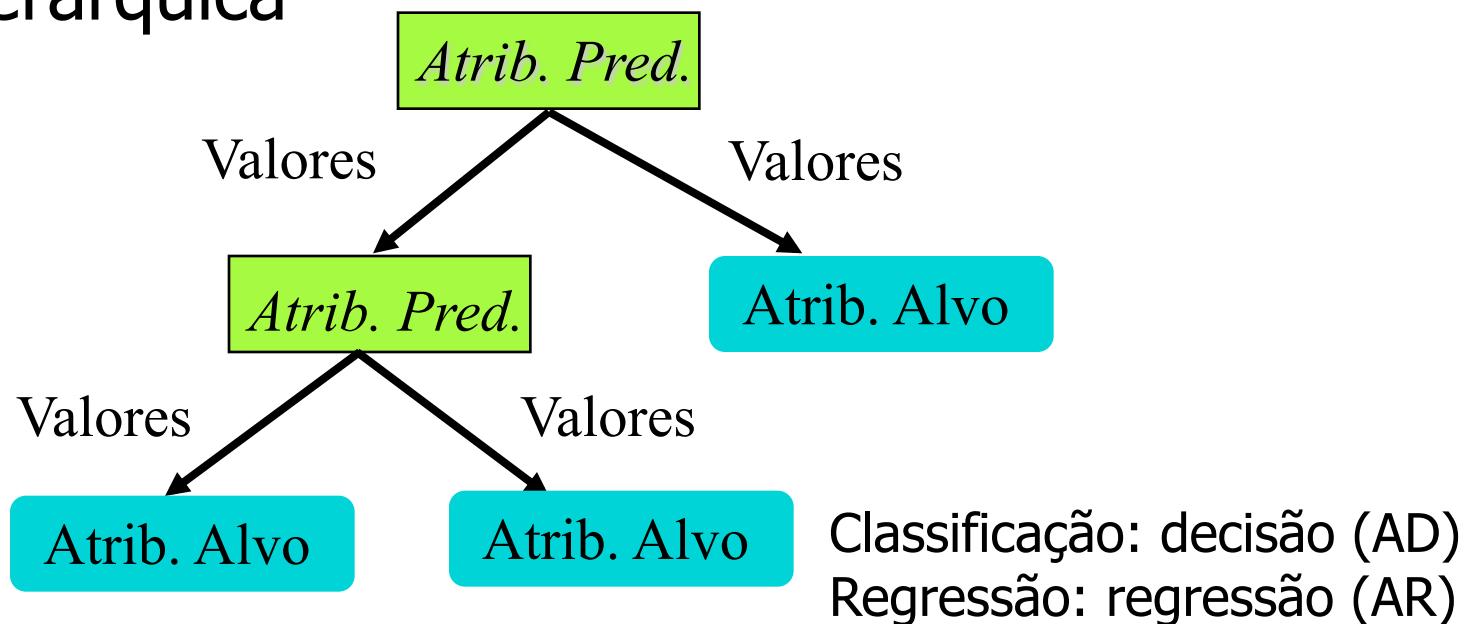
---

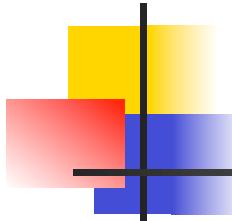
- Explicação das decisões pode ser importante para algumas aplicações
- RNAs, SVMs e RNPs são caixas pretas
- Modelos gerados por algoritmos de indução de
  - Árvores de características (decisão)
  - Conjunto de regras
  - Redes Bayesianas



# Árvores de características

- Alguns algoritmos de AM partitionam características (atributos) de forma hierárquica





# Algoritmo de indução de AD

- Induzem modelos representados por ADs

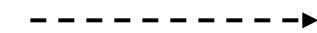
Nó raiz



*sorri*

não

Nó intermediário



*segura*

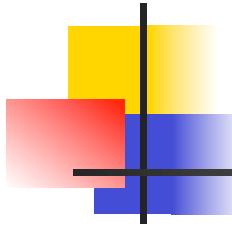
Inimigo

Nós folha



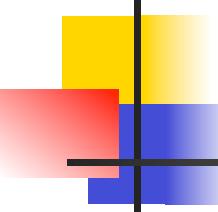
Inimigo

Amigo



# Algoritmo de indução de AD

- Existem vários, entre eles:
  - Algoritmo de Hunt
    - Um dos primeiros
    - Base de vários algoritmos atuais
  - CART
  - ID3
  - C4.5
  - VFDT



# Algoritmo de Hunt

- Seja  $X_t$  o conjunto de objetos de treinamento que atingem o nó t

*Se todos os objetos de  $X_t \in$  a mesma classe  $y_t$*

*Então t é um nó folha rotulado como  $y_t$*

*Se os objetos de  $X_t \in$  a mais de uma classe*

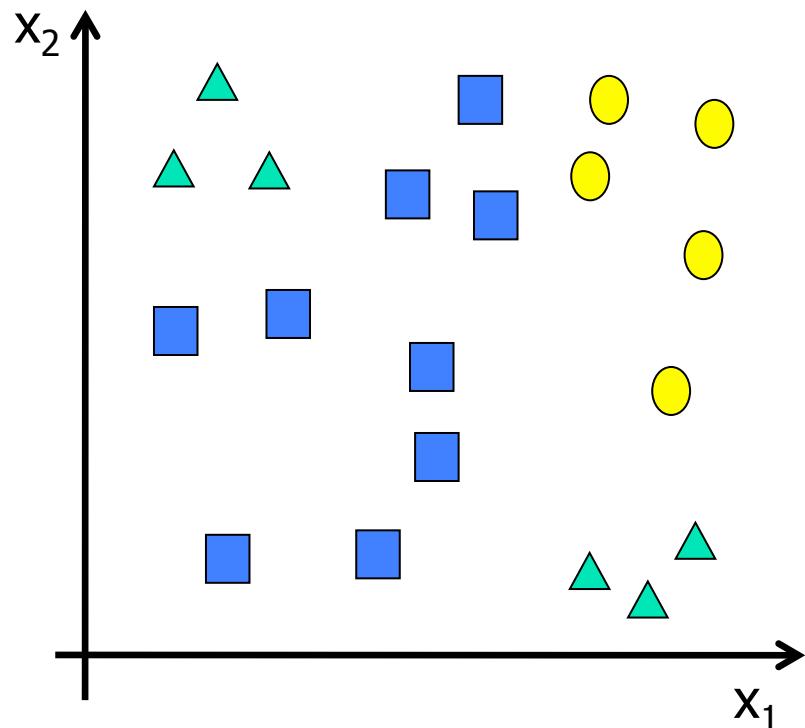
*Então Selecionar um atributo preditivo teste para dividir  $X_t$*

*Dividir  $X_t$  em subconjuntos utilizando esse atributo*

*Aplicar algoritmo a cada subconjunto gerado*

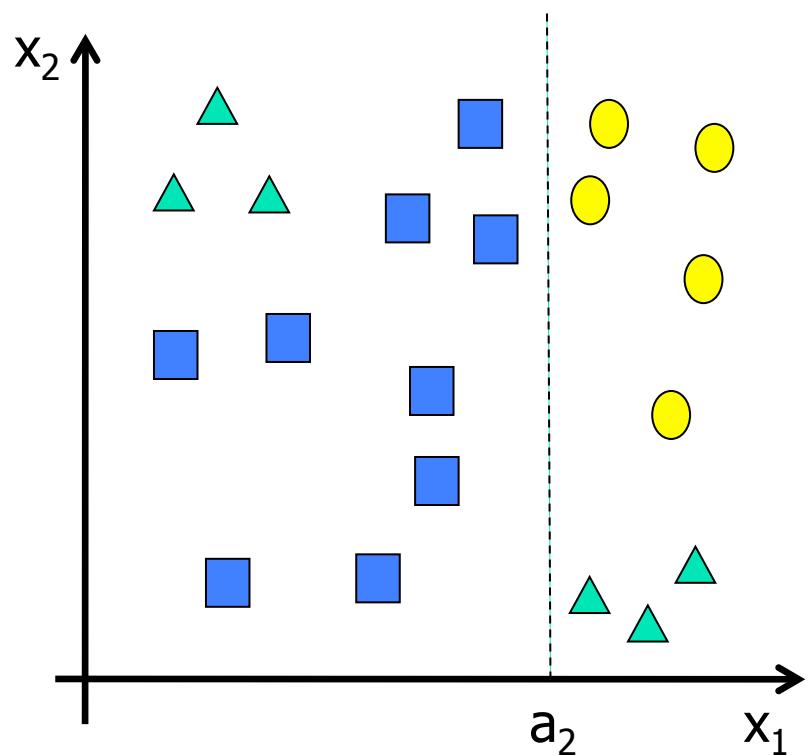
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido



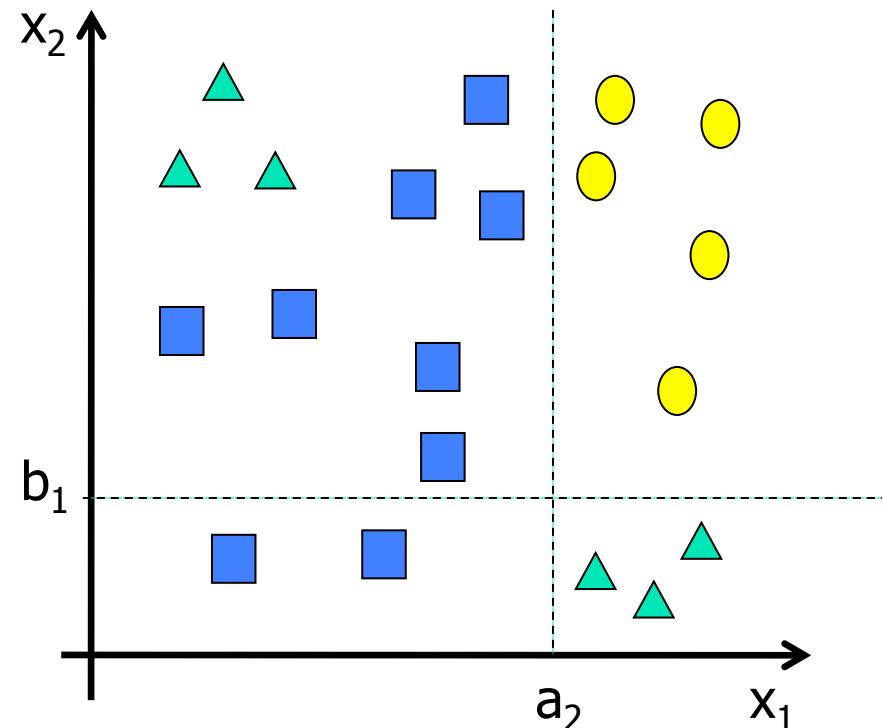
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido



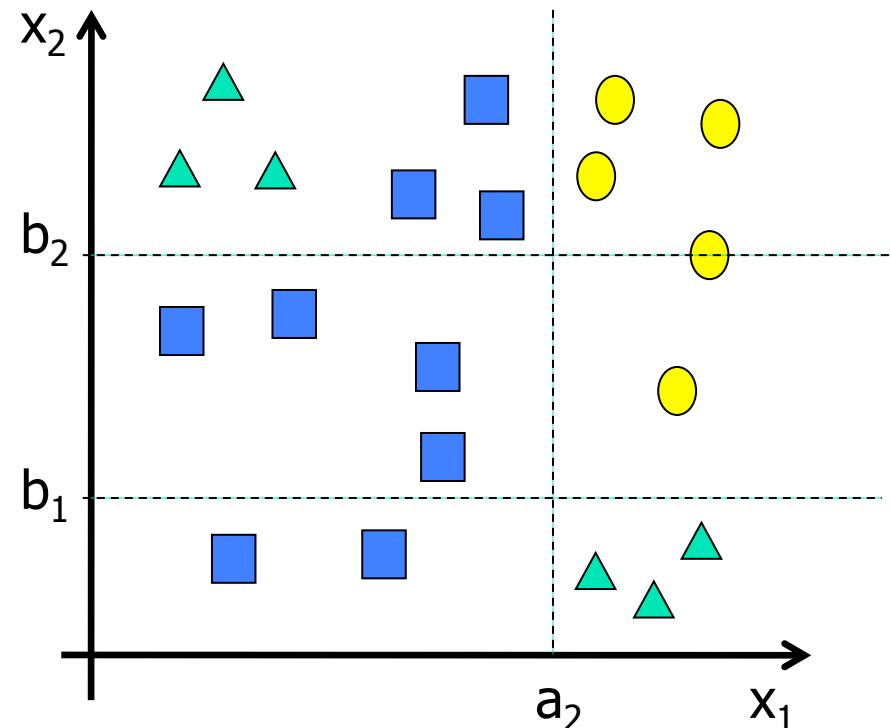
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido



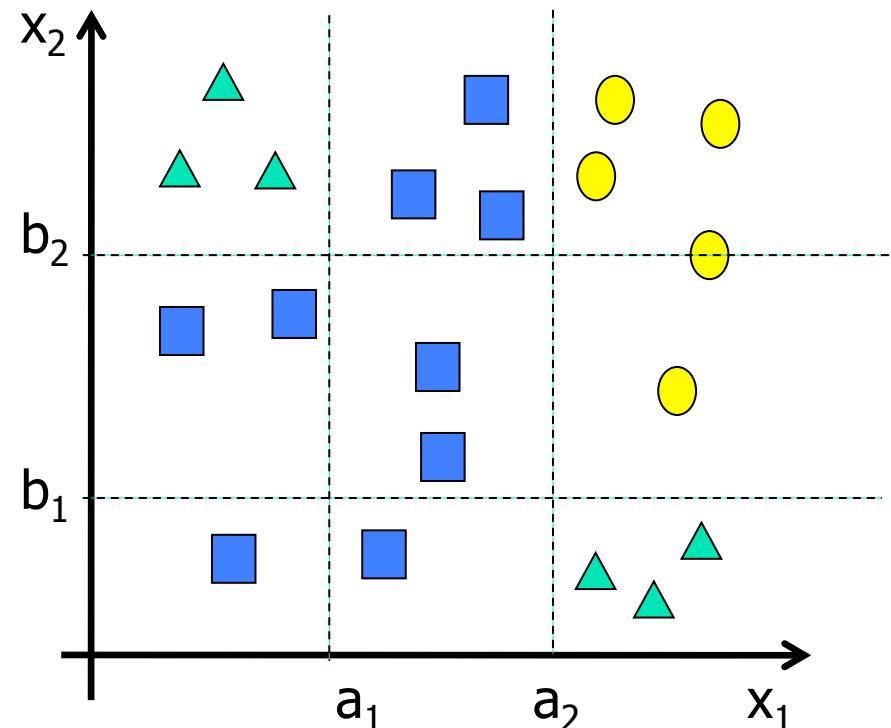
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido



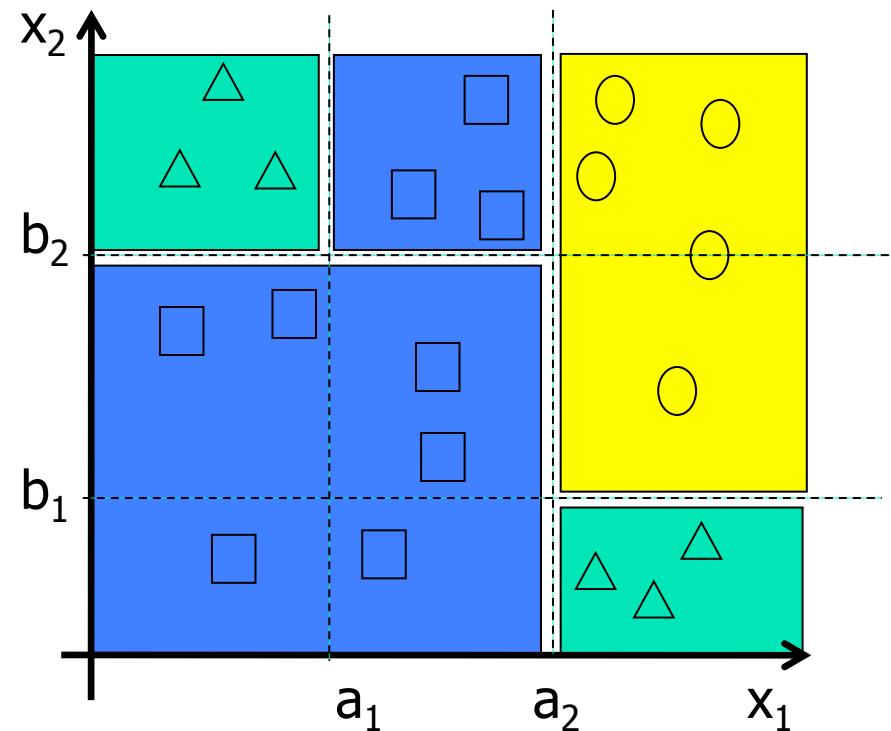
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido

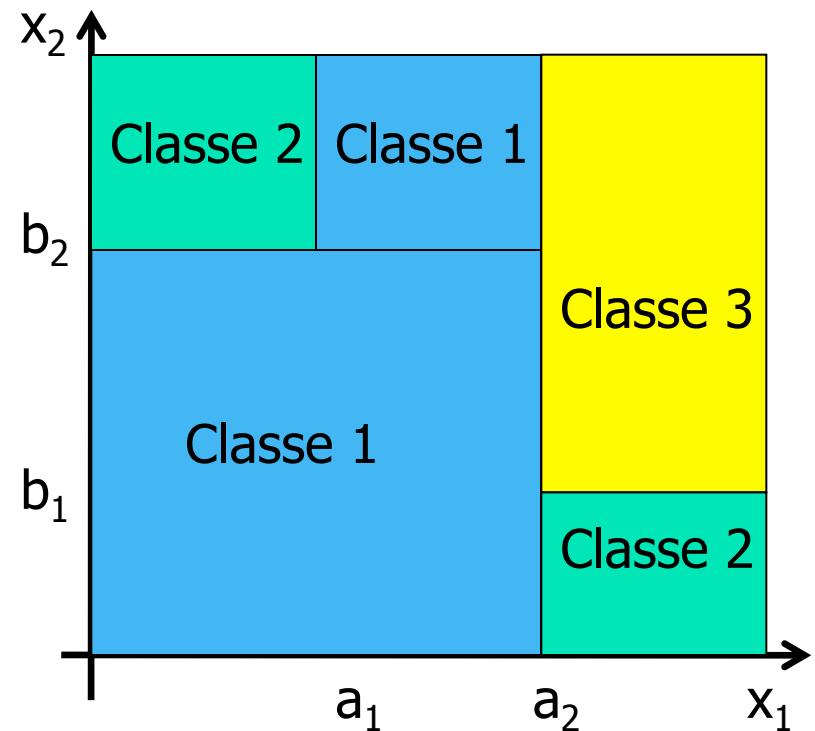
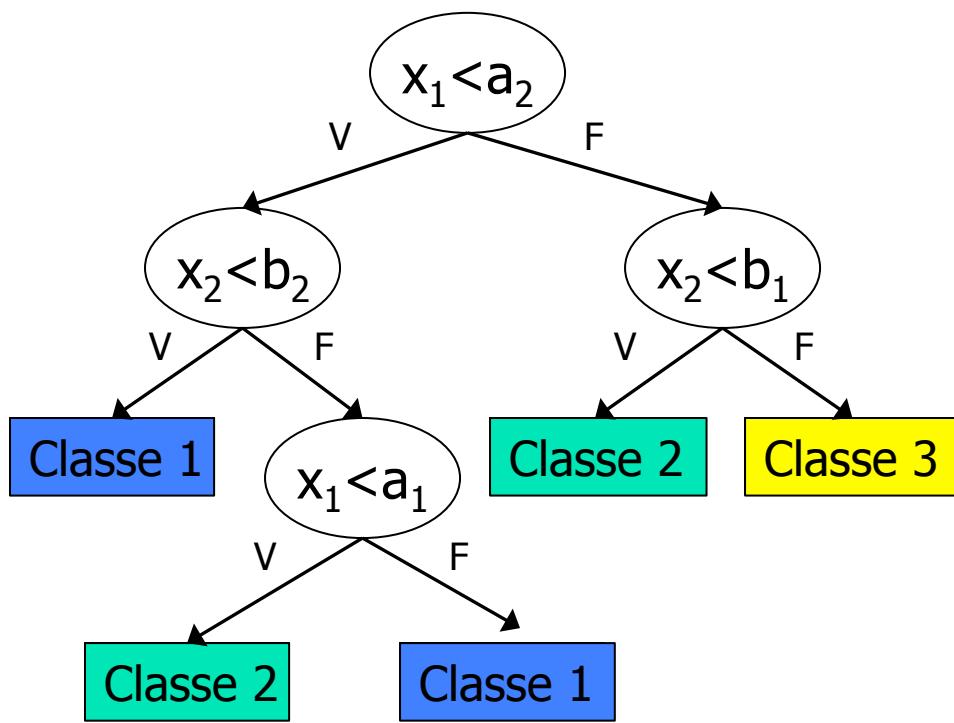


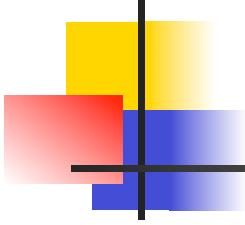
# Algoritmo de indução de AD

- Valores numéricos e simbólicos
- Grau de pureza é calculado para cada atributo
  - Atributo que gera menos impureza é escolhido
- Critério de parada precisa ser definido

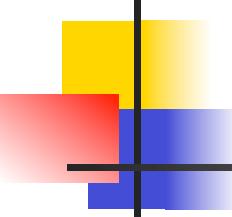


# Árvore e partição do espaço de hipóteses





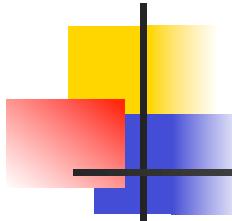
# Avaliação de Desempenho Preditivo



# Algoritmos e modelos

---

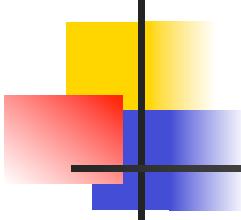
- Algoritmos de AM induzem modelos
  - Funções, hipóteses
- Desempenho a ser avaliado
  - Saída de um algoritmo de AM:
    - Modelo induzido
  - Saída de um modelo de classificação:
    - Classificação para um novo exemplo



# Avaliação de desempenho

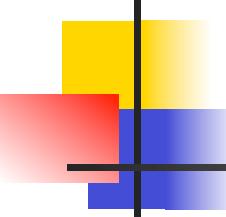
---

- Depende da tarefa
  - Classificação: considera taxa de exemplos incorretamente classificados
    - Ex.: Acurácia
  - Regressão: considera diferença entre valor previsto e valor correto
    - Ex.: MSE
- Média dos erros obtidos em diferentes execuções de um experimento



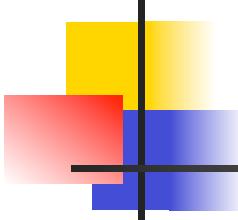
# Desempenho de classificação

- Principal objetivo de um modelo é a classificação correta de novos exemplos
  - Desempenho preditivo
  - Errar o mínimo possível
    - Minimizar taxa de erro de classificação
  - Geralmente não é possível medir com exatidão essa taxa de erro
    - Ela deve ser estimada do erro de treinamento
    - Amostragem de dados



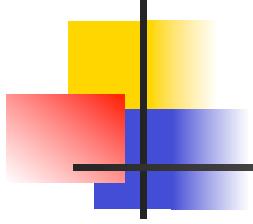
# Amostragem de dados

- Erro de treinamento
  - Ajuste de híper-parâmetros de um algoritmo
  - Comparação de algoritmos ou de híper-parâmetros de um algoritmo
    - Para dados de treinamento
- Erro de teste
  - Comparação de algoritmos para novos dados
  - Nunca para escolha



# Amostragem de dados

- Permite melhor avaliação do desempenho preditivo
- Alternativas
  - Amostragem única
    - *Hold-out*
  - Re-amostragem



# *Hold-out*

1
2
3
4
5
6
7
8

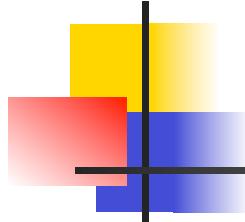
**Partição 1**

2
3
5
7

Treinamento

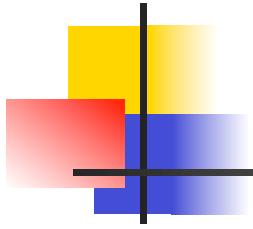
4
8
1
6

Teste

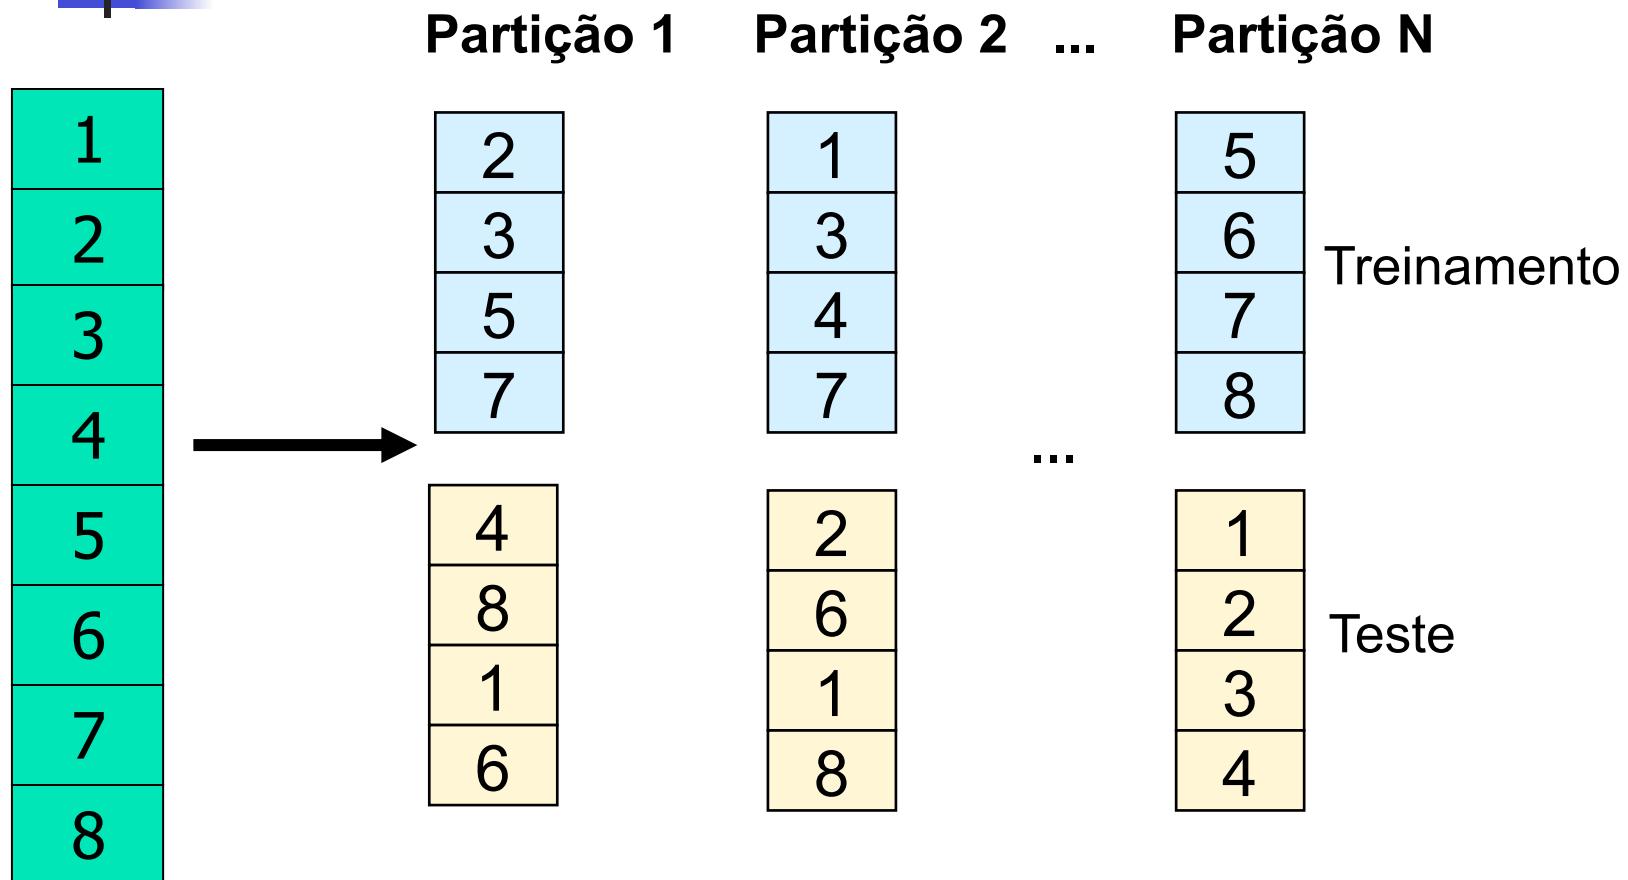


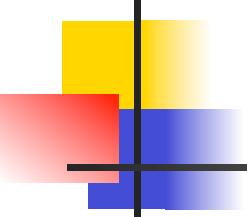
# Métodos de reamostragem

- Utilizam várias partições para os conjuntos de treinamento e teste
  - *Random subsampling*
  - *K-fold Cross-validation*
    - *Leave-one-out*
  - *Bootstrap*

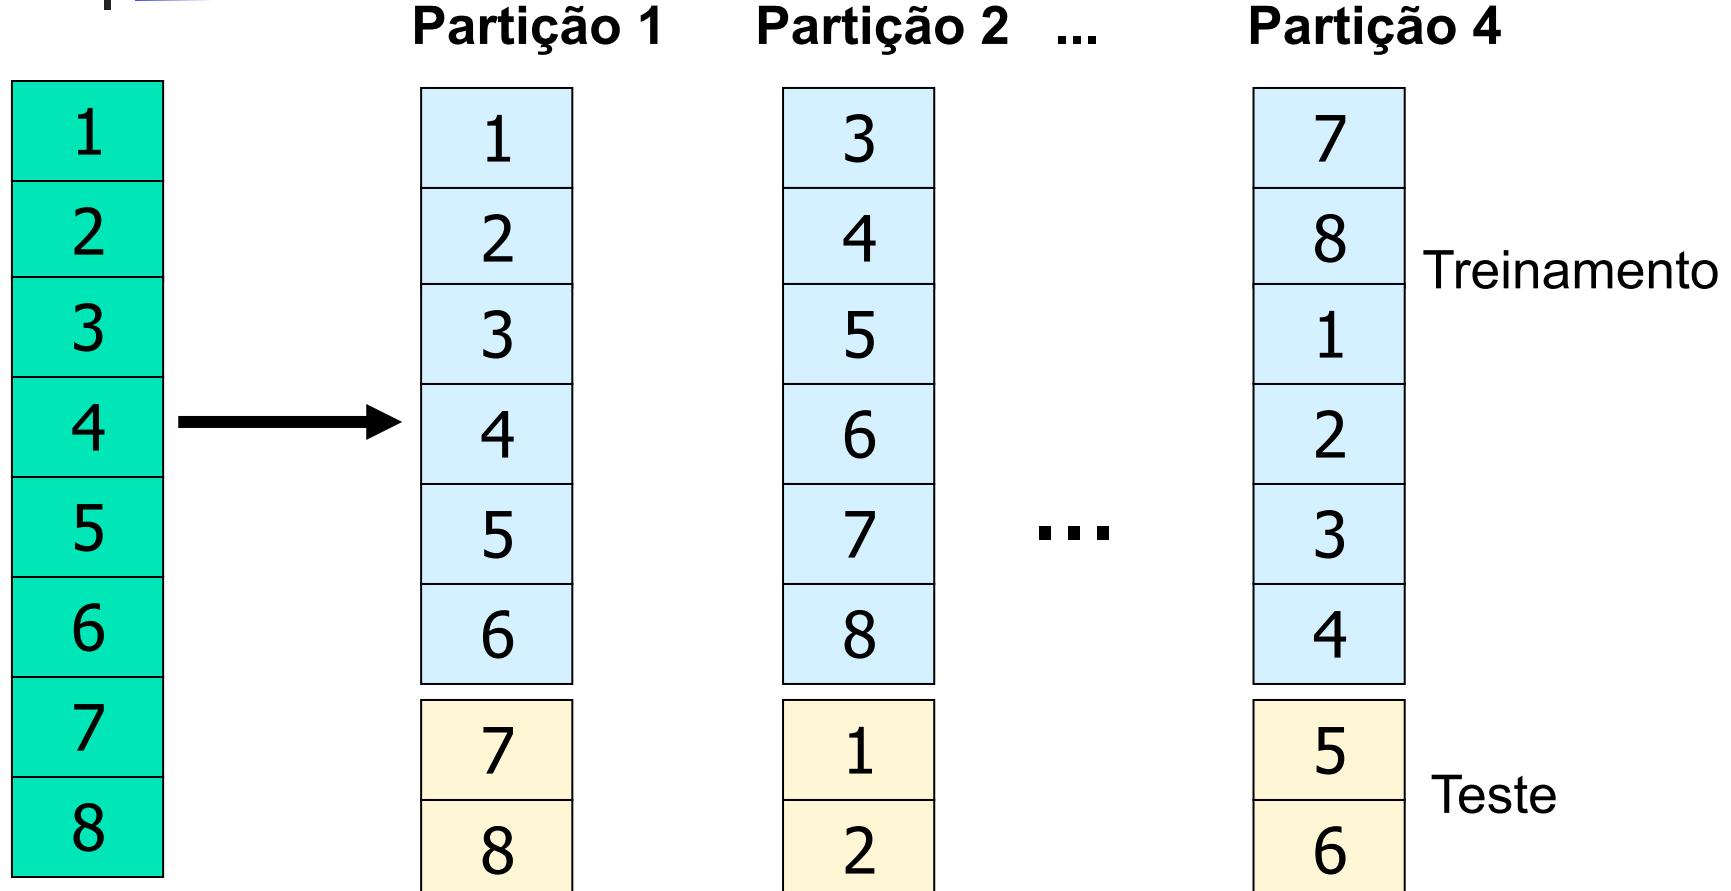


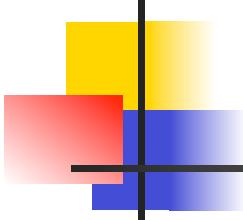
# Random subsampling





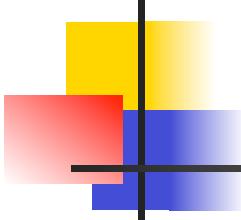
# K-fold cross-validation





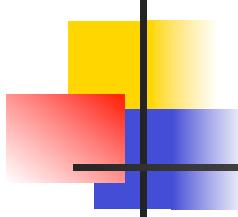
# Leave-one-out

- Estimativa de erro é praticamente não tendenciosa
  - Média das estimativas tende a taxa de erro verdadeiro
- Computacionalmente caro
  - Geralmente utilizado para pequenos conjuntos de exemplos
  - 10-fold cross validation aproxima leave-one-out
- Variância tende a ser elevada



# Bootstrap

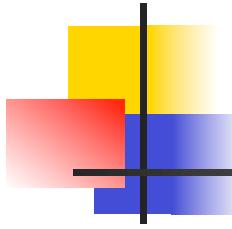
- Funciona melhor que *cross-validation* para conjuntos muito pequenos
- Forma mais simples de *bootstrap*:
  - Amostragem com reposição
    - Cada partição é uma amostra aleatória com reposição do conjunto total de exemplos
      - Conjunto de treinamento têm o mesmo número de exemplos do conjunto total
      - Exemplos que restarem são utilizados para teste



# Bootstrap

---

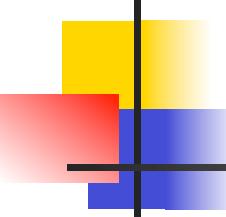
- Se conjunto original tem N exemplos
  - Amostra de tamanho N tem  $\approx 63,2\%$  dos exemplos originais
- Processo é repetido k vezes
  - Resultado final = média dos k experimentos
- Existem diversas variações



# Acurácia

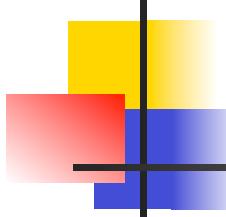
---

- Quantos exemplos foram corretamente classificados
  - Avalia erro nas classes igualmente
- Pode não ser adequada para dados desbalanceados
  - Pode prejudicar desempenho para classe minoritária
    - Geralmente mais interessante que a classe majoritária
  - Acurácia balanceada



# Classificação binária

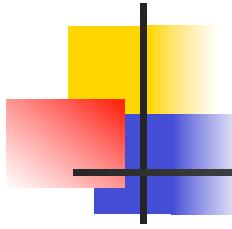
- Classe de interesse é a classe positiva
- Dois tipos de erro:
  - Classificação de um exemplo N como P
    - Falso positivo (alarme falso)
      - Ex.: Diagnosticado como doente, mas está saudável
    - Classificação de um exemplo P como N
      - Falso negativo
        - Ex.: Diagnosticado como saudável, mas está doente



# Desempenho preditivo

- Matriz de confusão (tabela de contingência) pode ser utilizada para distinguir os erros
  - Base de várias medidas
  - Pode ser utilizada com 2 ou mais classes

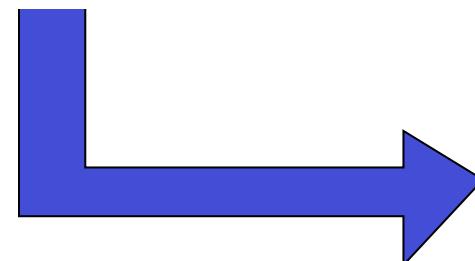
Classe verdadeira	Classe predita		
	1	2	3
1	25	0	5
2	10	40	0
3	0	0	20



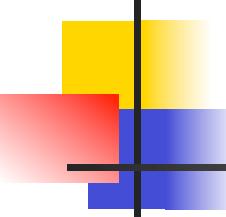
# Exemplo

- Matriz de confusão para 200 exemplos divididos em 2 classes

		Classe predita	
		p	n
Classe verdadeira	P	70	30
	N	40	60



		Classe predita	
		p	n
Classe verdadeira	P	VP	FN
	N	FP	VN



# Medidas de avaliação

$$\text{Taxa de FP (TFP)} = \frac{FP}{FP + VN}$$

(Alarmes falsos)

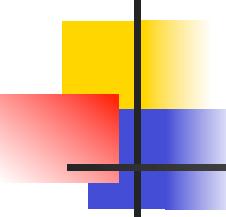
Erro do tipo I

		Classe predita	
		p	n
Classe verdadeira	P	VP	FN
	N	FP	VN

$$\text{Taxa de FN (TFN)} = \frac{FN}{VP + FN}$$

Erro do tipo II

		Classe predita	
		p	n
Classe verdadeira	P	VP	FN
	N	FP	VN



# Medidas de avaliação

$$\text{Taxa de FP (TFP)} = \frac{FP}{FP + VN}$$

(Alarmes falsos)

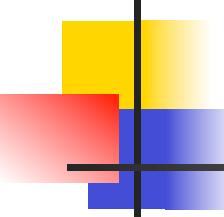
Custo

		Classe predita	
		p	n
Classe verdadeira	P	VP	FN
	N	FP	VN

$$\text{Taxa de VP (TVP)} = \frac{VP}{VP + FN}$$

Benefício

		Classe predita	
		p	n
Classe verdadeira	P	VP	FN
	N	FP	VN



# Exemplo

## ■ Avaliação de 3 classificadores

		Classe predita	
		p	n
Classe verdadeira	P	20	30
	N	15	35

Classificador 1  
TVP =  
TFP =

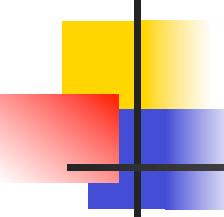
		Classe predita	
		p	n
Classe verdadeira	P	70	30
	N	50	50

Classificador 2  
TVP =  
TFP =

		Classe predita	
		p	n
Classe verdadeira	P	60	40
	N	20	80

Classificador 3  
TVP =  
TFP =

$$\frac{VP}{VP + FN} \quad \frac{FP}{FP + VN}$$



# Exemplo

$$\frac{VP}{VP + FN} \quad \frac{FP}{FP + VN}$$

## ■ Avaliação de 3 classificadores

		Classe predita	
		p	n
Classe verdadeira	P	20	30
	N	15	35

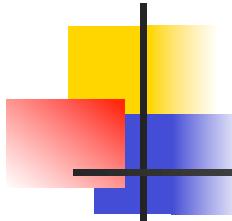
Classificador 1  
TVP = 0.4  
TFP = 0.3

		Classe predita	
		p	n
Classe verdadeira	P	70	30
	N	50	50

Classificador 2  
TVP = 0.7  
TFP = 0.5

		Classe predita	
		p	n
Classe verdadeira	P	60	40
	N	20	80

Classificador 3  
TVP = 0.6  
TFP = 0.2



# Medidas de avaliação

- Medidas frequentemente utilizadas

$$\text{TFP} = \frac{FP}{FP + VN}$$

(Erro tipo I)

$$\text{Precisão} = \frac{VP}{VP + FP}$$

$$\text{TVP} = \frac{VP}{VP + FN}$$

Sensibilidade  
Revocação (Recall)

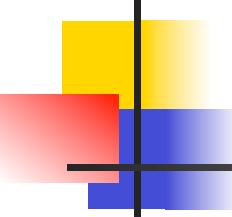
$$\text{TFN} = \frac{FN}{VP + FN}$$

(Erro tipo II)

$$\text{Especificidade} = \frac{VN}{VN + FP} = 1 - \text{TFP}$$

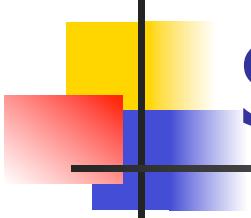
$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Medida-F1} = \frac{2}{1/prec + 1/rev}$$



# Revocação X Precisão

- Revocação (*recall*)
    - Porcentagem de exemplos positivos classificados como positivos
      - Nenhum exemplo positivo é deixado de fora
  - Precisão
    - Porcentagem de exemplos classificados como positivos que são realmente positivos
      - Nenhum exemplo negativo é incluído
- $$\frac{VP}{VP + FN}$$
- $$\frac{VP}{VP + FP}$$



# Sensibilidade X Especificidade

- Sensibilidade

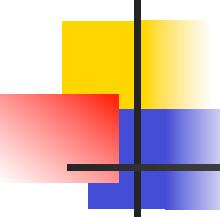
- Porcentagem de exemplos positivos classificados como positivos
    - Igual a revocação

$$\frac{VP}{VP + FN}$$

- Especificidade

- Porcentagem de exemplos negativos classificados como negativos
    - Nenhum exemplo negativo é deixado de fora

$$\frac{VN}{VN + FP}$$



# Medidas de avaliação

- Medida-F

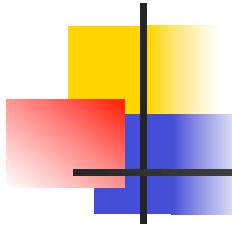
- Média harmônica ponderada da precisão e da revocação

$$\frac{(1 + \alpha) \times (prec \times rev)}{\alpha \times prec + rev}$$

- Medida-F1

- Precisão e revocação têm o mesmo peso

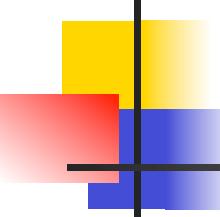
$$\frac{2 \times (prec \times rev)}{prec + rev} = \frac{2}{1/prec + 1/rev}$$



# Exemplo

- Seja um classificador com a seguinte matriz de confusão, definir:
  - Acurácia
  - Precisão
  - Revocação
  - Especificidade

		Classe predita	
		p	n
Classe verdadeira	P	70	30
	N	40	60



# Exemplo

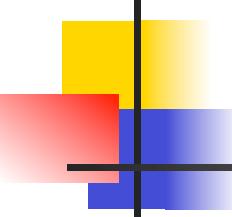
$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN}$$

$$\text{Precisão} = \frac{VP}{VP + FP}$$

$$\text{Revocação} = \frac{VP}{VP + FN}$$

$$\text{Especificidade} = \frac{VN}{VN + FP}$$

		Preditos	
		p	n
Verdadeiro	P	VP	FN
	N	FP	VN
Verdadeiro	P	70	30
	N	40	60



# Exemplo

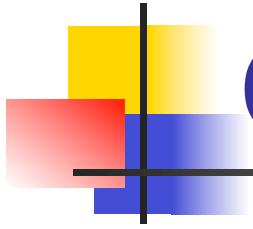
$$\text{Acurácia} = \frac{VP + VN}{VP + VN + FP + FN} = (70 + 60) / (70 + 30 + 40 + 60) = 0.65$$

$$\text{Precisão} = \frac{VP}{VP + FP} = 70/(70+40) = 0.64$$

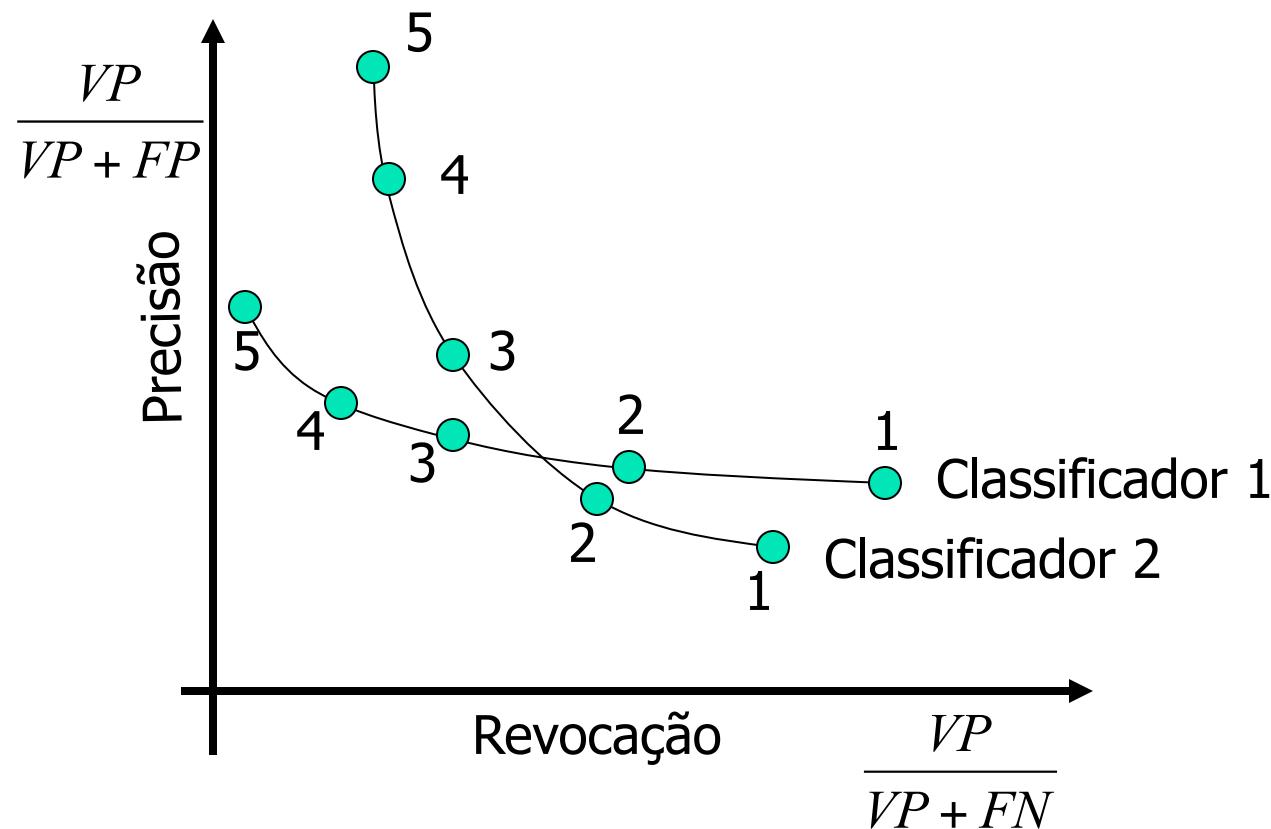
$$\text{Revocação} = \frac{VP}{VP + FN} = 7/(70+30) = 0.70$$

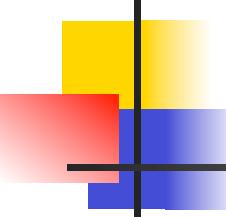
$$\text{Especificidade} = \frac{VN}{VN + FP} = 60/(40+60) = 0.60$$

		Preditos	
		p	n
Verdadeiro	P	VP	FN
	N	FP	VN
Preditos	p	70	30
	n	40	60



# Observação

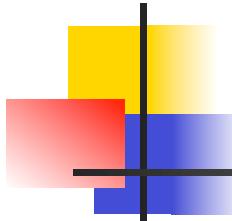




# Gráficos ROC

- Do inglês, *Receiver operating characteristics*
- Medida de desempenho originária da área de processamento de sinais
  - Muito utilizada nas áreas médica e biológica
  - Mostra relação entre custo (TFP) e benefício (TVP)

$$\frac{FP}{FP + VN} \times \frac{VP}{VP + FN}$$



# Exemplo

- Colocar no gráfico ROC os 3 classificadores do exemplo anterior

Classificador 1  
TFP = 0.3  
TVP = 0.4



Classificador2  
TFP = 0.5  
TVP = 0.7



Classificador 3  
TFP = 0.2  
TVP = 0.6



# Gráficos ROC

Classificador ideal

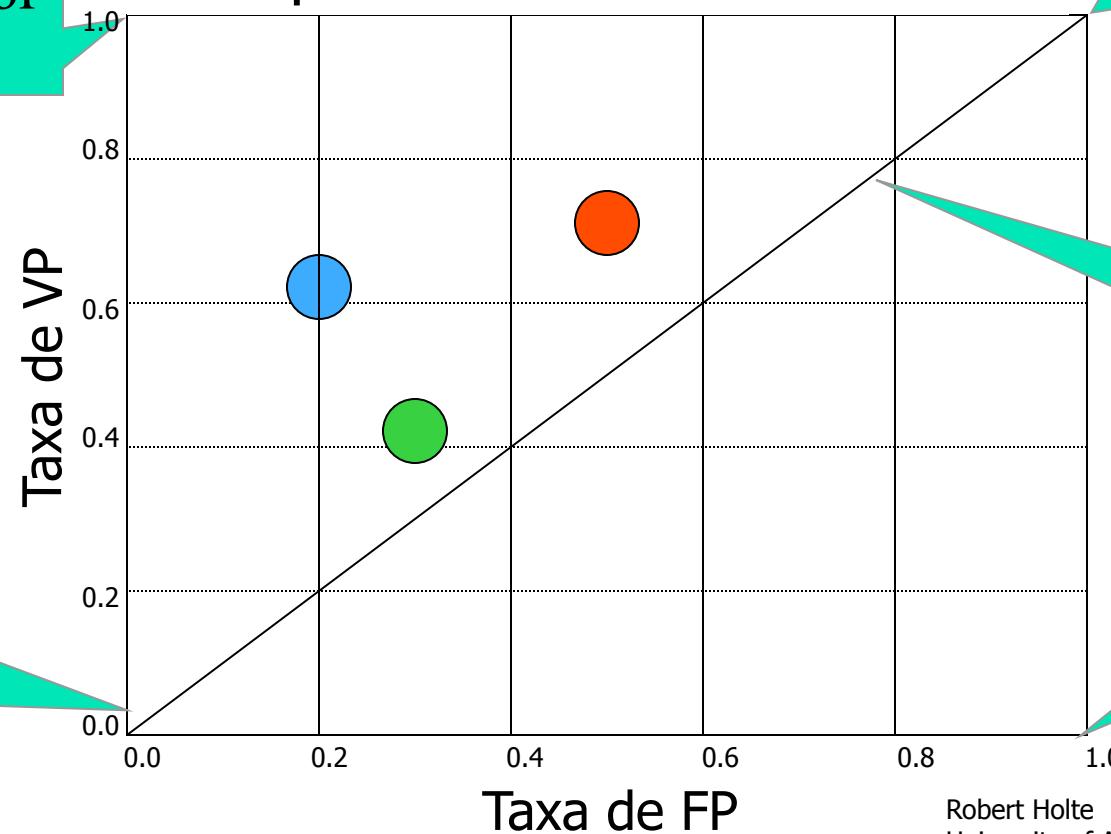
ROC para os três classificadores

Sempre positiva

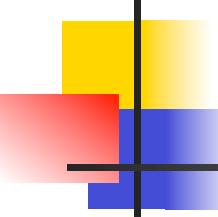
Escolha aleatória

Pior classificador

Sempre negativa



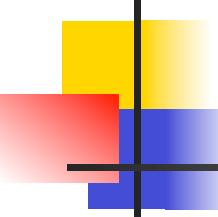
Robert Holte  
University of Alberta



# Gráficos ROC

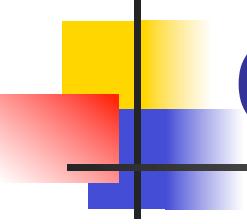
---

- Classificadores discretos produzem um simples ponto no gráfico ROC
  - ADs e conjuntos de regras
- Outros classificadores produzem uma probabilidade ou escore
  - RNAs e NB
- Curvas ROC permitem uma melhor comparação de classificadores
  - São insensíveis a mudanças na distribuição das classes

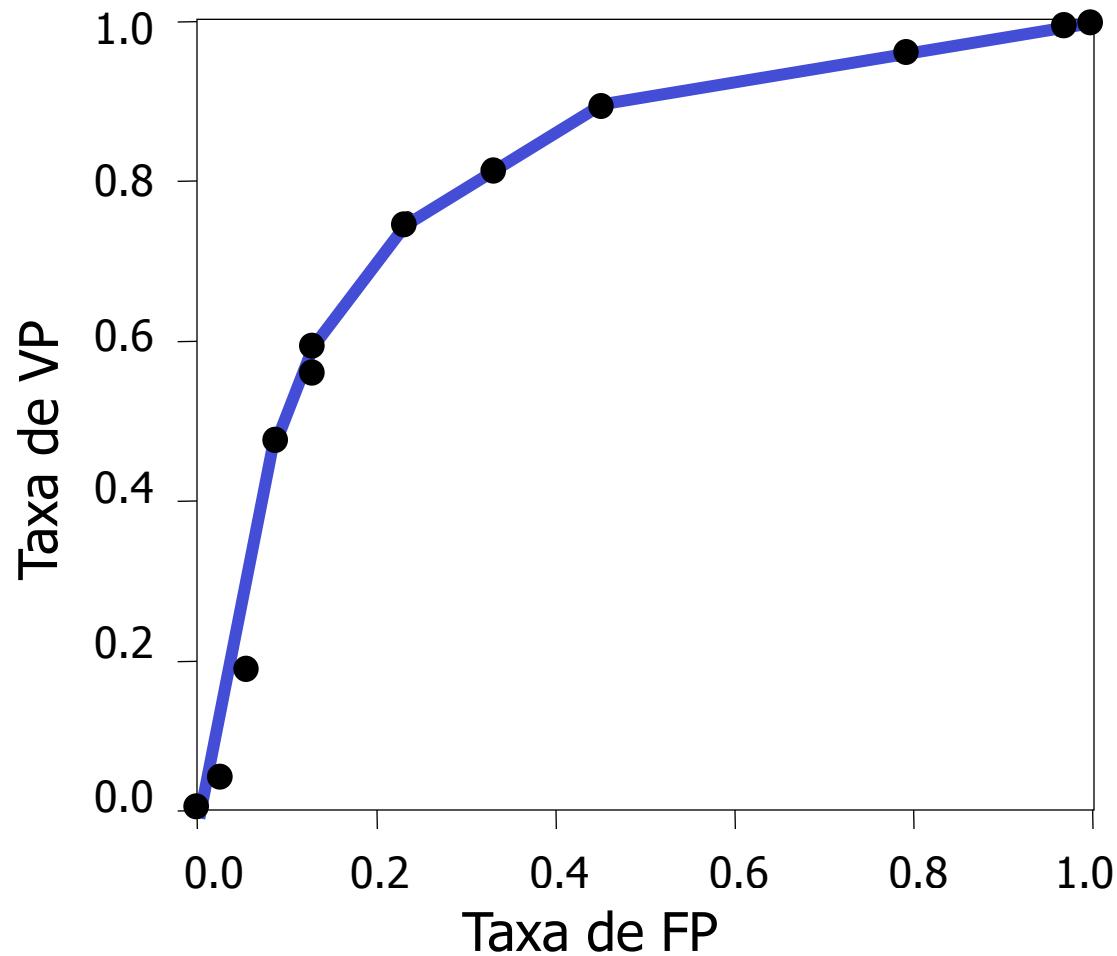


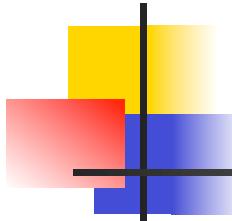
# Curvas ROC

- Mostram ROC para diferentes variações
- Classificadores que geram valores continuos (*threshold*, probabilidade)
  - Diferentes valores de *threshold* podem ser utilizados para gerar vários pontos
    - Ligação dos pontos gera uma curva ROC
- Classificadores discretos
  - Convertidos internamente ou comitês



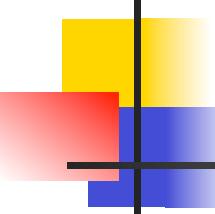
# Curvas ROC



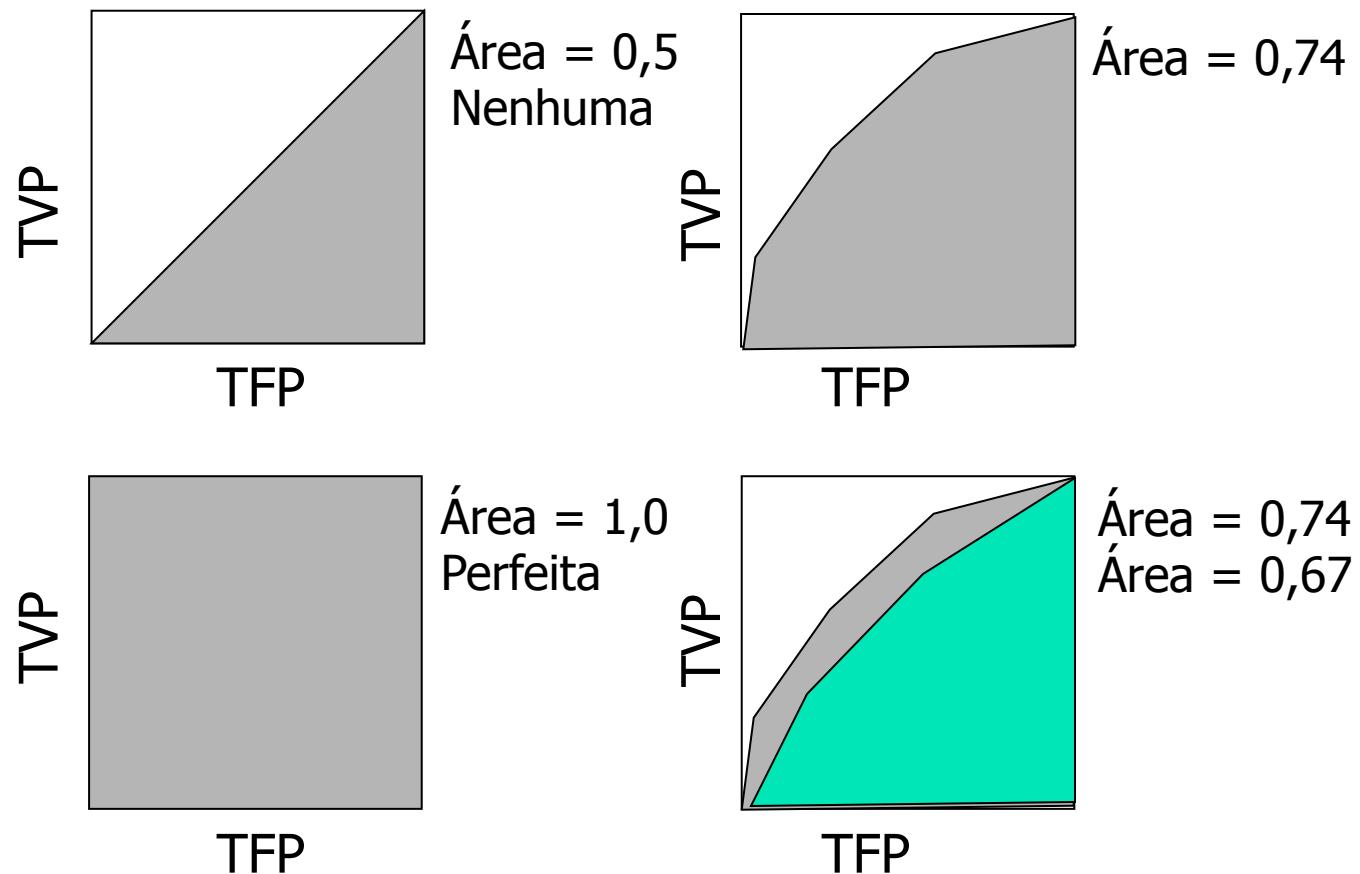


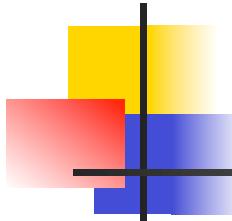
# Área sob a curva ROC (AUC)

- Fornece uma estimativa do desempenho de classificadores
- Gera um valor contínuo no intervalo  $[0, 1]$ 
  - Quanto maior melhor
  - Adição de áreas de sucessivos trapézóides
- Um classificador com maior AUC pode apresentar AUC pior em trechos da curva
- Mais confiável utilizar médias de AUCs



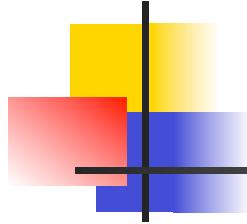
# Área Sob Curvas ROC



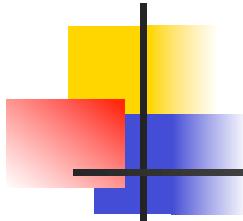


# Avaliação de Desempenho

- Teste de Hipóteses
  - Permite afirmar que uma técnica é melhor que outra com X% de confiança
  - Podem assumir que os dados seguem uma dada distribuição de probabilidade
    - Paramétricos
    - Não paramétricos
  - Número de técnicas comparadas
    - Duas
    - Mais que duas

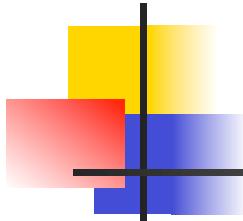


# Métodos Descritivos



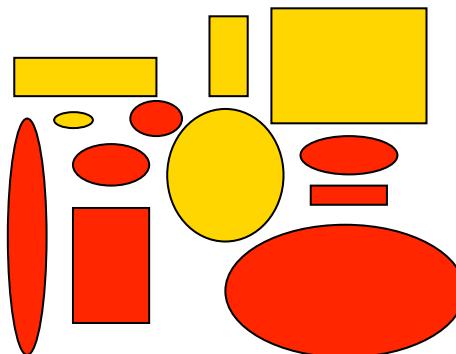
# Agrupamento (Clustering)

- Objetivo: organizar exemplos em grupos (clusters)
  - Utilizando medida de similaridade ou correlação entre exemplos
  - Em geral exemplos não têm rótulo
    - Aprendizado não supervisionado
- Não existe conhecimento anterior sobre:
  - Número de grupos (geralmente)
  - Significado dos grupos

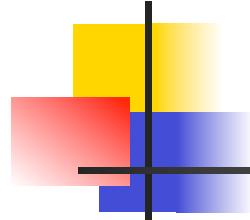


# Agrupamento

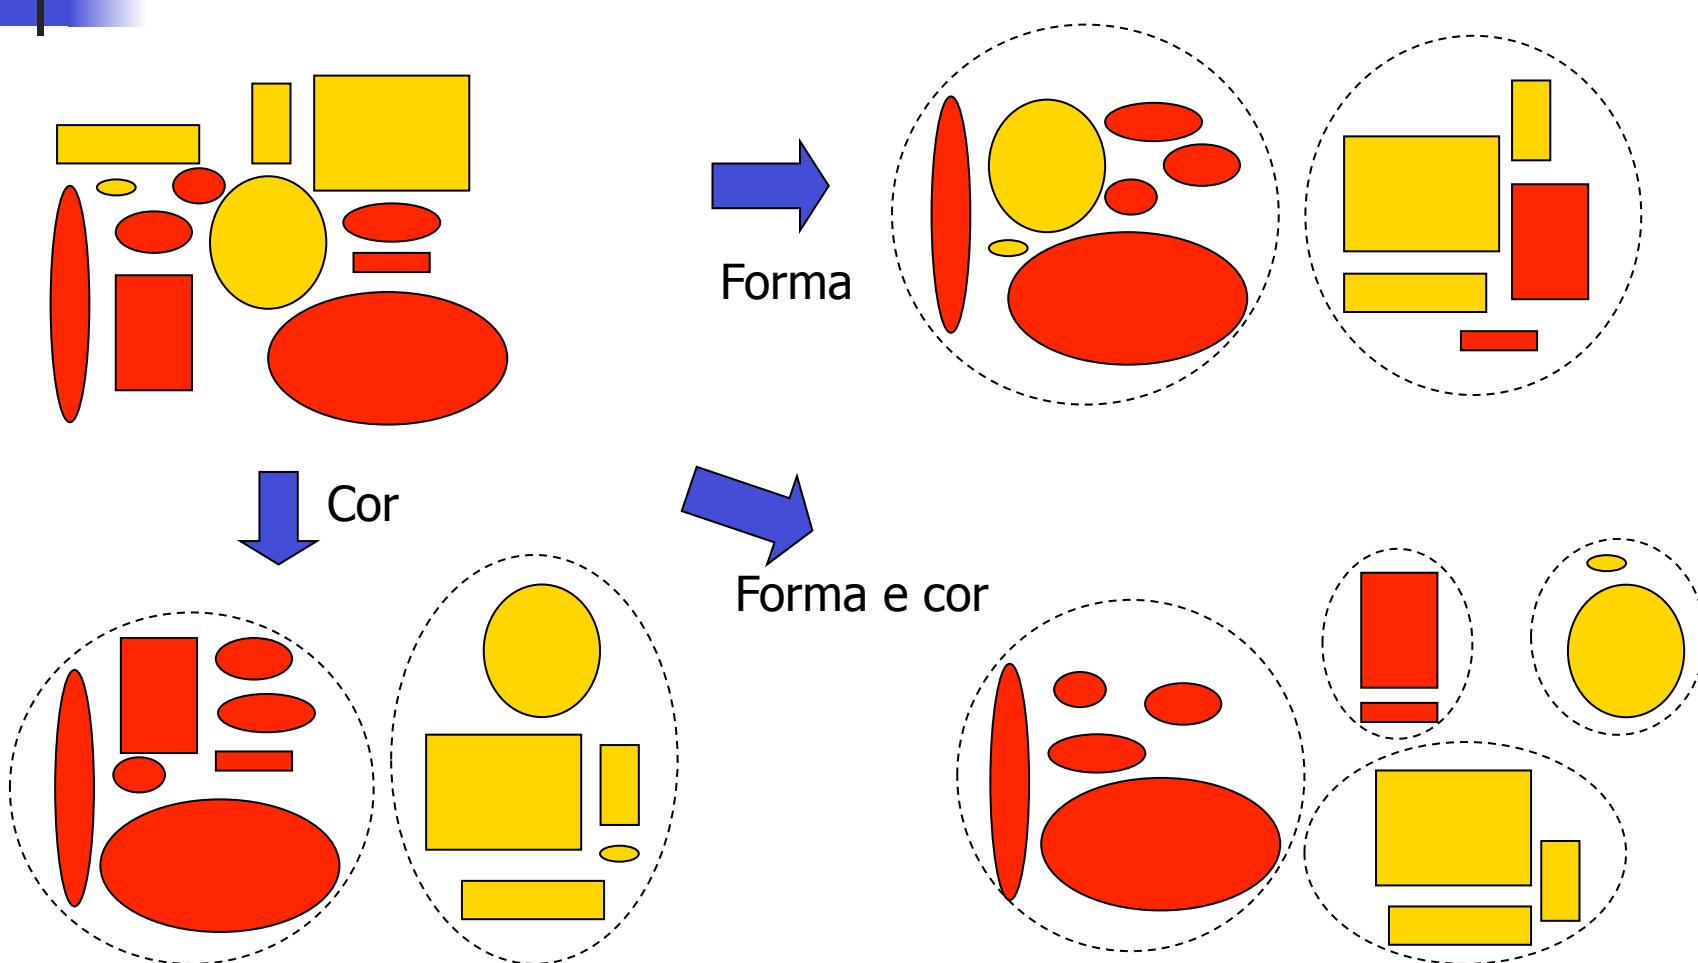
- Organização de um conjunto de objetos em grupos (clusters)
  - Particiona objetos de acordo com alguma relação entre eles

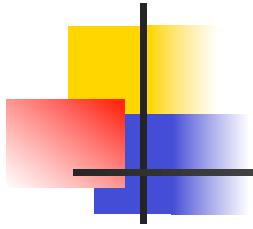


Como partitionar?



# Agrupamento

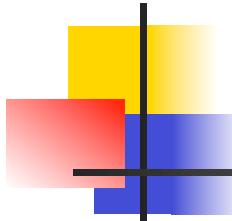




# Objetivo

---

- Encontrar partição que maximiza similaridade e minimiza dissimilaridade
  - Quanto maior a homogeneidade dentro dos grupos e menor entre os grupos, melhor
- Alternativa 1:
  - Busca exaustiva pela partição ideal



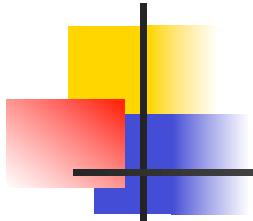
# Algoritmos de agrupamento

- Busca exaustiva
  - Tentar todos os possíveis agrupamentos de  $k$  grupos (para vários valores de  $k$ )
  - Números de Stirling do segundo tipo
    - Número de formas de particionar  $n$  exemplos em  $k$  subconjuntos não vazios

$$>> \binom{n}{k} \geq \left(\frac{n}{k}\right)^k$$

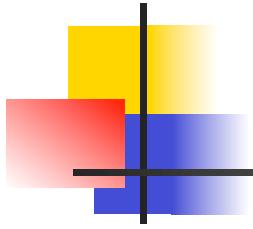
$k$  = número de grupos  
 $n$  = número de objetos

- Impraticável

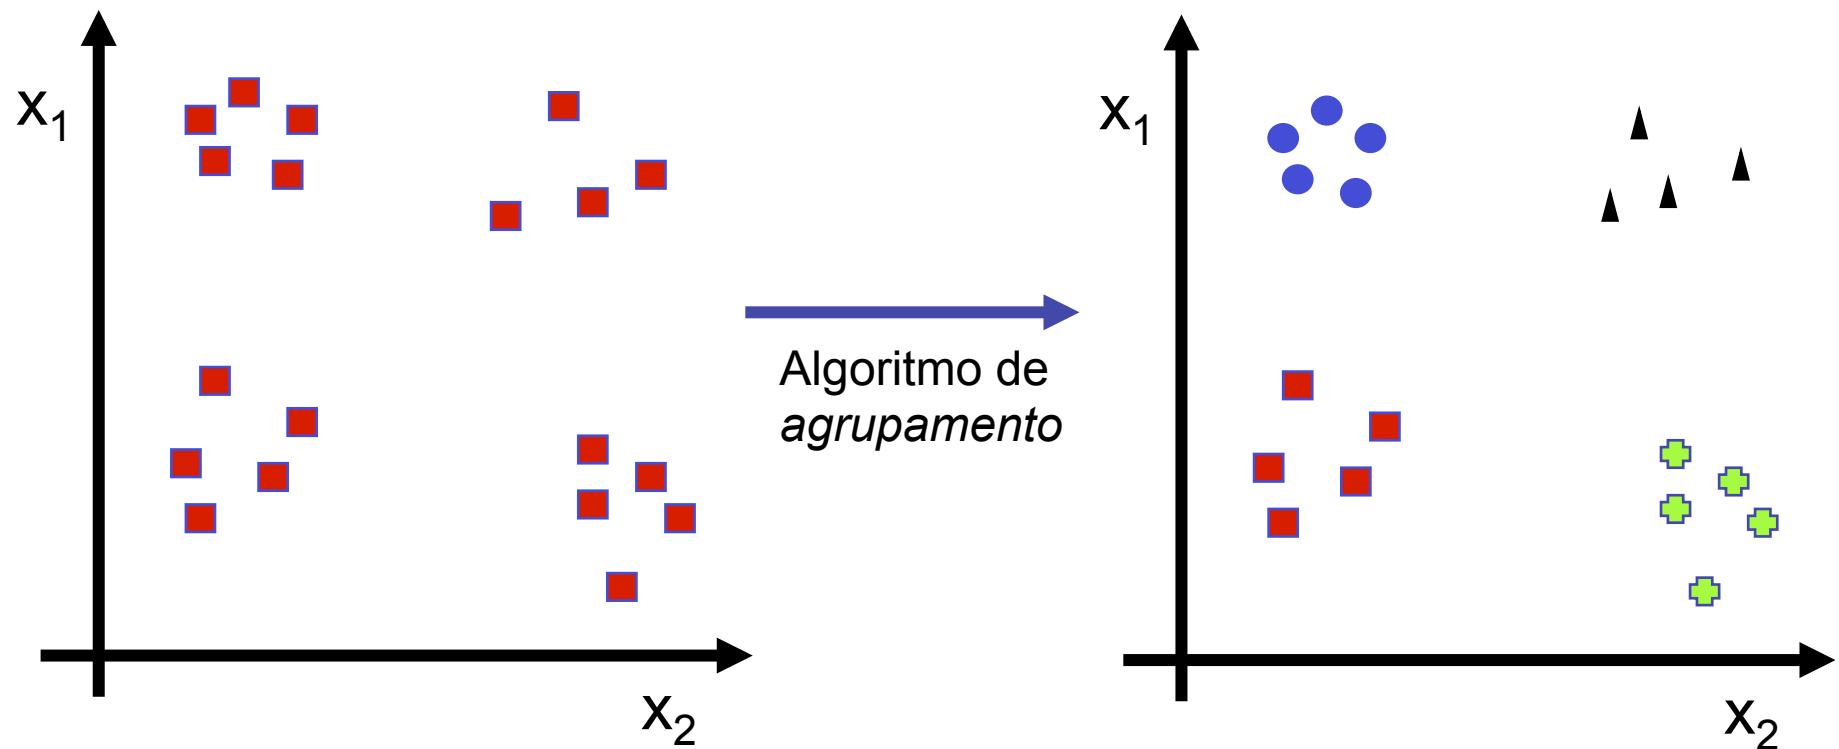


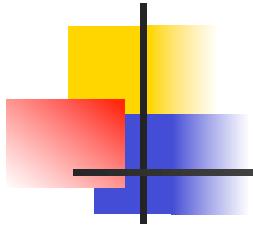
# Objetivo

- Encontrar partição que maximiza similaridade e minimiza dissimilaridade
  - Quanto maior a homogeneidade dentro dos grupos e menor entre os grupos, melhor
- Alternativa 1:
  - Busca exaustiva pela partição ideal
- Alternativa 2:
  - Utilizar uma heurística (algoritmo de agrupamento)

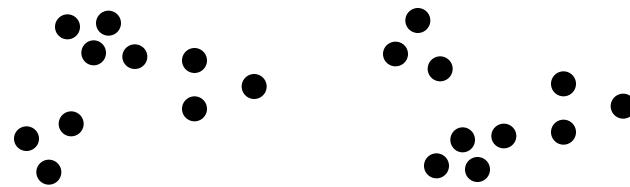


# Agrupamento de dados

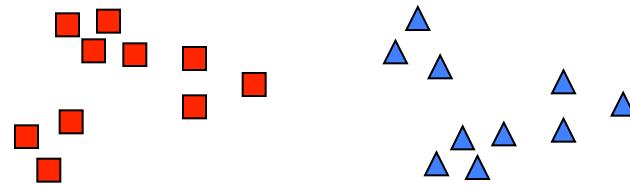




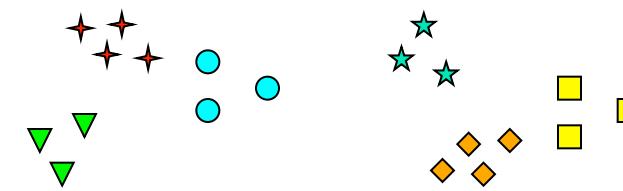
# Quantos clusters?



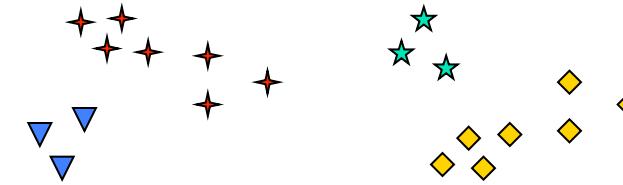
Dados originais



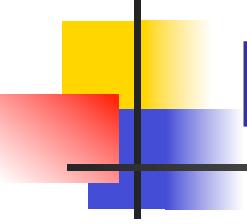
2 clusters



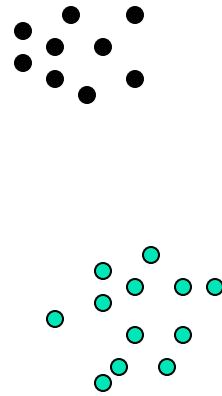
6 clusters



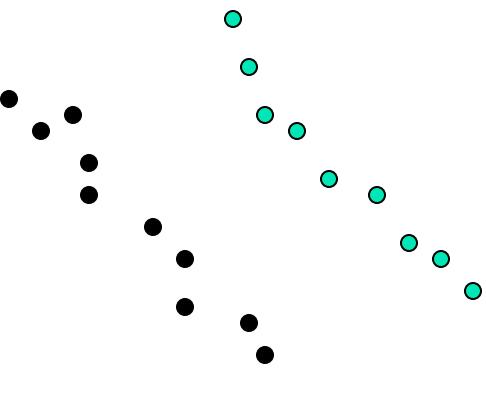
4 clusters



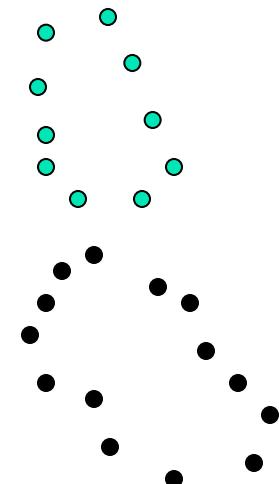
# Possíveis formatos



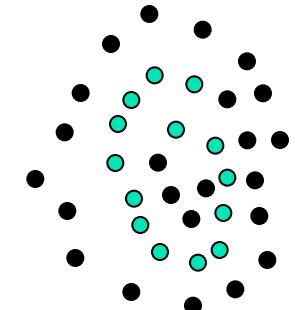
Compacto



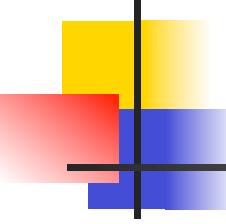
Alongado



Elipsoidal



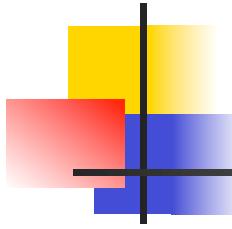
Espiral



# Agrupamento de dados

---

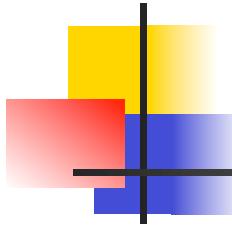
- Várias definições
- Gera partições
  - Grupos ou clusters
- De acordo com a pertinência dos dados, pode ser:
  - Duro (crisp)
  - Fuzzy



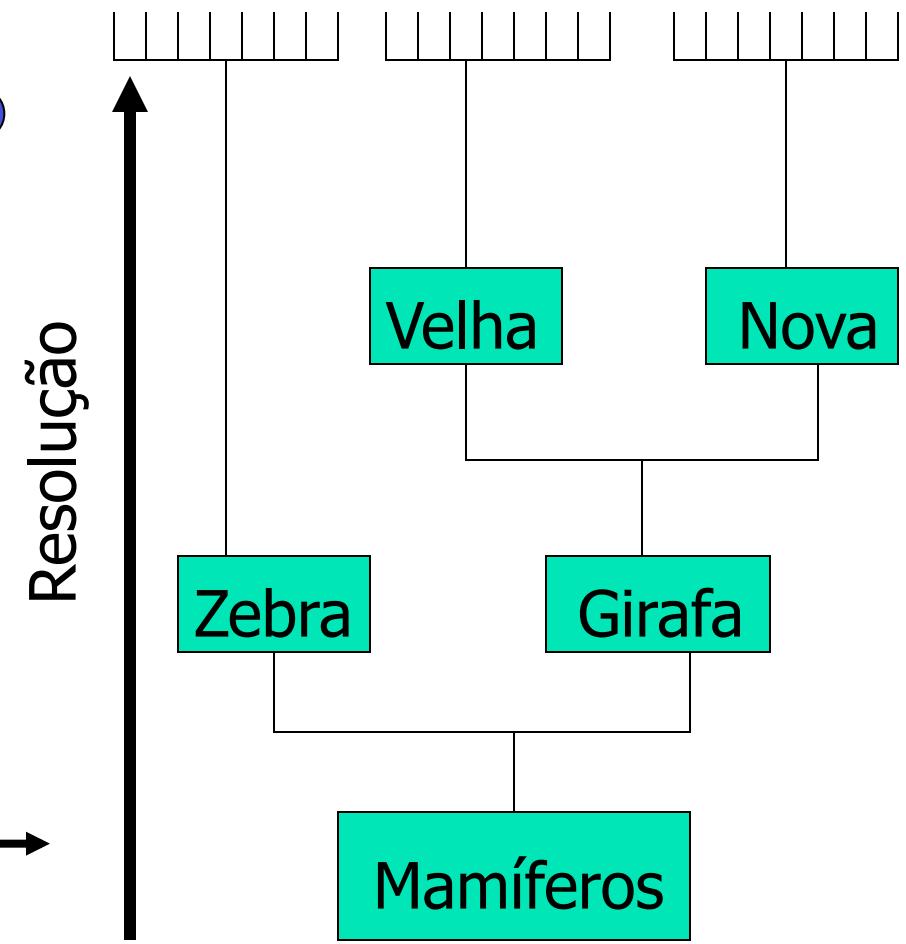
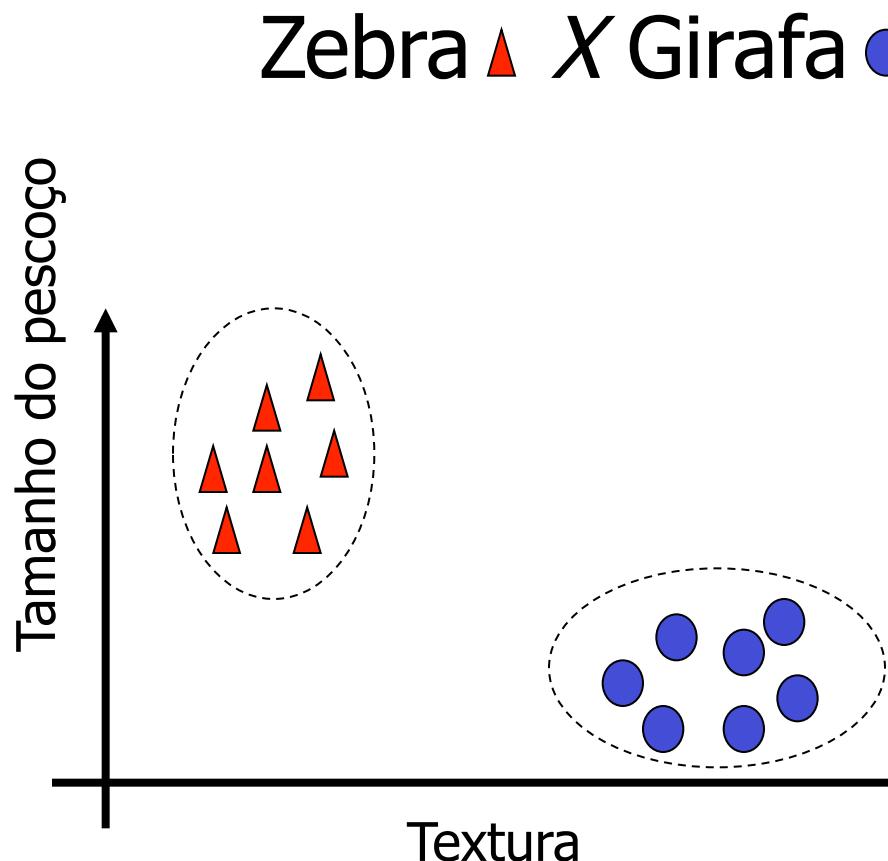
# Algoritmos de agrupamento

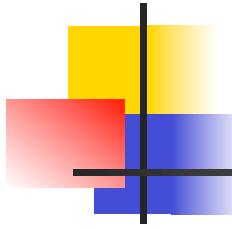
---

- Principais abordagens
  - Particionais
    - Protótipos (erro quadrático médio)
    - Densidade
  - Hierárquicos
  - Baseados em grids
  - Baseados em grafos



# Particional X Hierárquico

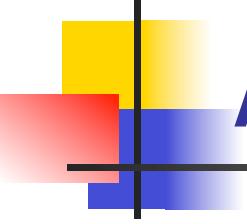




# Algoritmos particionais

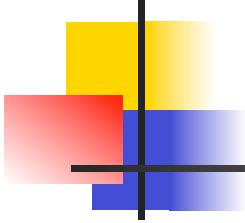
---

- Existem vários, incluindo
  - K-médias (K-médias ótimo, K-médias sequencial)
  - SOM
  - FCM
  - DENCLUE
  - CLICK
  - CAST
  - SNN



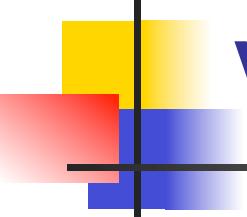
# Algoritmo k-médias

- 1 Sugerir médias  $\mu_1, \mu_2, \dots, \mu_k$  iniciais
- 2 Repetir
  - Usar as médias sugeridas para agrupar os objetos em  $K$  clusters
  - Para  $i$  variando de 1 a  $K$ 
    - Substituir  $\mu_i$  pela média de todos os objetos do cluster  $C_i$
  - Até nenhuma das médias mudar



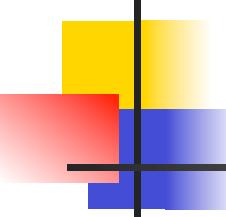
# Avaliação de Desempenho

## Descritivo



# Validação de agrupamentos

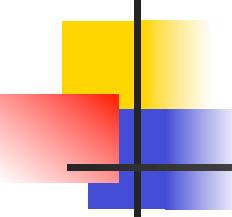
- Existem várias medidas para avaliar qualidade de classificadores
  - Acurácia, precisão, revocação, F1
- Como avaliar a partição gerada por um algoritmo de agrupamento?
  - Existem várias medidas de validação para agrupamento de dados
    - Julgam aspectos diferentes



# Medidas de validação

---

- Podem ser divididas em três grupos
  - Índices ou critérios externos
    - Medem o quanto os rótulos dos grupos coincidem com a classe verdadeira
  - Índices ou critérios internos
    - Medem a qualidade da partição obtida sem considerar informações externas
  - Índices ou critérios relativos
    - Usados para comparar duas partições ou grupos



# Medidas internas

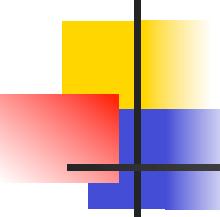
---

- Coesão de clusters
  - Mede o quanto próximos estão os objetos dentro de um cluster
- Separação de clusters
  - Mede o quanto distinto ou separado cada cluster está dos demais clusters



# Silhueta

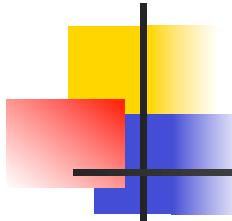
- Combina coesão com separação
- Calculada para cada objeto que faz parte de uma partição
  - Baseada em:
    - Distância entre os objetos de um mesmo cluster e
    - Distância dos objetos de um cluster ao cluster mais próximo



# Silhueta

---

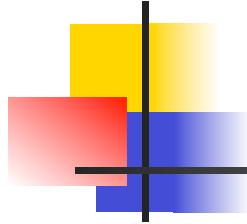
- Para cada objeto  $x_i$ 
  - $a(x_i)$ : distância média de  $x_i$  aos outros objetos de seu cluster
  - $b(x_i)$ : min (distância média de  $x_i$  a todos os objetos de cada um dos demais clusters)
- Largura média da silhueta
  - Média sobre todos os objetos do conjunto de dados
  - Valor entre -1 e 1 (quanto mais próximo de 1, melhor)



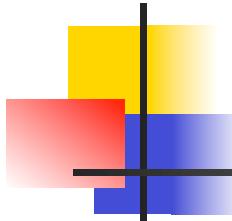
# Ambiente para experimentos

---

- Microcomputador (notebook) pessoal
- Cluster de computadores
- Nuvens
  - Quatro das principais nuvens possuem ferramentas para uso de AM
    - Amazon
    - Microsoft
    - Google
    - IBM



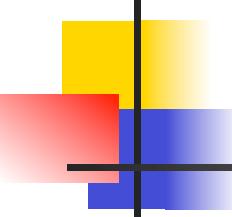
# Considerações Finais



# Conclusão

---

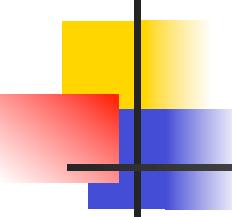
- Mineração de Dados
- Aprendizado de Máquina
- Algoritmos
  - Viés indutivo
- Tarefas
  - Preditivas
  - Descritivas



# Considerações Finais

---

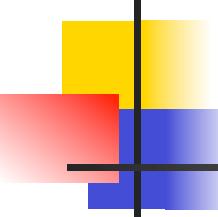
- Dados são bens preciosos
- Permitem extração de modelos e conhecimentos relevantes
- Extração manual e com técnicas simples é impossível ou ineficiente
- AM automatiza extração de modelos e conhecimentos a partir de dados
  - Cada vez mais usada em problemas reais
  - Várias aplicações em diversas tarefas



# Desafios

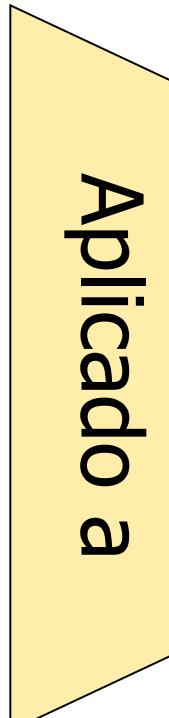
---

- Meta-aprendizado
- Pré-processamento
- Fortalecimento de base teórica
- Aprendizado em fluxos contínuos de dados
- Tarefas de classificação mais complicadas
  - Multiclasse, hierárquica, multirrótulo, uma classe, ranking
- Prova de corretude
- Comitês de algoritmos



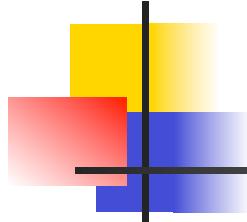
# Áreas de interesse

- Aprendizado ativo
- Classificação multirrótulo
- Comitês
- Dados desbalanceados
- Detecção de anomalia
- Detecção de novidades
- Limpeza de dados
- Meta-aprendizado
- Visualização de resultados



Aplicado a

- Agricultura
- Bioinformática
- Biometria
- Ecologia
- Finanças
- Medicina
- Redes sociais
- Sistemas de recomendação



# Perguntas

